



Universidad Politécnica de Madrid

ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA DE SISTEMAS INFORMÁTICOS

DOCTORADO EN CIENCIAS Y TECNOLOGÍAS DE LA COMPUTACIÓN PARA

SMART CITIES

TESIS DOCTORAL Sistema recomendador híbrido basado en modelos probabilísticos

Autor Priscila Marisela Valdiviezo Diaz

DIRECTORES

Dr. Jesús Bobadilla

Dr. Antonio Hernando

Septiembre 2019

TRIBUNAL

| | Tribunal n | ombrado por el Sr. Rector Magnífic | co de la Universid | ad Politécnica |
|----|--------------|---------------------------------------------|--------------------|----------------|
| de | Madrid, el | día de de | e 2019. | |
| | | | | |
| | Presidente | D. Fernando Ortega Requena (Uni | versidad Politécni | ca de Madrid) |
| | Vocales: | D. Miguel Ángel Patricio Guisado Madrid) | (Universidad Ca | rlos III de |
| | | D. Francisco Javier García Algarr | a (U-tad: Centro | Universitario |
| | | de Tecnología y Arte Digital) | | |
| | | D. Alejandro Martin (Universidad | l Autónoma de M | adrid) |
| | Secretario: | D. Abraham Gutierrez (Universida | ad Politecnica de | Madrid) |
| | Suplente: | D. Antonio González Pardo (Univ | ersidad Autónom | a de Madrid) |
| | Suplente: | D. Luis Usero Aragonés (Universid | | , |
| | Realizado e | el acto de lectura y defensa de la Te | sis el día | _ de |
| de | 2019 en la l | Escuela Técnica Superior de Ingeni | ería de Sistema Ir | nformáticos de |
| la | Universidad | Politécnica de Madrid. | | |
| | | | | |
| | Calificación | ı: | | |
| | | | | |
| | | | | |
| | | | | |
| | FI PRESI | DENTE | LOS VOC | CALES |

Resumen

Los sistemas de recomendación están diseñados para proporcionar recomendaciones a los usuarios por medio de un análisis de preferencias pasadas. Para lograr esto, los sistemas de recomendación utilizan técnicas de filtrado de información, las más conocidas son: filtrado colaborativo, filtrado basado en contenido, filtrado demográfico e híbrido. El filtrado colaborativo calcula las recomendaciones en función de las votaciones que la comunidad de usuarios ha realizado sobre un conjunto de ítems. Hay dos enfoques de filtrado colaborativo: basados en la memoria, que generalmente proporciona recomendaciones inexactas pero explicables; y basado en modelos, cuyas recomendaciones son más precisas pero difíciles de entender.

En la actualidad, se ha incrementado el desarrollo de sofisticados algoritmos de aprendizaje automático que se pueden usar en el contexto de los sistemas de recomendación. En esta tesis doctoral primero se presenta una revisión comprensiva sobre los enfoques basados en modelos para sistemas de recomendación de filtrado colaborativo, resaltando las ventajas y desventajas identificadas entorno a estos modelos. Luego, en base a las ventajas que ofrecen los enfoques basados en modelos probabilísticos, se propone un modelo bayesiano que combina el espacio de usuarios e ítems, y que proporciona tan buenos resultados como los modelos de factorización matricial, pero que a diferencia de éstos, genera una representación fácilmente interpretable, por tanto las recomendaciones son fáciles de explicar.

El modelo propuesto predice los nuevos votos de un usuario en función de los votos existentes en el conjunto de datos y éste permite fácilmente calcular una medida de confiabilidad relacionada con las predicciones. La confiabilidad se puede definir como la certeza que tiene el sistema de recomendación en el cálculo de las predicciones.

Se realizaron algunos experimentos con el objeto de comparar el enfoque propuesto con varios modelos de línea base, los cuales fueron seleccionados tanto de Resumen 4

la familia de enfoques basados en factorización matricial y de aquellos que utilizan un enfoque probabilístico para explicar sus resultados. Para los experimentos, se procesaron cuatro conjuntos de datos públicos de filtrado colaborativo, éstos fueron: MovieLens, FilmTrust, Yahoo, BookCrossing. El modelo fue evaluado considerando algunas medidas de calidad estándar: Error medio absoluto (MAE) para evaluar la calidad de las predicciones; Precisión y *Recall* para evaluar la calidad de las recomendaciones y la ganancia acumulada descontada normalizada (nDCG) para medir la calidad de las listas de recomendaciones.

Los resultados de los experimentos presentaron un mejor rendimiento con el enfoque propuesto utilizando nDCG en comparación con los métodos de línea base, también se presenta mejoras significativas en la precisión de la predicción en dos de los conjuntos de datos probados y se obtiene buenos resultados en la calidad de las recomendaciones, especialmente cuando el número de recomendaciones es bajo.

Abstract

Recommender systems are designed to provide recommendations to users by means of an analysis of past preferences. To achieve this, recommender systems use information filtering techniques, these can be: Collaborative Filtering, Content-based Filtering, Demographic Filtering, and Hybrid. Collaborative Filtering computes the recommendations based on the ratings that the community of users have made over a set of items. There are two collaborative filtering approaches: memory-based, which usually provides inaccurate but explainable recommendations; and model-based, whose recommendations are more precise but hard to understand.

Today's has increased the development of sophisticated machine learning algorithms which can be used in recommendation systems context. In this doctoral thesis, firts is presented a comprehensive review the literature on model-based approaches for recommender systems of collaborative filtering, highlighting strengths and weaknesses they provide. Then, based on the advantages offered by the approaches based on probabilistic models, a Bayesian model is proposed, that combines the space of users and items, and that provides as good results as the matrix factorization models, but unlike these, generates an easily interpretable representation, therefore, the recommendations are easy to explain.

The proposed modelit predicts new ratings of a user based on the existing ratings in the dataset, and it allows to easily compute a measure of reliability associate to the predictions. Reliability can be defined as the certainty of the recommendation system in the calculation of predictions.

Some experiments were performed in order to compare the proposed approach with several baseline models, which were selected both from the family of approaches based on matrix factorization and from those that use a probabilistic approach to explain their results. The experiments were carried out using four public datasets of collaborative filtering, these were: MovieLens, FilmTrust, Yahoo,

Abstract 6

BookCrossing. The model was evaluated considering some standard quality measures: Mean Absolute Error (MAE) to evaluate the quality of the predictions; Precision and Recall to evaluate the quality of the recommendations and the Normalized Discounted Cumulative Gain (nDCG) to measure the quality of recommendation lists.

The results of the experiments achieved a best performance in the quality measure nDCG compared to baseline methods, there are also significant improvements in the prediction accuracy in two of the tested datasets and good results are obtained in the quality of recommendations, especially when the number of recommendations is low.

Agradecimientos

En primer lugar quiero agradecer a Dios por la sabiduría, fortaleza y protección que me dio durante este tiempo de estudios y estancias fuera del país, por siempre estar conmigo en los momentos más difíciles que pasé en este proceso de formación. Gracias a Él estoy cumpliendo esta meta propuesta.

De igual manera, agradezco el apoyo de todas aquellas personas que de alguna forma me han ayudado en la realización de este trabajo. A mis directores de tesis y en especial agradezco al Dr. Fernando Ortega por su excelente asesoría, paciencia y amabilidad durante el desarrollo de esta tesis, quién además me brindó el apoyo necesario para que este trabajo llegara a buen término.

Mi más sincero agradecimiento a la Universidad Técnica Particular de Loja y a la Fundación Carolina por el apoyo brindado para realizar mi formación doctoral.

Finalmente, agradezco a mi madre y hermano por su confianza y comprensión, por sus ánimos en los momentos más difíciles y por siempre estar pendiente de mi desarrollo profesional y personal.

Listado de Publicaciones

Varios artículos resultantes de este trabajo de investigación han sido publicados en revistas y conferencias en el área de sistemas de recomendación.

Artículo: Valdiviezo-Diaz, P., Ortega, F., Cobos, E., Lara-Cabrera, R. (2019). A Collaborative Filtering approach based on Naive Bayes Classifier. IEEE Access, 7, 108581-108592, doi: 10.1109/ACCESS.2019.2933048.

Factor de impacto: 4.098 Q1 Indexación: JCR

Artículo: Ortega, F., Rojo, D., Valdiviezo-Diaz, P., & Raya, L. (2018). Hybrid Collaborative Filtering based on Users Rating Behavior. IEEE Access, 6, 69582–69591, doi: 10.1109/ACCESS.2018.2881074.

Factor de impacto: 4.098 Q1 Indexación: JCR

Artículo: Aguilar, J., Valdiviezo-Diaz, P., & Riofrio, G. (2016). A General Framework for Intelligent Recommender Systems. Applied Computing and Informatics, 13(2), 147–160, doi: 10.1016/j.aci.2016.08.002

Factor de impacto: 0.44 Q2 Indexación: SJR

Publicaciones en Congresos

Artículo: Valdiviezo-Diaz, P., & Bobadilla, J. (2018). A hybrid approach of recommendation via extended matrix based on collaborative filtering with demographics information. In International Conference on Technology Trends, CITT 2018 (pp. 384–398). vol 895, Springer, Cham.

Artículo: Aguilar, J., Valdiviezo-Diaz, P., & Riofrio, G. (2018). A Recom-

mender System Based on Cognitive Map for Smart Classrooms. In Proceedings of the International Conference on Information Technology Systems (ICITS 2018). Advances in Intelligent Systems and Computing, (pp. 427–442). Springer, Cham.

Artículo: Valdiviezo, P., & Hernando, A. (2016). A Comprehensive View of Recommendation Methods based on Probabilistic Techniques. In A. Rocha, L. Reis, M. Cota, R. Goncalves, O. Suarez (Eds.), Iberian Conference on Information Systems and Technologies, CISTI (pp. 604–609). Gran Canaria, Spain: IEEE Computer Society.

Índice general

| Re | Resumen | | | |
|----|---------|------------------------------|--------------------------------------------------------|----|
| Al | ostra | $\operatorname{\mathbf{ct}}$ | | 5 |
| Ag | grade | ecimie | ntos | 7 |
| Li | stado | de P | ublicaciones | 8 |
| 1. | Intr | oducci | ión | 16 |
| | 1.1. | Técnic | cas de recomendación | 17 |
| | | 1.1.1. | Filtrado colaborativo | 17 |
| | | 1.1.2. | Filtrado basado en contenido | 19 |
| | | 1.1.3. | Filtrado demográfico | 21 |
| | | 1.1.4. | Filtrado híbrido | 21 |
| | 1.2. | Enfoq | ues de filtrado colaborativo basado en modelos | 23 |
| | | 1.2.1. | Factorización matricial | 23 |
| | | 1.2.2. | Modelos probabilísticos | 23 |
| | 1.3. | Motiva | ación, Objetivos e Hipótesis | 24 |
| | 1.4. | Estruc | etura de la tesis | 27 |
| 2. | Esta | ado de | l arte sobre enfoques basados en modelos | 28 |
| | 2.1. | Visión | general | 28 |
| | 2.2. | Model | os basados en factorización matricial | 33 |
| | | 2.2.1. | Factorización matricial con bias | 33 |
| | | 2.2.2. | Factorización matricial no negativa | 34 |
| | | 2.2.3. | Limitaciones de los modelos de factorización matricial | 36 |
| | 2.3. | Model | os probabilísticos | 36 |
| | | 2.3.1. | Método Naïve Bayes mejorado | 37 |

<u>Índice general</u> 11

| | | 2.3.2. | Modelo Gaussian-Gamma |
|----|------|--------|---------------------------------------------------------------|
| | | 2.3.3. | Modelo de regresión Naïve Bayes para filtrado colaborativo 40 |
| | 2.4. | Model | os probabilísticos con factorización matricial 42 |
| | | 2.4.1. | Factorización matricial probabilística |
| | | 2.4.2. | Modelo bayesiano de factorización matricial no negativa 44 |
| | | 2.4.3. | Modelo Gaussian-Gamma de filtrado colaborativo: Baye- |
| | | | siano jerárquico |
| | | 2.4.4. | Otros modelos probabilísticos basados en factorización ma- |
| | | | tricial |
| | 2.5. | Model | os basados en reglas |
| | | 2.5.1. | Basados en árboles |
| | | 2.5.2. | Basado en reglas de asociación |
| | 2.6. | Ventaj | as y desventajas de los enfoques basados en modelos 54 |
| | 2.7. | Sumar | io |
| 3. | Mét | odo pi | ropuesto 60 |
| | 3.1. | Diseño | o del método |
| | | 3.1.1. | Componentes del método propuesto 61 |
| | | 3.1.2. | Clasificador Naive Bayes |
| | 3.2. | Formu | lación del método propuesto |
| | | 3.2.1. | Enfoque basado en el usuario |
| | | 3.2.2. | Enfoque basado en ítems |
| | | 3.2.3. | Enfoque híbrido |
| | 3.3. | Cálcul | o de la predicción |
| | 3.4. | Cálcul | o de confiabilidad |
| | 3.5. | Ejemp | lo de ejecución |
| | 3.6. | Algori | tmo NBCF |
| 4. | Exp | erimeı | ntos y resultados 74 |
| | 4.1. | Config | ruración del experimento |
| | 4.2. | Medid | as de calidad |
| | | 4.2.1. | Calidad de las predicciones |
| | | 4.2.2. | Calidad de las recomendaciones |
| | | 4.2.3. | Calidad de las listas de recomendaciones |
| | | 4.2.4. | Medidas de calidad seleccionadas |
| | 4.3. | Desem | peño del clasificador |

Índice general 12

| | | 4.3.1. MovieLens | 86 |
|-----------|-------|--------------------------------------------------------|-----|
| | | 4.3.2. FilmTrust | 87 |
| | | 4.3.3. Yahoo | 88 |
| | | 4.3.4. BookCrossing | 90 |
| | 4.4. | Desempeño del sistema de recomendación | 91 |
| | 4.5. | Medida de confiabilidad | 100 |
| | 4.6. | Análisis de complejidad computacional | 101 |
| | 4.7. | Discusión | 102 |
| 5. | Exp | olicación de recomendaciones | 104 |
| | 5.1. | Modelos de recomendación explicables | 105 |
| | 5.2. | Explicación de recomendaciones con el método propuesto | 108 |
| 6. | Con | aclusiones y trabajo futuro | 113 |
| R.e | efere | ncias | 116 |

Índice de figuras

| 1.1. | Esquema de los elementos que intervienen en un RS | 22 |
|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1.2. | Fundamentos de la propuesta | 25 |
| 2.1. | Clasificación de los enfoques basados en modelos | 30 |
| 4.1. | (a) matriz de confusión; (b) matriz de confusión normalizada; (c) matriz de confusión discretizando el voto (NoGusta = 1, 2, 3, Gusta = 4, 5); (d) Matriz de confusión normalizada discretizando el voto. Conjunto de datos de MovieLens-1M | 87 |
| 4.2. | (a) matriz de confusión; (b) matriz de confusión normalizada; (c) matriz de confusión discretizando el voto (NoGusta = 1, 2, 3, Gusta = 4, 5); (d) Matriz de confusión normalizada discretizando el voto. | |
| | Conjunto de datos FilmTrust | 88 |
| 4.3. | (a) matriz de confusión; (b) matriz de confusión normalizada; (c) matriz de confusión discretizando el voto (NoGusta = 1, 2, 3, Gusta = 4, 5); (d) Matriz de confusión normalizada discretizando el voto. Conjunto de datos Yahoo | 89 |
| 4.4. | (a) matriz de confusión; (b) matriz de confusión normalizada; (c) matriz de confusión discretizando el voto (NoGusta = 1, 2, 3, Gusta = 4, 5); (d) Matriz de confusión normalizada discretizando el voto. | 00 |
| 4 5 | Conjunto de datos BookCrossing | 90 |
| 4.5. | Ganancia acumulada descontada normalizada (nDCG) para el conjunto de datos MovieLens | 92 |
| 4.6. | Precisión y Recall de cada método de recomendación para el con- | |
| | junto de datos MovieLens | 93 |
| 4.7. | Ganancia acumulada descontada normalizada (nDCG) para el conjunto de datos FilmTrust | 94 |
| | | |

| 4.8. | Precisión y Recall de cada método de recomendación para el con- | |
|-------|------------------------------------------------------------------------------|-----|
| | junto de datos FilmTrust | 95 |
| 4.9. | Ganancia acumulada descontada normalizada (nDCG) para el con- | |
| | junto de datos Yahoo | 96 |
| 4.10. | . Precisión y Recall de cada método de recomendación para el con- | |
| | junto de datos Yahoo | 97 |
| 4.11. | . Ganancia acumulada descontada normalizada (nDCG) para el con- | |
| | junto de datos BookCrossing | 98 |
| 4.12. | . Precisión y Recall de cada método de recomendación para el con- | |
| | junto de datos BookCrossing | 99 |
| 4.13. | . Confiabilidad de la recomendación en (a) conjunto de datos Mo- | |
| | vieLens, (b) conjunto de datos FilmTrust, (c) conjunto de datos | |
| | Yahoo y (d) conjunto de datos BookCroosing | 101 |
| 5.1 | Matriz de votos | 110 |
| | | |
| 5.2. | Naïve Bayes based Collaborative Filtering - NBCF (usuario) | 110 |
| 5.3. | Naïve Bayes based Collaborative Filtering - NBCF (ítems) $\ \ldots \ \ldots$ | 111 |
| 5.4 | Naïve Bayes based Collaborative Filtering - NBCF (híbrido) | 112 |

Índice de tablas

| 2.1. | Características de los modelos probabilísticos | 58 |
|------|-----------------------------------------------------------------------------|----|
| 3.1. | Ejemplo de matriz de votos | 68 |
| 3.2. | Probabilidad prior del ítem i_1 usando el enfoque basado en el usuario | 69 |
| 3.3. | Probabilidad prior del usuario u_1 usando el enfoque basado en ítem | 69 |
| 3.4. | Likelihood del ítem i_1 basado en el voto del usuario u_1 | 70 |
| 3.5. | Likelihood del usuario u_1 basado en el voto del ítem $i_1 \ldots \ldots$ | 71 |
| 3.6. | Valor de clasificación, usando el enfoque basado en el usuario | 71 |
| 3.7. | Valor de clasificación, usando el enfoque basado en ítem | 71 |
| 3.8. | Valor de clasificación, usando el enfoque híbrido | 72 |
| 4.1. | Principales propiedades de los datasets usados en los experimentos | 75 |
| 4.2. | Métodos de línea base de CF utilizados para comparar los resulta- | |
| | dos con el método propuesto | 76 |
| 4.3. | Principales hiperparámetros utilizados en los experimentos. Data- | |
| | sets: MovieLens, FilmTrust, Yahoo, BookCrossing | 77 |
| 4.4. | Error medio absoluto (MAE) del desempeño de las predicciones de | |
| | los votos de test | 91 |

Capítulo 1

Introducción

Los sistemas de recomendación (RS, por sus siglas en inglés) se están convirtiendo en una alternativa para enfrentar el problema de la sobrecarga de información en la web (Lu, Wu, Mao, Wang, y Zhang, 2015). Estos sistemas están diseñados para proporcionar recomendaciones a usuarios registrados mediante un análisis de preferencias pasadas o en base a preferencias de usuarios similares (Ricci, Rokach, Shapira, y Kantor, 2011). RS actúa como un filtro que permite pasar la información relevante al usuario y bloquea la información irrelevante. Para este proceso, algunas técnicas de filtrado de información en RS y algoritmos de aprendizaje automático pueden ser usados. Las técnicas de recomendación más conocidas son el filtrado basado en contenido (CBF, por sus siglas en inglés), el filtrado colaborativo (CF, por sus siglas en inglés), filtrado demográfico, y filtrado híbrido (Bobadilla, Ortega, Hernando, y Gutiérrez, 2013). En (Aguilar, Valdiviezo-Díaz, y Riofrio, 2016) se presentan otras técnicas de recomendación como aquellas basadas en el conocimiento y en la comunidad.

Los sistemas de recomendación se han utilizado ampliamente en diferentes dominios de aplicación, con el objeto de recomendar una variedad de ítems, así podemos citar entre otros (Ricci y cols., 2011; Park, Kim, Choi, y Kim, 2012):

- Comercio electrónico: libros, dispositivos electrónicos, etc.
- Entretenimiento: programas de televisión, películas, música, juegos, etc.
- Turismo electrónico: restaurantes, servicios de viajes, casas en renta, etc.
- Educación: recursos educativos, cursos, etc.

En el dominio del comercio electrónico, por ejemplo, la recomendación se basa en algoritmos de CF. Podemos citar, la ventas por Amazon, las películas por Netflix que son seleccionadas en función de RS.

En la literatura podemos encontrar dos enfoques de CF: a) basado en la memoria, que generalmente proporciona recomendaciones inexactas pero explicables, éste se divide principalmente en dos tipos: enfoques basados en el usuario y basados en ítems; b) basado en modelos, cuyas recomendaciones son más precisas pero difíciles de entender. Hoy en día, los métodos basados en modelos están logrando mejores resultados en precisión y rendimiento. La implementación más popular del enfoque basado en modelos es la factorización matricial (MF, por sus siglas en inglés) (Koren, Bell, y Volinsky, 2009).

En el contexto de RS, el principal problema de la factorización matricial es que el espacio latente aprendido no es fácil de interpretar (K. Wang y Tan, 2011), por lo que estos modelos no son susceptibles de explicar sus resultados (Rastegarpanah, Crovella, y Gummadi, 2017). En esta tesis se direcciona este problema creando un modelo probabilístico que el usuario puede interpretar. El modelo propuesto combina enfoques basados en el usuario y en el ítem.

Para explicar en detalle el método propuesto, en este capítulo se abordan los conceptos fundamentales que involucran los sistemas de recomendación, se hace referencia a enfoques de factorización matricial y probabilísticos que son de interés en esta investigación. Luego se presenta la motivación e hipótesis de esta tesis. Finalmente se presenta la estructura de la tesis.

1.1. Técnicas de recomendación

En la literatura se distinguen diferentes enfoques de recomendación, entre ellos tenemos:

1.1.1. Filtrado colaborativo

En este enfoque las recomendaciones se calculan en función de las votaciones que la comunidad de usuarios ha realizado sobre un conjunto de ítems (Bobadilla y cols., 2013). Estos enfoques buscan similaridad entre los patrones de votación de los usuarios y hacen sugerencias de ítems que fueron considerados por otros usuarios en el pasado. Los sistemas de recomendación basados en CF utilizan una matriz de votos en la que cada usuario proporciona información sobre cuánto le

gusta o no le gustan algunos ítems. Así, los métodos de CF actúan directamente sobre la matriz de votos para calcular las predicciones y recomendaciones.

El CF puede subdividirse en enfoques basados en modelos y en memoria. En los enfoques basados en memoria la información a recomendar se obtiene directamente de la matriz de votos (Zhu, Hurtado, Bobadilla, y Ortega, 2018). La implementación más habitual del enfoque basado en memoria es KNN (K-Nearest-Neighbour)(Z. Wen, 2008), el cual captura relaciones similares entre usuarios o ítems según la matriz de votos, luego recomiendan los ítems que son altamente calificados por los usuarios similares al usuario activo (Yang, Wu, Zheng, Wang, y Lei, 2016), en este sentido el sistema de recomendación encuentra vecinos para un cierto usuario o ítem y calcula el valor de predicción para el voto desconocido. El método de recomendación basado en la memoria se puede subdividir en dos tipos: CF basado en el usuario y CF basado en ítems (Ricci y cols., 2011). Los métodos basados en el usuario predicen las votaciones de los usuarios activos basándose en las votaciones de los usuarios similares, y los enfoques basados en ítems predicen las votaciones del usuario en base a la información de ítems similares a los elegidos por el usuario activo. Los sistemas basados en memoria son la técnica más popular utilizada en aplicaciones de sistemas de filtrado colaborativo, son simples, fáciles de implementar y permiten explicar las recomendaciones que proporcionan (Hernando, Bobadilla, y Ortega, 2016). Las explicaciones con técnicas basadas en vecindarios son sencillas, ya que las recomendaciones se deducen directamente del comportamiento de los usuarios anteriores (Hu, Volinsky, y Koren, 2008), pero éstas no son precisas. Los métodos basados en memoria usualmente aplican métricas de similitud para obtener el parecido entre dos usuarios o dos ítems (Bobadilla y cols., 2013). Éstas pueden ser: Correlación de Pearson, Spearman Rank, Coseno, Jaccard, etc.

Por otro lado, en el enfoque basado en modelos, se crea un modelo a partir de la matriz de votaciones, que posteriormente se utiliza para hacer recomendaciones. Algunos ejemplos de métodos basados en modelos son entre otros, la factorización matricial (Salakhutdinov y Mnih, 2007), las redes bayesianas (Du y Chen, 2013), clustering (Bobadilla, Bojorque, Hernando, y Hurtado, 2018), reglas (Ali y cols., 2018), y enfoques basados en grafos (Fouss, Pirotte, Renders, y Saerens, 2007), son técnicas que trabajan exitosamente con sistemas de filtrado colaborativo basado en modelos.

En contraste con el enfoque basado en la memoria, el basado en modelos (es-

pecialmente la factorización matricial) ofrecen recomendaciones confiables pero son difíciles de explicar, porque todas las acciones pasadas del usuario se introducen en un modelo abstracto, bloqueando la relación directa entre las acciones pasadas del usuario y las recomendaciones proporcionadas (Hu y cols., 2008). Sin embargo, existen otro tipo de modelos como los probabilísticos que brindan facilidades en la explicación y justificación de las recomendaciones.

Los enfoques de filtrado colaborativo se enfrentan a problemas como (Aghdam, Analoui, y Kabiri, 2015; Parambath, 2013):

- Dispersión de la matriz de votos (Sparsity): este problema surge porque los usuarios no votan todos los ítems, es decir, los usuarios únicamente votan un pequeño porcentaje de los ítems que hay registrados en el sistema, y esto puede dar lugar a que el rendimiento del sistema disminuya.
- Escalabilidad: en los sistemas de recomendación el número de usuarios e
 ítems puede ser bastante grande, lo cual puede retardar el proceso de recomendación de manera significativa.
- Arranque en frío (Cold-start): en vista de que los sistemas de colaboración realizan la predicción basados en el voto de un usuario similar, surgen tres problemas de arranque en frío: nueva comunidad, nuevo ítem y nuevo usuario. El problema de nueva comunidad se da al iniciar con el sistema de recomendación, cuando existen pocos votos y todavía no existe información para aprender nada. Por tanto el sistema necesitaría obtener suficiente información de votos para poder realizar predicciones confiables. En el problema de nuevos ítems, si un ítem no ha sido votado, no tiene probabilidad de ser recomendado, o si ha sido votado por pocos usuarios, los resultados del sistema pueden ser muy sesgados. En el problema de nuevos usuarios, cuando un nuevo usuario ingresa al sistema no se tiene información de lo que le interesa, por tanto no es posible realizar las recomendaciones. De ahí que, el CF tiene como desventaja que el usuario siempre tiene que proporcionar algún voto, aunque no tenga una opinión formada sobre el ítem.

1.1.2. Filtrado basado en contenido

Puede diseñarse para recomendar ítems similares a los que a un usuario predeterminado le gustó en el pasado (Ricci y cols., 2011). Éstos utilizan información de los ítems para la predicción. La información de los ítems es importante para predecir su relevancia basado en un perfil de usuario, el cual incluye los gustos, preferencias y otras características, y sólo los ítems que tienen un alto grado de similitud con el perfil del usuario son recomendados (T.-m. Chang y Hsiao, 2013). Entre los métodos basados en modelos mayormente utilizados en RS basados en contenido, son: el método Latent Dirichlet Allocation (LDA) (Blei, Ng, y Jordan, 2003), un modelo generativo probabilístico no supervisado que puede ser utilizado para encontrar contenido semántico oculto en un corpus de texto. Este modelo permite modelar grandes corpus de texto, y generar aleatoriamente los documentos que se observan en este corpus; Análisis Semántico Probabilístico Latente (PLSA, también llamado PLSI por sus siglas en inglés), es una técnica de factorización matricial, que descompone la matriz de apariciones de palabras/ítems, en dos matrices que van a tener un significado probabilístico. Los ítems y las palabras están caracterizadas por una distribución de probabilidad la cual indica el grado de pertenencia de un ítem o palabra hacia un tópico u otro (Ekstrand, Riedl, y Konstan, 2011).

El enfoque basado en contenido tiene las siguientes limitaciones:

- Análisis de contenido limitado: está relacionado con la eficacia de las palabras claves y con las características asociadas a los ítems, por tanto, las técnicas basadas en el contenido están limitadas a las características que se asocian con los ítems que estos sistemas recomiendan (Ricci, Rokach, y Shapira, 2015).
- Sobre especialización: dado que los sistemas basados en contenido sólo recomiendan ítems que tienen un alto grado de similitud con aquellos preferidos en el pasado, el usuario está limitado a que el sistema le recomiende ítems que son similares a esos que ya fueron puntuados. Por tanto, el conjunto de ítems recomendados podría ser obvio y demasiado homogéneo (Lops, Gemmis, y Semeraro, 2011).
- Problema de nuevos usuarios (cold-start): el usuario tiene que evaluar un número suficiente de ítems antes de que un sistema de recomendación basado en contenido pueda entender las preferencias del usuario y proporcionar recomendaciones confiables. Esto además significa que los sistemas de recomendación deben ser lo suficientemente capaces para brindar recomendaciones no triviales para un usuario sin suficientes recomendaciones previas

en su perfil (Adomavicius y Tuzhilin, 2005).

1.1.3. Filtrado demográfico

Los sistemas están basados en información demográfica del usuario, como: la edad, género, ciudad, lenguaje, sexo, opiniones que tienen los usuarios sobre los ítems (Bobadilla y cols., 2013), etc. Esta información es necesaria para conocer las preferencias comunes entre los usuarios y así generar las recomendaciones. En esta técnica de recomendación se clasifica al usuario según sus atributos personales. De acuerdo a (Pazzani, 2000) las recomendaciones pueden estar basadas en información sobre otros usuarios del grupo al que pertenecen.

Un problema con este tipo de filtrado es la de obtener información demográfica que puede ser una tarea difícil y necesariamente se debería obtener información del usuario para poder hacer la recomendación.

Algunos trabajos desarrollados que incorporan información demográfica son: (Valdiviezo-Díaz y Bobadilla, 2018), el cual usa el enfoque de matriz extendida para incorporar información demográfica del usuario. En (H. Zhang, Nikolov, y Ganchev, 2017) proponen el uso de perfiles de usuario combinados, que son aprendidos de los ítems vistos por el usuario.

1.1.4. Filtrado híbrido

Combina dos o más enfoques de recomendación para tener un mejor funcionamiento. Se utilizan comúnmente el filtrado colaborativo con otra técnica que reduzca problemas de recomendación con nuevos ítems (Valdiviezo y Hernando, 2016). Estos sistemas tratan de mejorar todas las limitaciones que tienen los demás enfoques de recomendación, por ejemplo: CF se basa sólo en información de votos, y descarta características significativas de usuarios e ítems; CBF emplea características de usuarios e ítems, pero ignora los votos del usuario.

Actualmente se han propuesto enfoques de filtrado híbrido para integrar información ya sea del usuario o del ítem, por ejemplo: información demográfica del usuario o preferencias explícitas del usuario, metadatos de ítems o algún otro contenido del ítem, etc., con el objeto de mejorar la calidad de las recomendaciones. Un modelo híbrido que combina filtrado colaborativo y filtrado demográfico usando un modelo de factorización matricial, se presenta en (Valdiviezo-Díaz y Bobadilla, 2018). En (Tiwari y Potter, 2015), se propone un sistema de recomen-

dación para el usuario combinando filtrado colaborativo en los datos de transacción con el voto estimado, la información demográfica del usuario y la similitud del ítem.

También es posible construir sistemas híbridos combinando los enfoques basados en memoria y basado en modelos correspondientes a una misma técnica de recomendación. Por ejemplo algunos trabajos que combinan enfoques de CF basado en el usuario y basado en ítems dentro de un enfoque basado en modelo son los presentados por (Zhao, Sun, Han, y Peng, 2016; Kumar y Fan, 2015; Valdiviezo-Diaz, Ortega, Cobos, y Lara-Cabrera, 2019).

La figura 4.4 contiene un resumen de lo anteriormente explicado:

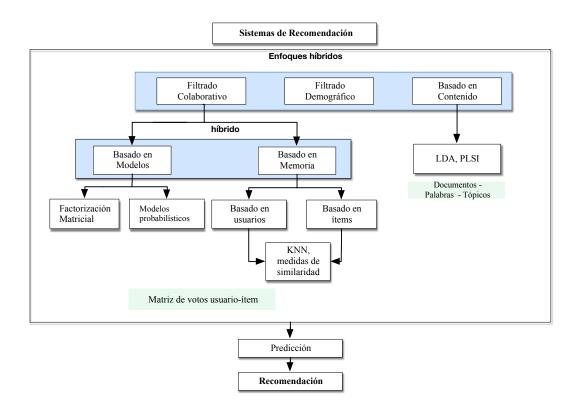


Figura 1.1: Esquema de los elementos que intervienen en un RS

En la figura anterior podemos observar los tipos de enfoques de sistemas de recomendación más utilizados en la literatura y los métodos de recomendación que se pueden utilizar en cada uno de ellos. Se observa también que un enfoque híbrido puede estar formado por la combinación de varias técnicas de recomendación (CF y CBF, CF y Demográfico, etc.), o por la combinación de diferentes algoritmos

de CF, a fin de mejorar el desempeño del sistema.

1.2. Enfoques de filtrado colaborativo basado en modelos

La mayoría de los enfoques actuales de filtrado colaborativo se enfrentan a tres problemas: dispersión, escalabilidad y cold-start (Parambath, 2013; Aghdam y cols., 2015). Adicional a éstos, en (Mohamed, Khafagy, y Ibrahim, 2019) se mencionan otros desafíos como: Sobre-especialización, Diversidad, Novedad, etc., que también necesitan ser investigados y solucionados.

Estos problemas se han abordado desde una amplia gama de perspectivas que aplican diferentes métodos en orden a proporcionar recomendaciones. A continuación se mencionan algunos de ellos.

1.2.1. Factorización matricial

La factorización matricial se ha convertido en una de las técnicas principales para dar solución a los problemas de escalabilidad. La factorización matricial es un método basado en modelos, donde los votos del usuario a ítems se modelan con un conjunto de factores latentes, que representan las características de los usuarios e ítems. Algunas implementaciones de este método son: Factorización Matricial con bias (BiasedMF) (Koren y Bell, 2015), Factorización Matricial Probabilística (PMF, por sus siglas en inglés) (Salakhutdinov y Mnih, 2007), Factorización Matricial No Negativa (NMF, por sus siglas en inglés) (L. Zhang, Chen, Zheng, y He, 2011), Factorización Matricial No Negativa Bayesiana (BNMF, por sus siglas en inglés) (Hernando y cols., 2016).

1.2.2. Modelos probabilísticos

En la literatura hay algunos métodos de recomendación desarrollados a partir de la teoría de la probabilidad. De acuerdo a (Ekstrand y cols., 2011) estos métodos por lo general tienen como objetivo construir modelos probabilísticos del comportamiento del usuario y usar esos modelos para predecir el comportamiento futuro. Los modelos probabilísticos han sido desarrollados tanto para ser usados en enfoques de filtrado colaborativo (ejemplo: PMF, BNMF), como en aquellos

basados en contenidos (LDA, PLSA), algunos de ellos se mencionaron también en el apartado anterior.

De acuerdo a (Herlocker, Konstan, y Riedl, 2000), las explicaciones de recomendaciones de RS adecuadas conducen a una mayor confianza del usuario. Por lo tanto, es necesario tener modelos de recomendación que permitan justificar correctamente sus predicciones. Los modelos probabilísticos son una alternativa para este proceso.

Hoy en día, los métodos basados en modelos probabilísticos están logrando mejores resultados en precisión y rendimiento, ya que éstos presentan buen desempeño de predicción.

Algunos trabajos desarrollados recientemente con este tipo de modelos para enfoques de filtrado colaborativo, son discutidos en el capitulo 2.

1.3. Motivación, Objetivos e Hipótesis

Diversas propuestas de enfoques de recomendación basados en modelos se han centrado en solucionar algunos de los problemas que enfrentan los sistemas de recomendación como: escalabilidad, interpretabilidad, cold-start, calidad de las predicciones, etc., sin embargo los resultados que proporcionan siguen siendo difíciles de interpretar. Si bien es cierto los enfoques basados en la memoria son de fácil implementación y pueden explicar fácilmente sus resultados, pero éstos generalmente proporcionan peores recomendaciones que los basados en modelos. Los enfoques basados en modelos presentan un mejor desempeño en la predicción proporcionando recomendaciones altamente precisas, sin embargo los modelos, especialmente los basados en factorización matricial, siguen siendo demasiado abstractos para explicar las recomendaciones. Por otro lado, los modelos probabilísticos explican mejor sus resultados que los basados en factorización matricial, debido al concepto de probabilidad que es más cercano al usuario que el concepto de espacio de factores latentes.

De ahí que el desarrollo de modelos que faciliten la explicación de sus recomendaciones es un tema que aún continua siendo explorado. Por lo tanto se ha visto la necesidad de entrar en el tema de los enfoques basados en modelos probabilístico aplicados a CF, que permitan explicar sus predicciones.

Objetivo principal

 Desarrollar un modelo que proporcione recomendaciones tan certeras como las generadas mediante factorización matricial y que permita justificarlas.

El objetivo principal de esta tesis se fundamenta principalmente en el siguiente esquema:

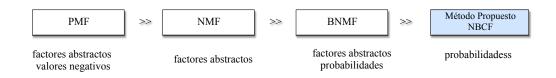


Figura 1.2: Fundamentos de la propuesta

Se conoce que la factorización matricial probabilística ofrece recomendaciones confiables pero su gran limitante es la explicación de sus resultados en términos de factores latentes. La principal problemática de estos factores, más allá de su alto nivel de abstracción, es la inclusión de factores negativos dentro del modelo de fatorización matricial. NMF restringe estos factores a solo valores positivos, pero las predicciones siguen estando sujetas a factores latentes, por lo que el problema de intentar dar un significado a estos factores continua estando presente. Actualmente se ha intentado juntar modelos que expliquen bien los resultados y que además tengan las virtudes de la factorización matricial, como por ejemplo BNMF (Hernando y cols., 2016) que ha sido desarrollado para aliviar el problema de la interpretación de resultados, aplicando un enfoque probabilístico para interpretar los factores de usuarios e ítems. Sin embargo, estos factores siguen siendo extremadamente abstractos para los usuarios.

De ahí que, los modelos probabilísticos están siendo ampliamente estudiados dentro del CF porque brindan ventajas para la explicación de recomendaciones, además éstos están dando buenos resultados debido a que pueden aplicarse para modelar y razonar sobre la incertidumbre en el proceso de hacer las recomendaciones.

De acuerdo a la figura 1.2 se ha ido convergiendo a un modelo que intente explicar los factores latentes, pero seguimos estando sujetos a las limitaciones que éstos presentan. Por ello en esta tesis se propone un modelo probabilístico fácilmente interpretable, que no use factorización matricial, y que proporcione una

explicación muy clara de sus resultados, el cual además compita con los modelos del estado del arte analizados.

El modelo propuesto está basado en técnicas bayesianas y combina los dos enfoques de CF: basado en el usuario y basado en ítems. Se combinan estos enfoques porque se complementan adecuadamente.

El objetivo principal es logrado mediante los siguientes **objetivos específi**cos:

- Analizar y seleccionar los trabajos de investigación que usen modelos probabilísticos para filtrado colaborativo y que además puedan ser utilizados como métodos de linea base para comparar con los resultados del modelo propuesto.
- Diseñar un nuevo modelo probabilístico para filtrado colaborativo que permita explicar las recomendaciones.
- Seleccionar datasets del estado del arte utilizados en el contexto de los sistemas de recomendación.
- Evaluar el desempeño del modelo con los datasets seleccionados usando medidas de calidad estándar y comparar sus resultados con otros métodos de línea base.

Hipótesis

Para alcanzar estos objetivos se plantea la siguiente hipótesis.

Es posible construir un modelo probabilístico que brinde tan buenos resultados como los modelos de factorización matricial y que además permita justificar de forma simple las recomendaciones que el modelo proporcione.

Las principales contribuciones de esta tesis son:

- Proporcionar un estado del arte sobre enfoques basados en modelos aplicados a sistemas de recomendación, resaltando las ventajas y desventajas identificadas entorno a estos modelos.
- Aprovechar las posibilidades que ofrecen los enfoques basados en modelos como los métodos probabilísticos, desarrollando un modelo híbrido basado

en técnicas bayesianas que combine los enfoques de CF de usuarios e ítems y que además permita la explicación de las recomendaciones.

- Sugerir un conjunto de métricas que puedan ser utilizadas para medir la calidad de las predicciones y recomendaciones de modelos probabilísticos para CF. Además de proporcionar una medida de confiabilidad relacionada con las predicciones.
- Facilitar una serie de datasets que han sido preparados para ser utilizados en la evaluación del método propuesto.

1.4. Estructura de la tesis

Este trabajo de investigación está estructurado de la siguiente manera:

Capítulo 2, presenta el estado del arte sobre enfoques basados en modelos para filtrado colaborativo, sean éstos: basados en factorización matricial, probabilísticos y basados en reglas.

Capítulo 3, describe el método propuesto para CF, haciendo referencia a tres enfoques, basado en el usuario, basado en ítems e híbrido. Además se presenta el cálculo de una medida de confiabilidad relacionada con las predicciones.

Capítulo 4, presenta la experimentación y evaluación de resultados, comparando el método propuesto con otros modelos del estado del arte, mediante el uso de métricas para la evaluación de la calidad de las predicciones y recomendaciones. Se presenta también el desempeño del clasificador para los conjuntos de datos utilizados.

Capítulo 5, se mencionan algunos modelos de recomendación explicables, y se muestra la explicación de los resultados con el modelo propuesto.

Capítulo 6, finalmente en este capítulo se detallan las conclusiones y trabajos futuros.

Capítulo 2

Estado del arte sobre enfoques basados en modelos

En esta sección se brinda unan visión general del estado actual de los enfoques de filtrado colaborativo basados en modelos. Luego se describen algunos métodos seleccionados de la revisión de la literatura, los cuales se los ha categorizado de acuerdo a la técnica que utilizan. Algunos de estos modelos son considerados como métodos de línea base con el objeto de comparar los resultados obtenidos con el enfoque propuesto. Para tener una idea clara de las características que poseen estos enfoques, se identifican además las principales ventajas y desventajas que brindan cada tipo de modelo establecido.

2.1. Visión general

En la literatura se proponen un gran número de enfoques de CF basados en modelos, algunos de ellos son modelos probabilísticos que facilitan la interpretación de sus resultados. También existen otros modelos como los basados en factorización matricial que generan una representación que no es fácilmente interpretable para el usuario.

Debido a las ventajas que brindan los modelos probabilísticos, como: buen

desempeño de predicción, facilidad para la explicación y justificación de resultados, etc. éstos en los últimos años han ido ganando importancia en diferentes campos de aplicación, por ejemplo, en el comercio electrónico autores como (Gaikwad, Udmale, y Sambhe, 2018) proponen un modelo probabilístico de CF para mejorar el análisis de las consultas de búsqueda y predecir la probabilidad de los productos que serán recomendados al usuario; en medicina (X. Li y Li, 2018), proponen un modelo probabilístico de aprendizaje en profundidad para analizar gran cantidad de datos médicos y hacer una predicción personalizada del riesgo para la salud; en transporte (Tang, Chen, Liu, y Khattak, 2018), desarrollan un modelo probabilístico bayesiano para la estimación del tiempo de viaje personalizado, utilizando las trayectorias de GPS dispersas y a gran escala generadas por los taxis.

De acuerdo a (Ekstrand y cols., 2011), los modelos probabilísticos son aplicables cuando el proceso de recomendación debe seguir modelos de comportamiento del usuario.

El objetivo del aprendizaje en los modelos probabilísticos es estimar la función de densidad de probabilidad de los datos o la distribución de probabilidad, para lo cual es necesario hacer ciertas suposiciones sobre:

- El modelo de distribución que describe los atributos. Es muy importante conocer con qué atributos contamos en nuestro conjunto de entrenamiento para asumir el tipo de distribución que estos atributos representan, en nuestro caso serían los votos del usuario. Por ejemplo una distribución multinomial es comúnmente utilizada cuando los atributos son discretos, y cuando los atributos son continuos, éstos son distribuidos mediante una distribución normal.
- El modelo de distribución que describe las clases. Conocer cuál es la salida esperada del algoritmo, si ésta va ser binaria o categórica. En caso de que la clase sea discreta se utiliza una distribución multinomial. Además en este punto también se puede considerar como realizar la estimación de la clase, la cual puede ser con una distribución posterior, es decir considerar solo la clase con la mayor probabilidad a posteriori Maximum A Posteriori (MAP, por sus siglas en inglés), o utilizar el método de estimación de máxi-

ma verosimilitud *Maximum Likelihood Etimation* (MLE, por sus siglas en inglés).

■ La dependencia entre las variables. Puede darse el caso de que todas las variables sean independientes, que hayan variables que tengan independencia y otras no, que las variables sean dependientes, etc. De esto depende el método que se utilice para el modelado, por ejemplo si suponemos que todas las variables son independientes conocido el valor de la clase, entonces se puede utilizar el método naives bayes.

En base a la revisión de la literatura, en la siguiente figura se muestra una clasificación de los enfoques basados en modelos y algunos de los algoritmos estudiados en cada uno de ellos.

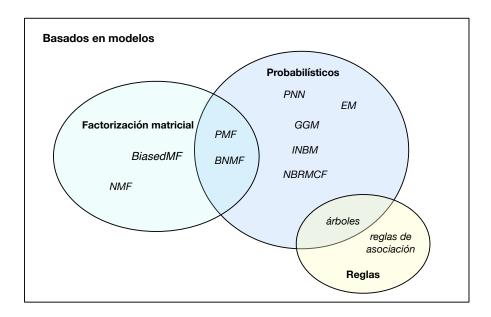


Figura 2.1: Clasificación de los enfoques basados en modelos

En la figura 2.1 se diferencia tres familias de enfoques basados en modelos: de factorización matricial, probabilísticos y basados en reglas. Se puede ver también como los métodos probabilísticos pueden ser utilizados en combinación con otras técnicas como la factorización matricial.

■ Factorización matricial (Koren y cols., 2009), consisten en descomponer una matriz en dos o más matrices que hacen referencia a los usuario e ítems

respectivamente. En esta categoría se incluyen modelos no probabilísticos como la factorización matricial no negativa y la factorización matricial con bias.

- Modelos probabilísticos, en esta familia se listan algunos modelos bayesianos y no bayesianos. Los bayesianos de acuerdo a (Barber, 2012), utilizan el conocimiento previo junto con un modelo dado, para hacer inferencias sobre cantidades desconocidas. Los métodos bayesianos tienen como punto central el Teorema de Bayes. En este conjunto también se mencionan trabajos que combinan modelos probabilísticos con técnicas de factorización matricial. En la siguiente sección se desarrolla más este tipo de modelos.
- Modelos basados en reglas (Hernando, Bobadilla, Ortega, y Gutiérrez, 2017; Najafabadi, Mahrin, Chuprat, y Sarkan, 2017): Los hemos subdivido en aquellos modelos basados en árboles (los cuales pueden realizar una selección de variables en la construcción del modelo); y aquellos modelos basados en reglas de asociación, que describen las asociaciones entre los datos (usuario - ítem) en la base de datos.

Los modelos probabilísticos modelan la incertidumbre con las distribuciones de probabilidad y, a menudo, utilizan la máxima verosimilitud (likelihood) para encontrar un simple modelo óptimo. El likelihood o la estimación de máxima verosimilitud se puede utilizar para estimar los parámetros del modelo de aprendizaje.

Como parte de los modelos probabilísticos están también, las redes neuronales probabilísticas (PNN, por sus siglas en inglés) (Devi, Samy, Kumar, y Venkatesh, 2010), las cuales han sido utilizadas para aliviar problemas de sparsity y cold-start en filtrado colaborativo. Las redes neuronales también han sido usadas en combinación con la factorización matricial. En la literatura se encuentran algunos estudios realizados recientemente con este tipo de combinación, podemos citar entre otros: un modelo probabilístico que usa una red neuronal para filtrado colaborativo presentado por (He y cols., 2017), y un modelo probabilístico híbrido basado en redes neuronales para extraer factores latentes de los usuarios e ítems (Liu y Wang, 2017). Por otro lado, existen modelos basado en técnicas de clustering, como el Expectation-Maximization para filtrado colaborativo (EMCF, por

sus siglas en inglés) (K. Wang y Tan, 2011), el cuál también se basa en MF para inferir las preferencias del usuario. En (Nilashi, bin Ibrahim, Ithnin, y Sarmin, 2015) se presenta un método híbrido de CF multi-criterio basado en EM en combinación con redes neuronales y técnicas de reducción de dimensionalidad, para la recomenación de hoteles.

Por otra parte, los modelos probabilísticos bayesianos son capaces de integrar el conocimiento anterior en sus probabilidades condicionales y manejar observaciones faltantes. De acuerdo a (Shengbo, 2011) los métodos bayesianos a menudo asumen que el parámetro del modelo (clase) se extrae de alguna distribución de probabilidad previa con algunos parámetros llamados hiperparámetros utilizados para distinguirlos de los parámetros del modelo.

Los modelos probabilísticos incluidos en la figura 2.1, son explicados en la siguiente sección, algunos de ellos son considerados como métodos de linea base para comparar sus resultados con el modelo propuesto.

Externamente a todos los tipos de modelos mencionados, se identificaron otros modelos, que se ubicarían dentro del recuadro general; hablamos de aquellos modelos basados en: métodos difusos (S.-M. Chen, Cheng, y Lin, 2015), algoritmos genéticos (Hassan y Hamada, 2018), entre otros, los cuales han presentado buen desempeño en la calidad de las predicciones y recomendaciones. Sin embargo, siguen presentando ciertas limitaciones, por ejemplo, en los algoritmos genéticos, la implementación de la solución podría tornarse demasiado costosa en términos de tiempo y recursos.

En el contexto de los RS, existen problemas que son necesarios modelarlos usando distribuciones de probabilidad para representar los conceptos, por ello en la sección 2.3 se describen algunos de los modelos probabilísticos señalados en la figura 2.1.

2.2. Modelos basados en factorización matricial

El modelo básico de factorización matricial consiste en encontrar para cada usuario un vector $p_u \in \Re^f$ que mide el interés que el usuario tiene en los ítems, y un vector $q_i \in \Re^f$ para cada ítem, que mide el grado en el que el ítem posee esos factores (Koren y cols., 2009). En este caso, f, representa la dimensión del espacio de factores latentes. Las interacciones usuario-ítem se modelan como un producto escalar entre sus correspondientes vectores, tales como:

$$\hat{r}_{u,i} = q_i^T p_u \tag{2.1}$$

El producto resultante denota el voto estimado de un usuario hacia un ítem. Para aprender los vectores p y q el sistema minimiza el error cuadrático regularizado sobre el conjunto de votos conocidos (Koren y cols., 2009).

$$\min_{q \cdot p^*} \sum_{(u,i) \in \kappa} \left(r_{ui} - q_i^T p_u \right)^2 + \lambda \left(\|q_i\|^2 + \|p_u\|^2 \right)$$
 (2.2)

Donde: K es el conjunto de los pares (u, i) para lo cual r_{ui} es conocido, $\lambda (||q_i||^2 + ||p_u||^2)$, es el término de regularización para evitar el sobreajuste.

Como se muestra en la figura 2.1, existen algunas implementaciones basadas en factorización matricial, en este trabajo se describen las más comúnmente usadas.

2.2.1. Factorización matricial con bias

El método de factorización matricial con bias (BiasedMF), surge debido a que gran parte de la variación observada en los votos se debe a los efectos asociados con los usuarios o ítems, conocidos como sesgos (bias). Es decir que, estos sesgos probablemente sean causados por desviaciones del voto, por ejemplo algunos usuarios proporcionan votos más altos que otros usuarios, y algunos ítems pueden obtener votos más altos que otros ítems (L. Chen, Chen, y Wang, 2015).

Formalmente, la estimación del voto se calcula utilizando el sesgo involucrado

en el voto:

$$b_{ui} = \mu + b_u + b_i \tag{2.3}$$

Donde: μ es el promedio global de los votos, los parámetros b_u y b_i indican la desviación observada del usuario e ítem, respectivamente, desde el promedio (Koren y Bell, 2011). Las bias se pueden estimar con el método de gradiente descendente.

La ecuación de este método está dada por (Adomavicius y Tuzhilin, 2011):

$$\tilde{r}_{u,i} = b_{ui} + q_i^T p_u \tag{2.4}$$

Igualmente, el sistema aprende minimizando la función del error cuadrático, como sigue:

$$\min_{p^*, q^*, b} \sum_{(u,i) \in K} (r_{ui} - \tilde{r}_{ui})^2 + \lambda \left(\|p_u\|^2 + \|q_i\|^2 + b_u^2 + b_i^2 \right)$$
(2.5)

Existen algunos trabajos desarrollados con el uso de este método, por ejemplo en (Sun, Zhang, Liang, y He, 2015), desarrollan un algoritmo de factorización matricial con bias para modelar características explícitas basados en los valores del voto, al añadir factores de alta dimensión; por otro lado en (H. Zhang y cols., 2017) utilizan el método BiasedMF para fusionar los votos con los perfiles del usuario en un solo modelo.

2.2.2. Factorización matricial no negativa

Otro método que se deriva de la factorización matricial y que ha ganado popularidad en los últimos años, es el método de factorización matricial no negativa (NMF) (L. Zhang y cols., 2011), la cual consiste en la factorización de la matriz de votos R con entradas positivas, en dos nuevas matrices: W que representa la matriz de factores latentes de los usuarios y H que representa la matriz de factores latentes de los ítems. Este modelo impone como restricción la no negatividad

de los factores de estas dos matrices, tales que verifiquen la siguiente expresión:

$$R \approx W \cdot H \tag{2.6}$$

Por lo tanto, el algoritmo NMF trata de minimizar la diferencia cuadrática entre R y $W \cdot H$, obteniendo la siguiente función de coste:

$$\sum_{ui} (R_{u,i} - (W \cdot H)_{u,i})^2 \tag{2.7}$$

Las matrices W y H minimizan el error sujeto a las restricciones no negativas. Este problema se puede plantear mediante el descenso de gradiente tal y como se realiza en PMF, sin embargo, la restricción de valores positivos permite transformar la función de coste para acelerar el proceso de aprendizaje.

Dada la función de coste anterior, las reglas de actualización de las matrices W y H están dadas por:

$$W \leftarrow W \leftarrow \frac{R \cdot H^T}{W \cdot H \cdot H^T} \tag{2.8}$$

$$H \leftarrow H \cdot \frac{W^T \cdot R}{W \cdot W^T \cdot H}$$

Donde W y H, están restringidas a ser no negativas.

NMF a diferencia de BiasedMF y PMF facilita la interpretabilidad de los resultados, debido a sus factores positivos.

Algunos trabajos aplicados a CF basados en NMF son: (Hernando y cols., 2016), el cual combina métodos bayesianos con NMF para predecir los gustos del usuario en sistemas de recomendación; (S. Zhang, Wang, Ford, y Makedon, 2013) proponen una variación de NMF basado en el método de Expectativa-Maximización (EM) para encontrar un modelo cuando la matriz de votos es incompleta; (Aghdam y cols., 2015) utilizan NMF y similaridad para aprender

los factores latentes de los usuarios e ítems y estimar los votos desconocidos utilizando estas características latentes; en (Parvin, Moradi, Esmaeili, y Qader, 2019) se propone un recomendador de factorización matricial no negativa basado en la confianza usando un método de dirección alterna, etc.

2.2.3. Limitaciones de los modelos de factorización matricial

De la revisión del estado del arte, se determinó que los métodos de factorización matricial poseen algunas debilidades como:

- El espacio latente aprendido no es fácil de interpretar (C. Wang y Blei, 2011). Las matrices que representan las características latentes de los usuarios e ítems son abstractas para entender su significado, por tanto no son intuitivas para interpretar.
- Cuando la dispersión es demasiado grande, la precisión de la recomendación se reduce (R. Chen y cols., 2018). El problema de dispersión tiene un fuerte efecto sobre el poder predictivo de los algoritmos, puede conllevar a un sobre ajuste (over-fitting) de los datos y dar como resultado una mala precisión.
- Problemas para explicar las recomendaciones. Debido a que la descomposición en factores latentes es difícil de interpretar, y éste a su vez pueden generar valores negativos, la predicciones resultan difíciles de explicar (Rastegarpanah y cols., 2017).

2.3. Modelos probabilísticos

Los sistemas de recomendación de filtrado colaborativo basado en factorización matricial proporcionan unos resultados excelentes en cuanto a calidad de predicciones y recomendaciones, pero éstos son difíciles de interpretar. Este tipo de algoritmos tienen una deficiencia: la transformación de la matriz de votaciones en matrices de factores latentes es altamente abstracta para los usuarios y, por ende, imposibilita la explicación de las recomendaciones. Por otra parte, existen modelos probabilísticos que facilitan la tarea de interpretar y justificar sus resultados.

Dentro del estudio del estado del arte se identifican dos familias de modelos probabilísticos aquellos bayesianos y no bayesianos. De acuerdo a (Barnard y Prügel-Bennett, 2011) los sistemas recomendadores bayesianos que utilizan conocimiento previo pueden producir resultados mejores que los utilizados en el filtrado colaborativo basado en la memoria, y aquellos recomendadores probabilísticos simples que no utilizan conocimiento previo.

Los modelos bayesianos se basan en la definición de probabilidad condicional y el teorema de bayes. Éstos utilizan la probabilidad para representar la incertidumbre sobre las relaciones aprendidas de los datos. Además, el concepto de prior (anterior) es muy importante, para representar nuestras expectativas o conocimientos previos sobre cuál podría ser la verdadera relación.

Desde la perspectiva bayesiana, la probabilidad de obtener los parámetros dado los datos (posteriori), es proporcional al producto de la probabilidad de los datos dado los parámetros (likelihood), por la probabilidad de los parámetros (prior). El componente de likelihood incluye el efecto de los datos, mientras que el prior especifica la creencia en el modelo antes de que se observaran los datos (Ricci y cols., 2015).

Basado en esto, a continuación se mencionan algunos modelos bayesianos que no usan factorización matricial, y que son utilizados en filtrado colaborativo.

2.3.1. Método Naïve Bayes mejorado

Este método de filtrado colaborativo se basa en Naïve Bayes y tiene una complejidad similar al método original. A diferencia del método bayesiano ingenuo (naive) original, este algoritmo se puede aplicar a los casos en que la suposición de independencia condicional no se cumple estrictamente (K. Wang y Tan, 2011). El método INBM (por sus siglas en inglés) proporciona una nueva solución simple a la falta de independencia en comparación con las redes bayesianas.

En el algoritmo propuesto para este método, los ítems de una alta probabilidad condicional tiene una alta prioridad a ser recomendados y la tarea aquí es calcular la probabilidad condicional de cada ítem para cada usuario.

En este método, la relevancia entre los ítems es el fundamento teórico. El funcionamiento es el siguiente: primero se calcula la probabilidad prior $p(m_i)$, que es la posibilidad de que el ítem m_i sea interesante para todos los usuarios.

$$p(m_i) = \frac{\sum_{i \in U} t_i}{N} \tag{2.9}$$

Donde:

U: Conjunto de usuarios interesados en el ítem

N: Número total de usuarios

Para calcular la matriz de probabilidad condicional, primero se obtiene la probabilidad conjunta y luego ésta se convierte en probabilidad condicional.

$$p(m_i, m_j) = \frac{t_{i,j}}{N} (2.10)$$

$$p(m_i|m_j) = \frac{p(m_i, m_j)}{p(m_j)}$$
 (2.11)

Sobre la base de estas dos matrices se hace la recomendación. Para lo cual se aplica la siguiente ecuación.

$$p(m_x|m_{u1}, m_{u2}...) = p(m_x) \cdot q^{\frac{cn}{n}}$$
(2.12)

Donde n es el número de intereses conocidos del usuario y cn es una constante entre 1 y n. cn representa cuán independiente son los ítems. El valor de cn es calculado por experimentos.

 $p(m_x)$, muestra si el elemento \boldsymbol{x} en sí es atractivo para el usuario, y \boldsymbol{q} representa la probabilidad condicional obtenida en la ecuación 2.11, que muestra si el

ítem es adecuado para el usuario.

Una limitante de este método es el cálculo de **cn** en base a experimentos, el valor de este parámetro debería ser obtenido de forma automática y adecuada.

2.3.2. Modelo Gaussian-Gamma

En (Barnard y Prügel-Bennett, 2011) se presenta un modelo Gaussiano para el comportamiento del voto con la adición de un prior Gaussian-Gamma. El modelo llamado GGM (por sus siglas en inglés) presenta un buen desempeño cuando se usa conjuntos de datos muy dispersos. Es decir, este modelo utiliza el conocimiento previo dentro de las estimaciones de probabilidad, para reducir el impacto de la dispersión (sparsity).

De acuerdo con (Luo, Zhang, Xiang, y Qi, 2017), la distribución Gaussian-Gamma se ha utilizado con éxito en aplicaciones que requieren un modelo robusto o disperso, y se puede usar para mejorar la precisión de la Gaussiana. La distribución gaussiana y gamma pertenece a la familia exponencial. Sin embargo, en este modelo, las probabilidades son discretas, en lugar de continuas.

Los autores consideran que los priors y los likelihoods son independientes del ítem de interés, y actualizan incrementalmente la probabilidad posterior dada cada característica.

$$p(r_{u,i} = k | r_{u'i} = k') = \frac{P(r_u = k)P(r_{u'} = k' | r_u = k)}{\sum_{k''} P(r_u = k'')P(r_{u'} = k' | r_u = k'')}$$
(2.13)

Las probabilidades posteriores se combinan para encontrar el valor esperado del voto.

$$E(r_{u,i}) = \sum_{k \in K} P(r_{u,i} = k)k$$
 (2.14)

Para calcular las probabilidades anteriores (prior) se considera la cantidad de veces que el usuario u ha dado un voto k a un ítem. Para el cálculo del likelihood

se consideran las diferencias en los votos del usuario. Éstas diferencias $r_u - r_{u'}$ son modeladas desde una distribución gaussiana. El modelo no es estrictamente gaussiano se hacen algunas simplificaciones removiendo constantes, por tanto los likelihoods llegan a ser discretos, en lugar de continuos. La ecuación es la siguiente:

$$P(r_{u'} = k' | r_u = k) = \frac{exp(-\tau_{u,u'}/2(k - k' - \mu_{u,u'})^2)}{\sum_{k''} exp(-\tau_{u,u'}/2(k'' - k' - \mu_{u,u'})^2))}$$
(2.15)

$$\tau_{u,u'} = \frac{1}{\sigma^2} \tag{2.16}$$

Donde:

 $\mu_{u,u'}$ Es la diferencia media entre los dos votos de usuarios.

 $\tau_{u,u'}$ Es la precisión de la distribución gaussiana, o σ^{-2} la recíproca de la varianza.

El modelo puede ser incrementado considerando un prior Gaussian-Gamma, donde la media y la varianza son tratados como desconocidos, la media sería modelada por una gaussiana y la varianza por una distribución gamma.

Según (Barnard y Prügel-Bennett, 2011), en estos modelos las creencias son la probabilidad de que un usuario asigne un voto de una clase dada a un ítem, y las características son los votos realizados por otros usuarios. Para ello, se consideran los prior y los likelihoods.

2.3.3. Modelo de regresión Naïve Bayes para filtrado colaborativo

En (S. Wen, Wang, Li, y Wen, 2018) proponen un algoritmo de recomendación de filtrado colaborativo basado en Naive Bayes. El modelo original de clasificación Naive Bayes se modifica dentro de un modelo de regresión bayesiano y se aplica a la recomendación de filtrado colaborativo con el objeto de mejorar la precisión. El algoritmo NBRMCF (por sus siglas en inglés) transforma el problema de la predicción de votos en un problema de clasificación. Los votos se consideran categorías de la clasificación, de esta forma para realizar la recomendación utilizando

el modelo Naïve Bayes, el proceso de predecir el voto de usuarios se convertirá en el proceso de dividir usuarios e ítems en diferentes categorías de calificación.

Los valores de los atributos y los valores de las categorías se discretizan para simplificar la complejidad del modelo de regresión de Naïve Bayes. Además se cambian los resultados de clasificación a un resultado de regresión, es decir que este modelo lleva a cabo la regresión lineal de los valores de clasificación discretizados, multiplicando la probabilidad de cada clase de clasificación por el valor del voto para obtener el valor matemático esperado, el cual se utiliza como resultado final.

Basado en esto, los pasos para aplicar el algoritmo son los siguientes:

- Determinación del usuario e ítem como atributo característico: se selecciona un conjunto de usuarios U y un conjunto de ítems I como atributos característicos, el conjunto de clasificación R_i , con s categorías de clasificación. Los votos suelen ser números enteros y se redondean si el voto es un decimal.
- Obtención de los ejemplos de entrenamiento: los datos de entrada se pueden expresar en forma de una matriz de votos usuario-ítems. La matriz consta de m usuarios e n ítems. Se define $r_{a,b} \in R$ como el valor del voto del ítem i dado por el usuario a.
- Cálculo de la probabilidad de cada categoría de clasificación. Cuenta el número de cada tipo de calificación $NUM_{-}R_{i}$ y el número de calificaciones NUM. Entonces la probabilidad de cada clasificación se calcula como:

$$P(R_i) = \frac{NUM_-R_i}{NUM} \tag{2.17}$$

■ Cálculo de las probabilidades prior: dado que, $P(R_i)$ y $P(U_a|R_i)$ y $P(I_b|R_i)$ como condición, en este método la probabilidad prior se obtiene como:

$$P(X|R_i) = P(U_a, I_b|R_i) = P(U_a|R_i) * P(I_b|R_i)$$
(2.18)

■ Obtención del valor esperado: en el método original de naive bayes, usualmente el valor más grande de probabilidad previa de la categoría de clasificación es considerada como la categoría de clasificación final. Pero este método cambia el resultado de la clasificación a un resultado de regresión. Este método ya no usa la categoría de la probabilidad prior máxima como clasificación final. Este método calcula la probabilidad de la muestra X, donde X representa el ítem y el usuario que deben clasificarse.

$$P(X) = \sum_{i=1}^{s} P(X|R_i) = \sum_{i=1}^{s} P(R_i)P(U_a|R_i)P(I_b|R_i)$$
 (2.19)

Finalmente, se obtiene el valor matemático esperado E(X) de la muestra X como el voto final.

$$E(X) = \sum_{i=1}^{s} \frac{P(X|R_i)}{P(X)} * R_i$$
 (2.20)

En este trabajo podemos ver que las técnicas bayesianas no sólo pueden ser utilizadas para resolver problemas de clasificación, sino que estos métodos también pueden extenderse a problemas de regresión. En vista de que la regresión es utilizada para simular la relación existente entre dos o más variables, el método propuesto por estos autores predice el comportamiento de la variable dependiente (en este caso la clase) a partir de un conjunto de variables independientes.

2.4. Modelos probabilísticos con factorización matricial

En el contexto de los RS de filtrado colaborativo los modelos probabilísticos están siendo muy utilizados en combinación con la factorización matricial, y algunos de ellos con información complementaria (por ejemplo, características del usuario y/o ítem, preferencias explícitas del usuario, información contextual, etc.).

La factorización matricial es el método más popular de CF basado en modelos, algunas implementaciones probabilísticas de este método son PMF (Salakhutdinov

y Mnih, 2007), BNMF (Hernando y cols., 2016), GGMCF (Luo y cols., 2017), etc., así mismo se tienen algunas combinaciones de PMF con enfoques basados en usuario e ítems. En este apartado se describen estos modelos, algunos de los cuales se presentan en la figura 2.1.

2.4.1. Factorización matricial probabilística

La factorización matricial probabilística (PMF), es un modelo de análisis factorial, que consiste en un modelo lineal gaussiano de variable latente restringido. Esto es, si tenemos un conjunto de datos de N usuarios y M ítems, y una matriz de votos R de $N \times M$, este modelo consiste en encontrar dos matrices $P \in R^{K \times N}$ que hace referencia a los usuarios y $Q \in R^{K \times M}$, a los ítems. Siendo P_i , Q_j con $i \in \{1, 2, ..., N\}$ y $j \in \{1, 2, ..., M\}$, vectores columna correspondientes a la u-ésima columna de P y i-ésima columna de Q, respectivamente. En este caso K es el tamaño de las características latentes.

En este modelo se define la distribución condicional sobre las calificaciones observadas, $R_{i,j}$ que representa el voto del ítem j dado por el usuario i, calculado en base a las matrices latentes P y Q. La distribución condicional sobre los votos observados estaría dado por (Salakhutdinov y Mnih, 2007):

$$p(R|P,Q,\sigma^2) = \prod_{i=1}^{N} \prod_{j=1}^{M} \left[\eta(R_{i,j}|P_i^T Q_j,\sigma^2) \right]^{I_{ij}}$$
 (2.21)

Donde $\eta(x|\mu, \sigma^2)$ es la función de densidad de probabilidad de la distribución gaussiana con media μ y varianza σ^2 , I_{ij} es la función indicadora que es igual a 1 si el usuario i calificó el ítem j y es igual a θ en caso contrario.

La distribución prior gaussiana sobre el vector de características del usuario P e ítem Q, se obtienen con las siguientes ecuaciones (Jung y Lease, 2012):

$$P(\sigma_P^2) = \prod_{i=1}^{N} \eta(P_i | \mu_P, \sigma_P^2 I)$$
 (2.22)

$$Q(\sigma_Q^2) = \prod_{j=1}^{M} \eta(Q_j | \mu_Q, \sigma_Q^2 I)$$
 (2.23)

En este caso \boldsymbol{I} denota una matriz identidad de dimensión \boldsymbol{K} , donde $\mu_P = 0$, $\mu_Q = 0$ y $\sigma_P^2 = \sigma_P I_K$, $\sigma_Q^2 = \sigma_Q I_K$ que serían matrices diagonales.

En base a estos datos se obtiene la distribución posterior del modelo, tal y como se muestra en (Salakhutdinov y Mnih, 2007), donde la estimación de los parámetros del modelo anterior se puede encontrar utilizando el método del logaritmo de estimación de máxima verosimilitud, en base al logaritmo de la distribución posterior.

La predicción del voto se lleva a cabo multiplicando el vector de usuario correspondiente y vector de ítems P_u y Q_i respectivamente (2.21).

Lo ideal de este modelo probabilístico, es que la predicción se expresa en términos de la distribución predictiva sobre \boldsymbol{R} que es gaussiana en lugar de simplemente una estimación puntual. El resultado será una matriz completa de votos estimados. En este sentido, los nuevos votos de los ítems que aún no han sido votados son estimados.

Este método presenta una muy buena escalabilidad, puesto que, una vez aprendido el modelo, el cálculo de las predicciones se realiza en un tiempo mínimo, además proporciona unos resultados excelentes en cuanto a calidad de predicciones y recomendaciones. Sin embargo, el algoritmo PMF tiene una deficiencia: la transformación de la matriz de votaciones en matrices de factores latentes es altamente abstracta para los usuarios y, por ende, dificulta la interpretación de resultados.

2.4.2. Modelo bayesiano de factorización matricial no negativa

Esta técnica se basa en un modelo probabilístico bayesiano de factorización no negativa para filtrado colaborativo (BNMF, por sus siglas en ingles) presentado

por (Hernando y cols., 2016), donde la predicción de los gustos de los usuarios en el sistemas de recomendación se basa en la factorización de la matriz de votos en dos matrices no negativas, una relacionada con los ítems y otra relacionada con los usuarios.

Este modelo considera la existencia de K factores latentes que explican los votos que hacen los usuarios. De esta manera, un vector a_u de dimensión K, es asociado para cada usuario u y un vector b_i de dimensión K es asociado para cada ítem i. En este modelo $a_{u,k}$ y $b_{k,i}$ están dentro del rango [0, 1]. Los factores latentes representan grupos de usuarios que comparten los mismos gustos en el sistema. De esta manera, el parámetro K indica el número de tales grupos en el conjunto datos. El valor $a_{u,k}$ representa la probabilidad que el usuario u pertenezca al grupo u de usuarios u pertenece al grupo u les guste el ítem u, u u0 guste u1 u1 pertenece al grupo u2. Basado en esto, los valores de estas probabilidades se calculan con las siguientes ecuaciones.

$$a_{u,k} = \frac{\gamma_{u,k}}{\sum_{j=1..k} \gamma_{u,i}} \tag{2.24}$$

$$b_{k,i} = \frac{\epsilon_{i,k}^+}{\epsilon_{i,k}^+ + \epsilon_{i,k}^-} \tag{2.25}$$

Los parámetros $\gamma_{u,k}$, $\epsilon_{i,k}^+, \epsilon_{i,k}^-$, $\lambda_{u,i,k}$, cumplen las siguientes condiciones:

$$\gamma_{u,k} = \alpha + \sum_{i|r_{u,i} \neq \bullet} \lambda_{u,i,k} \tag{2.26}$$

$$\epsilon_{i,k}^{+} = \beta + \sum_{u|r_{u,i\neq \bullet}} \lambda_{u,i,k} \cdot r_{u,i}^{+} \tag{2.27}$$

$$\epsilon_{i,k}^{-} = \beta + \sum_{u|r_{u,i\neq \bullet}} \lambda_{u,i,k} \cdot r_{u,i}^{-} \tag{2.28}$$

Donde:

 $\lambda_{u,i,k}$ son hiperparámetros a ser aprendidos.

Por tanto, la predicción de los gustos de los usuarios en el sistemas de recomendación se basa en la factorización de la matriz de calificación de dos matrices no negativas, una relacionada con los ítems y otra relacionada con los usuarios.

La predicción del voto es calculada multiplicando el vector de usuario $a_{u,k}$ y el vector del ítem $b_{k,i}$.

$$p_{u,i} = \sum_{k=1...K} a_{u,k} b_{k,i} \tag{2.29}$$

BNMF usa tres parámetros para el aprendizaje del modelo:

K: Indica el número de grupos del usuario

 α : Se relaciona con la posibilidad de obtener grupos

 β : Se relaciona con la cantidad de evidencia

Los valores de estos parámetros libres cambiarán iterando desde las ecuaciones usadas para el cálculo de las distribuciones condicionales presentadas en (Hernando y cols., 2016), hasta que convergen, esto es, repetir hasta que los cambios no sean significativos.

Este modelo permite entender y justificar las predicciones del modelo, debido a que los componentes de los vectores son no negativos, es decir cada componente tiene un significado probabilístico entendible. Por ejemplo se puede decir que: Si una predicción $p_{u,i}$ es alta, hay otros usuarios con los mismos gustos que \boldsymbol{u} que han calificado positivamente el ítem \boldsymbol{i} .

A diferencia de PMF, BNMF asume que las votaciones de los usuarios siguen una distribución categórica, lo que en la mayoría de los casos representa mejor la realidad, ya que los sistemas de CF suelen forzar a que sus usuarios emitan sus preferencias en base a una escala predefinida.

Por otro lado, en (Bobadilla, Bojorque, y cols., 2018) BNMF es usado para

mejorar los resultados actuales de clustering en el área de filtrado colaborativo, este nuevo método es llamado BNMF+. Los autores proveen un algoritmo preclustering original, adaptado para al método probabilístico BNMF. Los resultados aplicando esta nueva extensión de BNMF demostraron una mejora de la calidad del clúster concluyente cuando se utiliza BNMF en comparación con el método de factorización matricial clásica o a los resultados de KMeans mejorados y una mayor precisión en las predicciones utilizando métodos basados en factorización matricial que utilizando KMeans mejorados.

2.4.3. Modelo Gaussian-Gamma de filtrado colaborativo: Bayesiano jerárquico

En (Luo y cols., 2017) proponen un modelo bayesiano jerárquico basado en CF (GGCF, por sus siglas en inglés). Se impone un Gaussian-Gamma prior sobre los votos y las características latentes. En este modelo en lugar de una distribución gaussiana para el voto, se sustituye con una distribución gaussiana-gamma, es decir, se agrega una distribución gamma para la precisión (la inversa de la varianza) formando una jerarquía superior para el modelo. Las características latentes de los usuarios (U) e ítems (V), son también tratadas con una distribución gaussiana-gamma. El algoritmo de inferencia para este modelo usa el muestreo de Gibbs para aproximar la probabilidad posterior de las variables aleatorias.

De acuerdo a estos autores, la sustitución de la distribución gaussiana por una Gaussian-Gamma, significa que se utiliza una distribución Gaussiana para las observaciones, y se emplea una distribución Gamma para mejorar la precisión de los gaussianos. Esta sustitución hace que todas las variables aleatorias involucradas tengan una densidad condicional analítica porque las distribuciones Gaussian y Gamma pertenecen a la familia exponencial.

Considerando la matriz de votos R, con N usuarios y M ítems, y los vectores de características latentes de los usuarios U, e ítems V, el modelo se formaliza de la siguiente manera:

$$R_{i,j} \sim \eta(U_i' V_j, \lambda_{i,j}^{(-1)})$$
 (2.30)

$$\lambda_{i,j} \sim G(a,b) \tag{2.31}$$

Donde η y G denotan la distribución normal y la distribución Gamma, respectivamente, mientras que $U_i'V_j$, es el producto interno de los vectores U_i y V_j . $\lambda_{i,j}$ es la recíproca de la varianza, conocida como la precisión. Los parámetros a_{λ} y b_{λ} representan la forma y el radio de una distribución Gamma, respectivamente.

Basados en los votos del usuario-ítems, se asume que las características latentes \boldsymbol{U} y \boldsymbol{V} se distribuyen como distribuciones Gaussian-Gamma. Las distribuciones condicionales se obtienen como:

$$U_i \sim \eta(0, \lambda_{U_i}^{-1} I) \tag{2.32}$$

$$\lambda_{U_i} \sim G(a_U, b_U) \tag{2.33}$$

$$V_j = \sim \eta(0, \lambda_{V_j}^{-1} I) \tag{2.34}$$

$$\lambda_{V_j} \sim G(a_V, b_V) \tag{2.35}$$

Donde I es una matriz identidad de dimensión $K \times K$

Para la inferencia, el muestreo de Gibbs es aplicado en GGCF, éste requiere la forma analítica de las distribuciones condicionales para todos los parámetros involucrados.

2.4.4. Otros modelos probabilísticos basados en factorización matricial

Existen una variedad de modelos derivados de PMF, algunos se han centrado en construir enfoques híbridos combinando diferentes tipos de modelos dentro del modelo de factorización matricial. Adicionalmente a los modelos explicados anteriormente mencionamos el modelo probabilístico de factorización matricial de sesgo profundo (DBPMF, por sus siglas en inglés), propuesto por (K. Li, Zhou,

Lin, Zeng, y Alterovitz, 2019), el cual utiliza una red neuronal convolucional para extraer características latentes de usuario e ítems, agregando el sesgo en la factorización matricial probabilística para rastrear el comportamiento del voto del usuario y la popularidad del ítem.

Del mismo modo, para abordar el problema de arranque en frío, en (Nguyen y Takasu, 2017) presentan un modelo probabilístico embebido de ítems, que aprende representaciones de ítems a partir de los datos de clicks, y un modelo denominado EMB-MF que combina la incrustación probabilística de ítems con PMF para unir las representaciones de ítems de los dos modelos. De esta manera la predicción del voto es calculada en función de los datos de clicks.

Por otro lado, en (Ma, Wu, Gong, Qin, y Wang, 2017), se propone un algoritmo de factorización matricial probabilística local (LPMF, por sus siglas en inglés) que divide la matriz completa de votos en un cierto número de matrices locales y combina estas soluciones óptimas locales de manera ponderada. El método aprende modelos locales basados a su vez en matrices locales específicas.

En (Iwata y Takeuchi, 2015) se propone un método de recomendación para predecir los votos de ítems en diferentes dominios, en este caso ni los usuarios ni los ítems se comparten a través de estos dominios. El método propuesto se basa en la factorización matricial probabilística, la cual aprende un vector latente para cada usuario y cada ítem. Este método supone que los vectores latentes en diferentes dominios se generan a partir de una distribución de Gauss común con un vector de media desconocida y matriz de covarianza. En este caso cuando dos dominios están relacionados, sus factores latentes serían similares.

Otros modelos probabilísticos para filtrado colaborativo que se han desarrollados en los últimos años son, por ejemplo, un método de inferencia variacional distribuida con memoria libre para problemas de factorización matricial a gran escala presentado en (G. Chen, Zhu, y Heng, 2018), el cuál está basado en la propiedad de independencia condicional de las entradas observadas en el modelo de factorización matricial probabilística bayesiana y en el principio derivado de la inferencia variacional distribuida bayesiana. Este método no requiere ajustar el radio de aprendizaje cuidadosamente, mezclando el conjunto de entrenamiento en cada iteración o almacenando masivas variables redundantes, éste puede introducir nuevos agentes dentro de los cálculos sobre la marcha. Los resultados mostraron que este método puede converger significativamente más rápido con un buen desempeño en el tiempo de ejecución que otros algoritmos alternativos.

En (Zafari y Moser, 2017) incorporan el enfoque bayesiano en un modelo de factorización matricial y proponen dos nuevos modelos de factores latentes, que incluyen tanto las discrepancias de valor de característica influenciadas socialmente como las discrepancias de valor de característica condicional influenciada socialmente. En este modelo las preferencias del usuario se modelan como una red bayesiana. El modelado de las discrepancias con influencia social en las preferencias del valor de característica y las dependencias condicionales resultó en mejoras de precisión, en comparación con otros modelos que no consideran tales dependencias y discrepancias, sin embargo estas extensiones aumentaron ligeramente el tiempo de cálculo de los métodos que los autores proponen.

Dos procesos generativos de votos se formulan mediante modelos gráficos probabilísticos en (Weng, Wu, y Hong, 2018), con los correspondientes factores latentes, el modelo de factor latente parcial (PLFM, por sus siglas en inglés) y el modelo de factor latente sesgado (BLFM, por sus siglas en inglés). En este trabajo se proponen frameworks bayesianos completos de dichos modelos gráficos, así como los enfoques de inferencia variacional para la estimación de los parámetros.

En (G. Chen y cols., 2018), se presenta un método de inferencia variacional distribuida de memoria libre para el problema de factorización matricial a gran escala, que se basa en un principio recientemente derivado de la inferencia bayesiana variacional distribuida.

Un modelo de factorización matricial probabilística bayesiana es presentado por (K. Wang, Zhao, Peng, y Wang, 2016), ellos tratan el conjunto de ítems votados por un usuario como un documento, y emplean modelos de tópicos latentes para agrupar los ítems como tópicos, así un usuario tiene una distribución sobre el conjunto de tópicos. En este modelo se establecen vectores latentes específicos de tópicos para usuarios e ítems. Usando una representación latente multi-tópico, el modelo es más fuerte para reflejar las características complejas para los usuarios y los ítems en la predicción del voto, y mejorar la interpretabilidad del modelo.

Por otro lado, en (Lenskiy y Makita, 2017) proponen un enfoque bayesiano para predecir los géneros de películas, en base a los votos dados por los usuarios. Los autores aplican un modelo multivariado de Bernoulli para estimar la probabilidad de una película a ser asignada a cierto género, y así predecir los géneros de películas usando reglas bayesianas. También obtienen las correlaciones del género para verificar si un género estimado incorrectamente está correlacionado con el correctamente estimado.

En (Huang, Tan, y Sun, 2019) se propone un algoritmo de recomendación colaborativo basado en el modelo semántico latente probabilístico mejorado, que introduce el factor de popularidad en el análisis semántico latente probabilístico para derivar el modelo de factorización matricial probabilística, y resolver el problema de la dispersión de datos.

2.5. Modelos basados en reglas

En este apartado se incluyen aquellos modelos basados en árboles y basados en reglas de asociación.

De acuerdo a (Ricci y cols., 2015), los clasificadores basados en reglas clasifican los datos utilizando una colección de reglas "si... entonces". El antecedente o condición de la regla es una expresión hecha en base a conjunciones de atributos. La regla consecuente es una clasificación positiva o negativa.

Para construir un clasificador basado en reglas, se puede utilizar un método indirecto que consiste en extraer reglas de otros modelos de clasificación, como los árboles de decisión.

Si bien los árboles de decisión han sido utilizados ampliamente en tareas de clasificación, éstos aún necesitan ser explotados dentro de los sistemas de recomendación.

Los métodos basados en reglas no son muy utilizados en el contexto de RS porque son complicados de construir, debido a que se necesita derivar las reglas de otro modelo, o tener un conocimiento previo explícito del proceso de toma de

decisiones (Ricci y cols., 2011). Además, aún son vulnerables frente algunas de las limitaciones que enfrentan los sistemas de recomendación. Sin embargo estos métodos pueden ser utilizados en combinación con otras técnicas para mejorar el rendimiento de un RS, por ejemplo es posible el uso de un conjunto de reglas y algoritmos de filtrado colaborativo para la recomendación de ítems (Anderson y cols., 2003).

2.5.1. Basados en árboles

Un modelo de inferencia natural basado en reglas de incertidumbre es presentado en (Hernando y cols., 2017), para ofrecer a los usuarios no registrados la posibilidad de inferir sus propias recomendaciones. Este modelo se formaliza matemáticamente mediante un modelo probabilístico que simula el razonamiento directo basado en reglas. Este modelo se puede utilizar para construir un sistema de recomendación compuesto por dos modelos: el modelo propuesto para los usuarios nuevos no registrados de cold-start, o los usuarios de cold-start parcial; y un modelo tradicional basado en factorización matricial para usuarios registrados.

En (Golbandi, Koren, y Lempel, 2011), se presenta un método para obtener información de nuevos usuarios. El algoritmo empleado en este método está basado en la optimización de una función de coste definida formalmente. La parte principal de este método es un algoritmo de recomendación basado en un árbol de decisión, adecuado para un proceso de arranque adaptativo. El método implica un proceso de entrevista, donde se les pregunta a los usuarios sus opiniones sobre ciertos ítems elegidos deliberadamente. Para lograr una mayor precisión y experiencia de usuario, el proceso de entrevista se adapta a las respuestas de los usuarios, de modo que la respuesta a una pregunta influye en la elección de la siguiente pregunta, es decir, el proceso cambia dinámicamente las preguntas de la entrevista, a medida que el usuario ingresa las calificaciones de los ítems.

Una solución llamada modelo embebido mejorado en árbol, que combina las fortalezas de los modelos embebidos y basados en árbol es presentado en (X. Wang, He, Feng, Nie, y Chua, 2018). Primero se emplea un modelo basado en árboles para aprender reglas de decisión explícita. Luego se diseña un modelo embebido que puede incorporar características cruzadas explícitas y generalizar

las características cruzadas no vistas sobre el ID del usuario y el ID del ítem. En el núcleo de este método embebido hay una red de atención fácil de interpretar, que hace que el proceso de recomendación sea totalmente transparente y explicable.

Autores como (Tao, Jia, Wang, y Wang, 2019) integran árboles de regresión para guiar el aprendizaje de modelos de factores latentes para la recomendación, y utilizan una estructura de árbol aprendida para explicar los factores latentes resultantes. Específicamente, construyen árboles de regresión sobre usuarios e ítems, respectivamente, con revisiones generadas por los usuarios y asociando un perfil latente a cada nodo en los árboles para representar usuarios e ítems.

Los árboles han sido utilizados como herramienta de visualización para justificar las recomendaciones (Hernando, Bobadilla, Ortega, y Gutiérrez, 2013). Con esta herramienta las recomendaciones hechas a través de CF son explicadas empleando árboles de ítems, proporcionando a los usuarios una forma rápida y atractiva de entender las recomendaciones.

2.5.2. Basado en reglas de asociación

En (T. Wang y cols., 2017), se presentan dos modelos probabilísticos con parámetros prior que el usuario puede configurar para alentar al modelo a tener el tamaño y la forma deseada, para cumplir con una definición de interpretabilidad específica del dominio. Los autores proporcionan un método de inferencia aproximado que utiliza minería de reglas de asociación y un algoritmo de búsqueda aleatorio para encontrar un modelo máximo a posteriori de un conjunto óptimo de reglas bayesianas. Los resultados mostraron que las reglas simples basadas en el contexto de un usuario pueden ser directamente útiles para predecir la respuesta del usuario.

Para mejorar la precisión de las recomendaciones de CF en (Najafabadi y cols., 2017), aplican los registros de interacción implícita de los usuarios con los ítems para procesar datos masivos de manera eficiente mediante el empleo de reglas de asociación. Los registros de la actividad del usuario (usuario, canciones agrupadas, números de reproducciones) son la entrada para la minería de reglas de asociación. Se emplea la técnica de clúster para perfilar de manera eficiente

las preferencias de los ítems por parte del usuario a partir de los registros de reproducción de canciones y como una forma de reducción de la dimensionalidad de los datos incorporando la parte de minería de reglas. Posteriormente, las similitudes entre los ítems basados en sus características son calculadas para hacer las recomendaciones.

En (Cho, Kim, y Kim, 2002), se combina árboles de decisión y minería de reglas de asociación en un RS de una tienda web. En este sistema, las reglas de asociación se derivan para vincular ítems relacionados. La recomendación se calcula mediante la intersección de las reglas de asociación con las preferencias del usuario. Se buscan reglas de asociación en diferentes conjuntos de transacciones como compras, colocación de cestas, y a través de clicks. También utilizan una heurística para ponderar las reglas provenientes de cada uno de los conjuntos de transacciones.

Un trabajo reciente que combina técnicas de filtrado colaborativo y basado en contenido con técnicas de minería de datos como reglas de asociación es el presentado por (Gandhi y Gandhi, 2019), el cual consiste en un sistema de recomendación para el dominio de turismo. El sistema proporciona información sobre lugares turísticos en función de la similitud de los usuarios.

Así mismo en (Gupta, Kochhar, Jain, y Nagrath, 2019) se propone un método para la construcción de sistemas de recomendación utilizando el algoritmo Apriori y empleando reglas de asociación. Las reglas de asociación se utilizan para determinar el "puntaje" que predice la probabilidad de que dos ítems de un conjunto de datos se compren juntos.

2.6. Ventajas y desventajas de los enfoques basados en modelos

Luego del estudio del estado del arte sobre los enfoques basados en modelos, en esta sección se resumen las ventajas y desventajas que estos enfoques poseen de acuerdo a la clasificación descrita en esta investigación.

a. Basados en factorización matricial

Los modelos basados en factorización matricial presentan las siguientes ventajas:

Ventajas

- Se reduce la complejidad computacional (R. Chen y cols., 2018).
- Pueden ser aplicados a datos masivos.
- Alta escalabilidad (Ekstrand y cols., 2011).
- Direccionan mejor los problemas de dispersión (Su y Khoshgoftaar, 2009)
- Buen desempeño de Predicción

Desventajas

- Problemas para explicar las recomendaciones, el espacio latente aprendido no es fácil de interpretar (Rastegarpanah y cols., 2017).
- Definir los hiperparámetros que se ajustan al modelo es un proceso relativamente complejo (R. Chen y cols., 2018).
- Se requiere una actualización periódica del modelo.
- La factorización de la matriz solo utiliza información de las votaciones de los usuarios y no se puede generalizar a ítems que no han sido votados (K. Wang y Tan, 2011).

b. Probabilísticos (bayesianos sin factorización matricial)

Las principales ventajas y desventajas de los modelos bayesianos que no usan factorización matricial, son entre otras:

Ventajas

- Buen desempeño de predicción.
- Facilitan entender y justificar las predicciones (Hernando y cols., 2016).
- Son capaces de manejar problemas de dispersión (Ricci y cols., 2011).
- Son flexibles, integran el conocimiento del dominio mediante el uso de priors flexibles (Shengbo, 2011).
- Modelan mejor el sobreajuste (Ricci y cols., 2011).

Desventajas

- El proceso de inferencia bayesiano es complicado (R. Chen y cols., 2018).
- Es muy costos aprender y actualizar el modelo cuando hay muchos usuarios en el mismo (especialmente con redes bayesianas jerárquicas) (Shengbo, 2011).
- Actualización periódica del modelo.

c. Basado en reglas

Algunos de los beneficios y limitaciones de los modelos basados en reglas son:

Ventajas

- Son expresivos, ya que son simbólicos y operan con los atributos de los datos sin ningún tipo de transformación.
- Los modelos basados en reglas pueden clasificar nuevas instancias de manera eficiente.
- Son fáciles de interpretar (Ricci y cols., 2015).

Desventajas

- Es muy difícil construir un modelo de recomendación completo basado en reglas (Ricci y cols., 2015).
- Necesitan derivar las reglas de otros modelos, o tener un conocimiento previo explícito del proceso de toma de decisiones.
- Pueden hacer crecer ávidamente el modelo.
- Aunque son fáciles de interpretar pueden perder parte de la interpretabilidad, puesto que se pueden generar demasiadas reglas, lo que complica la interpretación global (T. Wang y cols., 2017).
- Debido al problema de dispersión, solo se puede obtener un número limitado de reglas confiables (Wu, Huang, y Lu, 2017).

En la tabla 2.1 se resumen las características que los enfoques basados en modelos poseen. Cada característica es puntuada en una escala de 1 a 5 estrellas, para indicar el grado en que esa característica es resuelta.

Esta tabla fue elaborada en base a un análisis cualitativo de los enfoques basados en modelos, revisados en el estado del arte. Además mediante experimentos llevados a cabo con los métodos de línea base seleccionados (tabla 4.2), se pudo comprobar algunas de las características señaladas en la tabla siguiente, por ejemplo la escalabilidad, el desempeño y la interpretabilidad. Esto nos permite identificar mejor los beneficios y limitaciones que los enfoques basados en modelos brindan de acuerdo al tipo de método que utilizan.

| Característica | Basado MF | Probabilístico | Basado reglas |
|--------------------------------|------------------------------------------------|------------------------------------------------|------------------------------------------------|
| Escalabilidad | \diamond \diamond \diamond \diamond | \diamond \diamond | \Diamond \Diamond |
| Dispersión | $\Diamond \Diamond \Diamond \Diamond \Diamond$ | $\Diamond \Diamond \Diamond \Diamond \Diamond$ | \Diamond \Diamond |
| Interpretación de resultados | ♦ | $\Diamond \Diamond \Diamond \Diamond \Diamond$ | \diamond \diamond \diamond |
| Explicación de recomendaciones | ♦ | $\Diamond \Diamond \Diamond \Diamond \Diamond$ | $\Diamond \Diamond \Diamond \Diamond \Diamond$ |
| Buen Desempeño de predicción | $\Diamond \Diamond \Diamond \Diamond \Diamond$ | \diamond \diamond \diamond \diamond | \diamond \diamond \diamond \diamond |
| Flexibilidad | $\Diamond \Diamond \Diamond \Diamond$ | $\Diamond \Diamond \Diamond \Diamond \Diamond$ | \diamond \diamond |

Tabla 2.1: Características de los modelos probabilísticos.

Como se puede observar, los modelos probabilísticos presentan grandes ventajas frente a los basados en factorización matricial, como la de ser flexibles en el modelado de diversos problemas y la facilidad que presentan para interpretar los resultados. En esta propuesta se aprovechan estas ventajas de los modelos probabilísticos brindando al usuario una explicación de los resultados que el modelo proporciona.

Por tanto en RS estos modelos jugarían un rol importante para la construcción de sistemas recomendadores que además de ser escalables, las recomendaciones sean fáciles de explicar.

2.7. Sumario

En resumen, este capítulo aborda un estudio sobre los enfoques basados en modelos para filtrado colaborativo, se identifican tres categorías de enfoques basados en modelos, las cuales dependen del método que utilizan, éstas son: basados en factorización matricial, probabilísticos, y basados en reglas. Como parte de los modelos probabilísticos están aquellos que facilitan o no la explicación de recomendaciones.

Se presentan también algunos modelos que combinan tanto métodos probabilísticos con factorización matricial. Por cada categoría de enfoques basados en modelos, se identifican algunos algoritmos que pueden ser utilizados en sistemas de recomendación de filtrado colaborativo, algunos de los cuales son utilizados como modelos de línea base para esta investigación.

La revisión de la literatura permitió entender formalmente las ventajas y des-

ventajas de estos modelos como parte de los enfoques de filtrado colaborativo. Se termina el estudio del arte con una comparación entre estos enfoques considerando las características de cada familia de modelos.

Basado en esto, nos centraremos en el diseño de un modelo probabilístico basado en técnicas bayesianas que combina tanto enfoques basado en el usuario y basado en ítems. Por las ventajas que presentan los modelos probabilísticos para entender los resultados, nuestra propuesta incluye además la explicación de recomendaciones.

Capítulo 3

Método propuesto

El enfoque propuesto genera una representación que es fácilmente interpretable, por esta razón las recomendaciones son fáciles de explicar. En esta sección, presentamos el diseño y formulación matemática del enfoque propuesto. Se presenta el método para calcular las predicciones y como calcular la medida de confiabilidad asociada con cada predicción. Finalmente se muestra un ejemplo de ejecución y el algoritmo del método desarrollado.

3.1. Diseño del método

El enfoque propuesto ha sido diseñado en base al clasificador Naïve Bayes (NBC, por sus siglas en inglés) (Barber, 2012). Elegimos NBC porque permite entender y justificar las predicciones del modelo, de tal manera que facilita explicar las recomendaciones de forma más sencilla. Además, varios estudios han demostrado que los resultados obtenidos con NBC son competitivos con otras técnicas.

3.1.1. Componentes del método propuesto

Cómo se mencionó en la sección 2.1, para diseñar un modelo probabilístico es necesario asumir ciertas suposiciones sobre el tipo de atributos que conforman el conjunto de datos, las clases y la dependencia entre variables. En este punto desarrollamos cada uno de estos componentes a fin de entender la formulación del método.

- Atributos del modelo: En vista de que el enfoque propuesto está orientado a CF, los atributos serían los votos dados por el usuario al ítem, los cuales en este caso son discretos. Éstos pueden estar en una escala de 1-5 estrellas (MovieLens) o 1-10 estrellas (BookCrossing).
- Salida del algoritmo (atributo clase): En este caso la clase será el valor del voto plausible, el cual es discreto, por lo que se utilizará una distribución multinomial. La estimación de la clase, se la realizará usando el método MAP (Maximum A Posteriori).
- Dependencia entre variables: En este caso asumimos que los votos dados por el usuario son independientes entre sí, por ello seleccionamos el método naive bayes, el cual se describe en el siguiente apartado.

3.1.2. Clasificador Naive Bayes

NBC es un algoritmo de aprendizaje supervisado basado en la aplicación del teorema de Bayes. De acuerdo a (Hernández, Ramirez, y Ferri, 2004) este clasificador posee una estructura de red fija donde sólo es necesario aprender los parámetros (probabilidades). NBC se fundamenta en el supuesto de que todos los atributos son condicionalmente independientes dada la variable clase. Por tanto NBC emplea la hipótesis de independencia de ahí el nombre de ïngenuo" (naive).

En el Teorema de Bayes se establece la siguiente relación: dada la variable de

clase C y el vector de característica dependientes x_1 a través de x_n , se tiene que:

$$P(C|x_1,...,x_n) = \frac{P(C)P(x_1,...x_n|C)}{P(x_1,...,x_n)}$$
(3.1)

En el clasificador Naive Bayes, dado un conjunto de variables independientes $X = \{x_1, x_2, \ldots, x_n\}$, la probabilidad posterior se construye para cada clase posible $C = \{c_1, c_2, \ldots, c_m\}$. En el enfoque propuesto, las variables independientes serán los votos de los usuarios para los ítems y las posibles clases serán cada valor de voto plausible. Por tanto, usando el supuesto de independencia condicional naive, se tendría:

$$P(x_i|C, x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n) = P(x_i|C)$$
(3.2)

Esta relación es simplificada para todo i, como:

$$P(C|x_1,...,x_n) = \frac{P(C) \prod_{i=1}^n P(x_i|C)}{P(x_1,...,x_n)}$$
(3.3)

NBC calcula un valor de clasificación P(C|X), que es proporcional a la probabilidad posterior, a partir de la probabilidad anterior (a priori) de cada clase P(C) y el likelihood P(X|C) (ecuación 3.4). P(C) se puede interpretar simplemente como la frecuencia de cada instancia de clase dividida por el número total de instancias, y dado que $P(x_1, \ldots, x_n)$ es constante dado la entrada, se puede usar la siguiente regla de clasificación:

$$P(C|X) \propto P(C) \prod_{i=1}^{n} P(x_i|C)$$
(3.4)

Por lo tanto, la clasificación final es producida por el argumento que maximiza el valor de clasificación:

$$\hat{y} = \operatorname*{argmax}_{y} P(C|X) \tag{3.5}$$

Se han propuesto diferentes implementaciones de NBC. Éstas se diferencian principalmente por los supuestos que hacen con respecto a la distribución de probabilidad $P(x_i|C)$. En CF se puede asumir datos distribuidos multinomialmente: cada voto del usuario se asigna a un conjunto fijo de valores del voto predefinidos. Por ejemplo, en el conjunto de datos MovieLens, cada voto se puede clasificar de 1 a 5 estrellas.

El método propuesto clasificará (predecirá) los nuevos votos de un usuario (es decir, el posible valor del voto que un usuario daría a un ítem) en función de los votos existentes en el conjunto de datos.

Las distribuciones de probabilidades a priori son calculadas en base a los votos de cada usuario e ítems. Este concepto está representado por las ecuaciones 3.6 y 3.9.

Debido a la suposición de independencia de NBC, el likelihood se calculará en función de los votos de un usuario o ítem con respecto a los votos de otro usuario o ítem, respectivamente. Se usan las ecuaciones 3.7 y 3.10 para calcular el likelihood. Para obtener el valor de clasificación, se combinan la probabilidad a priori y el likelihood (ecuaciones 3.8 y 3.11).

En nuestro método a diferencia del método naive bayes mejorado (INBM) mencionado en la sección 2, se considera que los votos son totalmente independientes entre sí.

3.2. Formulación del método propuesto

El método propuesto Naive Bayes para CF (NBCF, por sus siglas en inglés) obtiene la probabilidad de que un usuario vote un ítem con un valor de voto específico, conociendo los votos anteriores que existen en el conjunto de datos. Esto se calcula a través de la probabilidad a priori y el likelihood basados en la ecuación 3.4. De esta forma, se define tres diferentes enfoques basados en el cálculo de la probabilidad a priori y el likelihood.

- Enfoque basado en el usuario: la probabilidad a priori y el likelihood se calculan de acuerdo con los ítems que cada usuario ha votado.
- Enfoque basado en ítems: la probabilidad a priori y el likelihood se calculan de acuerdo con los votos que cada ítem ha recibido.
- Enfoque híbrido: integra los enfoques basados en el usuario e ítems, a fin de complementarse uno con otro y mejorar la precisión del modelo.

Para este propósito, consideramos un RS con un conjunto de usuarios U que votan un conjunto de ítems I. El valor del voto de un usuario u al ítem i se representa con $r_{u,i}$. La ausencia del voto se representa por \bullet .

3.2.1. Enfoque basado en el usuario

Basados en las especificaciones del clasificador Naive Bayes, se procede a calcular primeramente la probabilidad a priori, de ahí que en el enfoque NBCF (usuario) se define $P(r_i = y)$ como la probabilidad de que el ítem i sea votado como y por algún usuario.

$$P(r_i = y) = \frac{\#\{u \in U | r_{u,i} = y\} + \alpha}{\#\{u \in U | r_{u,i} \neq \bullet\} + \#R \cdot \alpha}$$
(3.6)

Donde: α es un parámetro para evitar θ probabilidades y #R representa el número de votos plausibles.

Luego, se define $P(r_j = k | r_i = y)$ como la probabilidad de que el ítem j sea votado como k sabiendo que el voto del ítem i es y:

$$P(r_j = k | r_i = y) = \frac{\#\{u \in U | r_{u,j} = k \land r_{u,i} = y\} + \alpha}{\#\{u \in U | r_{u,j} \neq \bullet \land r_{u,i} = y\} + \#R \cdot \alpha}$$
(3.7)

Igualmente, α es un parámetro para evitar θ probabilidades y #R representa el número de votos plausibles.

Finalmente, $P(r_{u,i} = y)$ será el valor de clasificación que el usuario u vote el ítem i con el voto y de acuerdo con los ítems votados por el usuario u.

$$P(r_{u,i} = y) \propto P(r_i = y) \prod_{j \in I_u} P(r_j = r_{u,j} | r_i = y)$$
 (3.8)

Donde: $I_u = \{i \in I | r_{u,i} \neq \bullet\}$ es el conjunto de ítems votados por el usuario u.

3.2.2. Enfoque basado en ítems

En el enfoque NBCF (ítems), se define $P(r_u = y)$ como la probabilidad de que el usuario u vote cualquier ítem con y:

$$P(r_u = y) = \frac{\#\{i \in I | r_{u,i} = y\} + \alpha}{\#\{i \in I | r_{u,i} \neq \bullet\} + \#R \cdot \alpha}$$
(3.9)

Ahora se procede a calcular el likelihood.

Sea $P(r_v = k | r_u = y)$ la probabilidad de que el usuario v vote como k conociendo que el usuario u ha votado como y.

$$P(r_v = k | r_u = y) = \frac{\#\{i \in I | r_{v,i} = k \land r_{u,i} = y\} + \alpha}{\#\{i \in I | r_{v,i} \neq \bullet \land r_{u,i} = y\} + \#R \cdot \alpha}$$
(3.10)

Para ambas ecuaciones (3.9 y 3.10), el parámetro α es utilizado para evitar θ probabilidades y #R representa el número de votos plausibles.

Por lo tanto, $P(r_{u,i} = y)$ será el valor de clasificación de que el ítem i sea votado como y por el usuario u de acuerdo con las votaciones recibidas del ítem i.

$$P(r_{u,i} = y) \propto P(r_u = y) \prod_{v \in U_i} P(r_v = r_{v,i} | r_u = y)$$
 (3.11)

donde $U_i = \{u \in U | r_{ui} \neq \bullet\}$ es el conjunto de usuarios que ha votado el ítem i.

3.2.3. Enfoque híbrido

En el enfoque NBCF (híbrido), se combinan ambos enfoques: basados en el usuario y en el ítem, esto permite aumentar el número de evidencias utilizadas para calcular el valor de clasificación. Cuanto mayor sea el número de evidencias, mejor será la calidad de las predicciones.

Ambos enfoques pueden combinarse utilizando un producto ponderado, basado en la cantidad de evidencias utilizadas para calcular el enfoque basado en el usuario y el enfoque basado en ítems.

De esta manera, en el enfoque híbrido $P(r_{u,i} = y)$ representa el valor de clasificación de que el usuario u vote el ítem i con el voto y:

$$P\left(r_{u,i}=y\right) \propto \left(P\left(r_{u}=y\right) \cdot \prod_{v \in U_{i}} P\left(r_{v}=r_{v,i} | r_{u}=y\right)\right)^{\frac{1}{1+\#U_{i}}} \cdot \left(P\left(r_{i}=y\right) \cdot \prod_{j \in I_{u}} P\left(r_{j}=r_{u,j} | r_{i}=y\right)\right)^{\frac{1}{1+\#I_{u}}} \tag{3.12}$$

Donde: $I_u = \{i \in I | \{r_{u,i} \neq \bullet\}$ es el conjunto de ítems votados por el usuario u y $U_i = \{u \in U | \{r_{u,i} \neq \bullet\}$ es el conjunto de usuarios que han votado el ítem i.

3.3. Cálculo de la predicción

Se calcula las predicciones considerando el voto que maximiza la probabilidad de ser calificado. Se define a $\hat{r}_{u,i}$ como la predicción del voto del usuario u para el ítem i.

$$\hat{r}_{u,i} = \underset{y}{\operatorname{argmax}} P\left(r_{u,i} = y\right) \tag{3.13}$$

En la ecuación el operador argmax devolverá el índice en el que $\hat{r}_{u,i}$ es máximo

(éste sería la clase con la máxima probabilidad).

3.4. Cálculo de confiabilidad

La confiabilidad de las predicciones es un campo de investigación abierto en el área de sistemas de recomendación (Moradi y Ahmadian, 2015; Bobadilla, Gutiérrez, Ortega, y Zhu, 2018). Esta medida ha sido ampliamente estudiada usando métodos de CF basado en memoria, pero raramente ha sido desarrollada para enfoques de CF basados en modelos (Zhu, Ortega, Bobadilla, y Gutiérrez, 2018).

La confiabilidad se puede definir como la certeza que tiene el sistema de recomendación en el cálculo de las predicciones, es decir, un sistema de recomendación necesita proporcionar alguna certeza en el ítem i recomendado, con el objeto de disminuir las dudas del usuario cuando selecciona, compra o visualiza ese ítem.

Cuando se proveen valores de confiabilidad, cada predicción se define por el par < predicción, confiabilidad >, donde la confiabilidad representa la confianza del modelo en una predicción. Al usar la confiabilidad, podemos aumentar la precisión de un RS filtrando las recomendaciones con baja confiabilidad, por lo que el sistema recomendará algunos ítems con un valor de alta confiabilidad. De acuerdo a (Hernando, Bobadilla, Ortega, y Tejedor, 2013), la idea de esta medida es que cuanto más confiable es una predicción, menos probable es que sea incorrecta.

En (Zhu, 2018) mencionan que no hay métodos de sistemas de recomendación para obtener pares < predicción, confiabilidad >, desde modelos de aprendizaje automático solamente basados en conjuntos de datos de votos. Ellos proponen una medida de confiabilidad para sistemas de recomendación de filtrado colaborativo basado en modelos de factorización matricial, para asignar valores de confiabilidad a las predicciones correspondientes. Sin embargo en nuestro enfoque, el modelo bayesiano propuesto puede fácilmente proporcionar la confiabilidad relacionada con cada predicción, considerando los valores de clasificación.

Sea $l_{u,i}$ la confiabilidad de la predicción del usuario u al ítem i.

$$l_{u,i} = \frac{P(r_{u,i} = \hat{r}_{u,i})}{\sum_{y \in R} P(r_{u,i} = y)}$$
(3.14)

Donde R es el conjunto de valores de votos plausibles del RS. Esta medida de confiabilidad puede ser aplicada tanto a un enfoque basado en el usuario, basado en ítem, y a un enfoque híbrido.

3.5. Ejemplo de ejecución

En esta sección, presentamos un ejemplo de ejecución para aclarar cómo funciona el método propuesto.

En la Tabla 3.1 mostramos un ejemplo de una matriz de votos con cinco usuarios y nueve ítems. Las celdas indicadas con '●' indican que el usuario no ha votado ese ítem.

 \boldsymbol{i}_9 \boldsymbol{i}_1 \boldsymbol{i}_2 i_3 i_4 i_6 i_7 2 1 2 5 4 3 • 5 \boldsymbol{u}_1 1 3 2 3 3 \boldsymbol{u}_2 2 2 1 4 4 5 u_3 3 2 2 3 3 2 1 \boldsymbol{u}_4 5 5 2 1 4 u_5

Tabla 3.1: Ejemplo de matriz de votos

En este ejemplo de ejecución, se detalla cómo calcular la predicción del voto del usuario u_1 al ítem i_1 (\hat{r}_{u_1,i_1}) utilizando los tres enfoques propuestos.

Primero, necesitamos calcular las distribuciones anteriores (prior). La Tabla 3.2 muestra la probabilidad de que el ítem i_1 sea votado por algún usuario con $\{1, 2, 3, 4, 5\}$, al aplicar un enfoque basado en el usuario. La ecuación 3.15 detalla cómo calcular la probabilidad de que el ítem i_1 sea votado con 1 de acuerdo con

la ecuación 3.6.

$$P(r_{i_1} = 1) = \frac{\#\{u \in U | r_{u,i_1} = 1\} + \alpha}{\#\{u \in U | r_{u,i_1} \neq \bullet\} + \#R \cdot \alpha} = \frac{\#\{u_2, u_3\} + 0.01}{\#\{u_2, u_3, u_4, u_5\} + 0.05} = \frac{2.01}{4.05} = 0.496297$$
(3.15)

Tabla 3.2: Probabilidad prior del ítem i_1 usando el enfoque basado en el usuario

| | 1 | 2 | 3 | 4 | 5 |
|---------------------------|----------|----------|----------|----------|----------|
| $P\left(r_{i_1}=y\right)$ | 0.496297 | 0.002470 | 0.249383 | 0.002470 | 0.249383 |

La tabla 3.3 muestra la probabilidad de que el usuario u_1 vote algún ítem con $\{1, 2, 3, 4, 5\}$, al aplicar el enfoque basado en ítems. La ecuación 3.16 detalla cómo calcular la probabilidad de que el usuario u_1 vote algún ítem con 1 según la ecuación 3.9.

$$P(r_{u_1} = 1) = \frac{\#\{i \in I | r_{u_i,i} = 1\} + \alpha}{\#\{i \in I | r_{u_i,i} \neq \bullet\} + \#R \cdot \alpha} =$$
(3.16)

$$\frac{\#\left\{i_2\right\} + 0.01}{\#\left\{i_2, i_3, i_4, i_5, i_7, i_8, i_9\right\} + 0.05} = \frac{1.01}{7.05} = 0.143262411$$

Tabla 3.3: Probabilidad prior del usuario u_1 usando el enfoque basado en ítem

| | 1 | 2 | 3 | 4 | 5 |
|---------------------------|----------|----------|----------|----------|----------|
| $P\left(r_{u_1}=y\right)$ | 0.143262 | 0.285106 | 0.143262 | 0.143262 | 0.285106 |

Luego, se tiene que calcular el likelihood. En el enfoque basado en el usuario, según la ecuación 3.8, solamente el likelihood que relaciona el ítem objetivo (i_1) con cada ítem votado por el usuario activo (u_1) es calculado. La Tabla 3.4 muestra la probabilidad que el ítem i_1 sea votado con $\{1, 2, 3, 4, 5\}$ con respecto a los ítems votados por el usuario u_1 .

La ecuación 3.17 detalla cómo calcular el likeliho
od del voto del ítem $i_1 \ {\rm con} \ 1$

si el ítem i_2 ha sido votado con 1.

$$P(r_{i_2} = 1 | r_{i_1} = 1) = \frac{\#\{u \in U | r_{u,i_2} = 1 \land r_{u,i_1} = 1\} + \alpha}{\#\{u \in U | r_{u,i_2} \neq \bullet \land r_{u,i_1} = 1\} + \#R \cdot \alpha}$$

$$\frac{\#\{u_3\} + 0.01}{\#\{u_2, u_3\} + 0.05} = \frac{1.01}{2.05} = 0.492682$$
(3.17)

Tabla 3.4: Likelihood del ítem i_1 basado en el voto del usuario u_1

| | \mathbf{y} | | | | | | | |
|--------------------|----------------|----------|----------|----------|----------|----------|--|--|
| | | 1 | 2 | 3 | 4 | 5 | | |
| | \mathbf{i}_2 | 0.492682 | 0.200000 | 0.009523 | 0.200000 | 0.961904 | | |
| | \mathbf{i}_3 | 0.492682 | 0.200000 | 0.961904 | 0.200000 | 0.009523 | | |
| $ig \mathbf{i}_n$ | \mathbf{i}_4 | 0.200000 | 0.200000 | 0.009523 | 0.200000 | 0.009523 | | |
| | i 5 | 0.004878 | 0.200000 | 0.200000 | 0.200000 | 0.009523 | | |
| | \mathbf{i}_7 | 0.980487 | 0.200000 | 0.009523 | 0.200000 | 0.009523 | | |
| | \mathbf{i}_8 | 0.492682 | 0.200000 | 0.009523 | 0.200000 | 0.009523 | | |
| | i 9 | 0.200000 | 0.200000 | 0.200000 | 0.200000 | 0.200000 | | |

En el enfoque basado en ítems, de acuerdo con la ecuación 3.11, solamente debe calcularse el likelihood que relaciona al usuario activo (u_1) con cada usuario que ha votado el ítem objetivo (i_1) .

La Tabla 3.5 muestra la probabilidad de que el ítem i_1 sea votado con $\{1, 2, 3, 4, 5\}$ con respecto a los usuarios que han votado ese ítem.

La ecuación 3.18 detalla cómo calcular la probabilidad de votar el ítem i_1 con 1 si el usuario u_2 lo ha calificado con 1.

$$P(r_{u_2} = 1 | r_{u_1} = 1) = \frac{\# \{ i \in I | r_{u_2,i} = 1 \land r_{u_1,i} = 1 \} + \alpha}{\# \{ i \in I | r_{u_2,i} \neq \bullet \land r_{u_1,i} = 1 \} + \# R \cdot \alpha} = \frac{\# \{ \} + 0.01}{\# \{ i_2 \} + 0.05} = \frac{0.01}{1.05} = 0.0095238$$
(3.18)

Finalmente, el valor de clasificación se puede calcular de acuerdo con las ecua-

| | v | | | | | | |
|--------------------------|----------------|------------|------------|------------|------------|------------|--|
| | | 1 | 2 | 3 | 4 | 5 | |
| | \mathbf{u}_2 | 0.00952380 | 0.00952380 | 0.00952380 | 0.00952380 | 0.00952380 | |
| 11. | \mathbf{u}_3 | 0.96190476 | 0.00952380 | 0.00952380 | 0.00952380 | 0.00952380 | |
| $\mid \mathbf{u}_j \mid$ | \mathbf{u}_4 | 0.00952380 | 0.49268292 | 0.00952380 | 0.96190476 | 0.20000000 | |
| | \mathbf{u}_5 | 0.00952380 | 0.98048780 | 0.00952380 | 0.96190476 | 0.00952380 | |

Tabla 3.5: Likelihood del usuario u_1 basado en el voto del ítem i_1

ciones 3.8, 3.11 y 3.12, para el enfoque basado en el usuario, basado en ítem e híbrido, respectivamente.

La Tabla 3.6 contiene el valor de clasificación utilizando el enfoque basado en el usuario. De acuerdo con la ecuación 3.13, la predicción será 1 si se usa este enfoque, ya que es el argumento que maximiza el valor de probabilidad.

Tabla 3.6: Valor de clasificación, usando el enfoque basado en el usuario

| \mathbf{y} | | | | | |
|------------------------------------------------------|-----------|-----------|------------|-----------|------------|
| $egin{array}{ c c c c c c c c c c c c c c c c c c c$ | | | | | |
| $P\left(r_{u_1,i_1}=y\right)$ | 1.1355E-5 | 3.1604E-8 | 7.8940E-11 | 3.1604E-8 | 3.7590E-12 |

La tabla 3.7 contiene el valor de clasificación usando el enfoque basado en ítems, en este caso la predicción será 2.

Tabla 3.7: Valor de clasificación, usando el enfoque basado en ítem

| y | | | | | | |
|------------------------------------------------------|------------|------------|------------|------------|------------|--|
| $egin{array}{ c c c c c c c c c c c c c c c c c c c$ | | | | | | |
| $P\left(r_{u_1,i_1}=y\right)$ | 1.19041E-7 | 1.24921E-5 | 1.17862E-9 | 1.20231E-5 | 4.92571E-8 | |

La tabla 3.8, presenta el valor de clasificación del enfoque híbrido, donde la predicción será 2.

Una vez obtenidas las predicciones para cada enfoque, se procede a calcular la confiabilidad de las predicciones. En este caso se debe aplicar la ecuación 3.14.

A continuación se presenta el calculo de esta medida para el enfoque híbrido, usando este enfoque la predicción es 2, por lo que el valor de confiabilidad de esta

Tabla 3.8: Valor de clasificación, usando el enfoque híbrido

predicción se puede obtener de la siguiente manera:

$$l_{u_1,i_1} = \frac{P(r_{u_1,i_1} = 2)}{\sum_{y=1}^{5} P(r_{u_1,i_1} = y)} = \frac{1,20724E - 2}{0,03616834} = 0,333784$$
 (3.19)

Este valor significa que el algoritmo tiene una confiabilidad del $33,4\,\%$ de que la predicción es correcta.

3.6. Algoritmo NBCF

En esta sección presentamos el algoritmo utilizado para implementar el método NBCF. Para reducir la complejidad computacional del algoritmo, se ha seguido un método de memorización.

El algoritmo 1 muestra los pasos para calcular las probabilidades que son necesarias para obtener las predicciones, por lo tanto, el algoritmo construye el modelo que debe usarse al calcular las predicciones. Este algoritmo calcula esas probabilidades de manera iterativa, almacenando los valores para evitar volver a calcularlos nuevamente.

Algorithm 1 Algoritmo NBCF

entrada: $(r_{ui}), (\alpha)$

salida: $(pup_{u,y}), (pip_{i,y}), (cup_{v,k,u,y}), (cip_{j,k,i,y})$

tmp: (uc_u) , (ic_i) , $(ijc_{j,i,y})$, $(uvc_{v,u,y})$

inicializar: $pup_{u,y}, pip_{i,y}, cup_{v,k,u,y}$ and $cip_{j,k,i,y}$ with α inicializar: $uc_u, ic_i, ijc_{j,i,y}$ and $uvc_{v,u,y}$ with $\#R \cdot \alpha$

for cada usuario u do

for cada ítem i votado por el usuario u do

$$y \leftarrow r_{u,i}$$

$$pup_{u,y} \leftarrow \frac{uc_u \cdot pup_{u,y} + 1}{uc_u + 1}$$

$$uc_u \leftarrow uc_u + 1$$

$$pip_{i,y} \leftarrow \frac{ic_i \cdot pip_{i,y} + 1}{ic_i + 1}$$

$$ic_i \leftarrow ic_i + 1$$

for cada ítem j votado por el usuario u do

$$k \leftarrow r_{u,j}$$

$$cip_{j,k,i,y} \leftarrow \frac{ijc_{j,i,y} \cdot cip_{j,k,i,y} + 1}{ijc_{j,i,y} + 1}$$

$$ijc_{j,i,y} \leftarrow ijc_{j,i,y} + 1$$

end

for cada usuario v votado por el ítem i do

$$k \leftarrow r_{v,i}$$

$$cup_{v,k,u,y} \leftarrow \frac{uvc_{v,u,y} \cdot cup_{v,k,u,y} + 1}{uvc_{v,u,y} + 1}$$

$$uvc_{v,u,y} \leftarrow uvc_{v,u,y} + 1$$

end

end

end

Capítulo 4

Experimentos y resultados

En este capítulo se presentan los experimentos realizados con el método propuesto, los conjuntos de datos y las medidas de calidad usadas para medir el desempeño del modelo, la configuración de los hiperparámetros de los métodos de línea base seleccionados y una discusión de los resultados obtenidos.

4.1. Configuración del experimento

Los experimentos diseñados comparan el enfoque propuesto con varios modelos de línea base, utilizando medidas de calidad y procesando cuatro conjuntos de datos públicos de CF (MovieLens, FilmTrust, Yahoo y BookCrossing), que se utilizan comúnmente en el área de los sistemas de recomendación.

- MovieLens: es una colección de votos de usuarios sobre películas. El rango de valores del voto es de 1 a 5 estrellas, con incrementos de 1 estrella.
- FilmTrust: colecciona votos de usuarios sobre películas en una escala de 0.5 a 4.0, con incrementos de 0.5. También contiene votos de confianza emitidas por usuarios.
- Yahoo: colecciona votos de los usuarios a canciones de diferentes artistas, en una escala de 1 a 5 estrellas, con incrementos de 1 estrella.

BookCrossing: contiene información de votos de libros. Las votaciones son explícitas, expresadas en una escala de 1 a 10 (los valores más altos indican una apreciación más alta) o implícitas, expresadas con 0, los incrementos son de 1 estrella. Para este conjunto de datos consideramos solo la información explícita del voto del libro del conjunto de datos original.

Los principales parámetros de estos conjuntos de datos se muestran en la Tabla 4.1.

Tabla 4.1: Principales propiedades de los datasets usados en los experimentos

| Datasets | #usuarios | #ítems | #votos | escala del voto | sparsity |
|--------------|-----------|---------|-----------|-----------------|-------------|
| MovieLens | 6,040 | 3,701 | 1,000,209 | 1-5 | $95{,}53\%$ |
| Film Trust | 1,508 | 2,071 | 35,494 | 0.5-4 | $98,\!86\%$ |
| Yahoo | 7,210 | 4,000 | 167,602 | 1-5 | 99,42% |
| BookCrossing | 77,805 | 185,963 | 432,628 | 1-10 | 99,99% |

El modelo propuesto ha sido diseñado utilizando un enfoque probabilístico para facilitar la explicación de sus resultados. Este concepto ha sido aplicado previamente en el campo de RS.

Hemos seleccionado como línea base los métodos de recomendaciones más populares en la literatura, tanto de la familia de enfoques basados en factorización matricial, y de aquellos que utilizan un enfoque probabilístico para explicar sus resultados. Los métodos seleccionados son:

- NMF, este modelo de factorización matricial fue seleccionado como línea base porque permite trabajar solo con factores positivos, lo cual facilita la interpretación de sus resultados.
- INBM, este modelo probabilístico bayesiano fue seleccionado porque al estar basado en naive bayes, la razón de cada recomendación es fácil de explicar.
- GGM, seleccionamos este modelo probabilístico porque al igual que al anterior tiene relación con el enfoque propuesto, ya que es un modelo bayesiano que facilita la interpretación de los resultados.
- BNMF, fue seleccionado de la familia de métodos probabilísticos basados en factorización matricial, en este método bayesiano cada uno de sus compo-

nentes tiene un significado probabilístico comprensible. Seleccionamos este método porque permite comprender y justificar las predicciones.

■ Bi-CF, aunque éste no es un método basado en modelos, fue seleccionado por ser un enfoque híbrido que combina filtrado colaborativo basado en el usuario (UBCF) y filtrado colaborativo basado en ítems (IBCF) (Kant y Mahara, 2018). Este método combina estos dos enfoques en una suma ponderada y usa la técnica de biclustering (subconjunto de usuarios e ítems) (Chandralekha, Saranya, y Sudha, 2016), para agrupar a los usuarios e ítems simultáneamente y así reducir la dimensionalidad. Además de acuerdo a (Alqadah, Reddy, Hu, y Alqadah, 2015) esta técnica facilita la interpretabilidad de los resultados.

La tabla 4.2 presenta el acrónimo por cada uno de los métodos seleccionados, que fueron explicados en el estado del arte.

Tabla 4.2: Métodos de línea base de CF utilizados para comparar los resultados con el método propuesto

| Línea base | Acrónimo |
|---------------------------------------------------------|----------|
| Factorización Matricial No negativa | NMF |
| Modelo Bayesiano de Factorización Matricial No Negativa | BNMF |
| Modelo Gaussian-Gamma | GGM |
| Método Naive Bayes Mejorado | INBM |
| Método basado en la técnica de Biclustering | Bi-CF |

Para los experimentos se utilizó el marco de filtrado colaborativo para Java (CF4J) desarrollado por (Ortega, Zhu, Bobadilla, y Hernando, 2018), el cual fue diseñado para llevar a cabo experimentos de investigación de RS basados en CF.

En todos los experimentos, ciertos hiperparámetros necesitan ser definidos de acuerdo con el método de CF comparado. Éstos se muestran en la tabla 4.3 por cada método de línea base. Además se incluye el hiperparámetro definido para el método propuesto, el cual es el mismo para todos los conjuntos de datos.

Tabla 4.3: Principales hiperparámetros utilizados en los experimentos. Datasets: MovieLens, FilmTrust, Yahoo, BookCrossing

| Hiperparámetro | MovieLens | FilmTrust | Yahoo | BookCrossing | |
|-----------------------------|-----------|-----------|-------|--------------|--|
| % usuarios de test | 20% | 20 % | 20% | 20 % | |
| % ítems de test | 20% | 20% | 20% | 20% | |
| % usuarios entrenamiento | 80% | 80 % | 80 % | 80% | |
| % ítems entrenamiento | 80 % | 80 % | 80 % | 80 % | |
| Precision & Recall (umbral) | 4 | 3 | 4 | 8 | |
| BNMF | | | | | |
| Num. factores | 6 | 6 | 6 | 6 | |
| Num. iteraciones | 150 | 50 | 120 | 120 | |
| α | 0.8 | 0.8 | 0.8 | 0.8 | |
| β | 5 | 4 | 5 | 4 | |
| Bi-CF | | | | | |
| Num. iteraciones | 50 | 20 | 30 | 30 | |
| α | 0.001 | 0.01 | 0.001 | 0.01 | |
| #cluster | 4 | 2 | 3 | 3 | |
| γ | 0.8 | 0.8 | 0.8 | 0.8 | |
| NMF | | | | | |
| Num. iteraciones | 150 | 100 | 150 | 300 | |
| Num. factores | 15 | 8 | 15 | 12 | |
| NBCF | | | | | |
| α | 0.01 | 0.01 | 0.01 | 0.01 | |

Los valores de los hiperparámetros involucrados en los experimentos, han sido seleccionados para maximizar la precisión de los algoritmos para todas las medidas de calidad utilizadas. Para este proceso se consideró la técnica de validación de sub-muestreo aleatorio repetida (*Monte Carlo cross-validation*) (Chlis, 2015). Esta técnica crea múltiples divisiones aleatorias del conjunto de datos. Cada división es separada en datos de entrenamiento y prueba. En nuestro caso se consideraron 5 repeticiones, luego los resultados de todas estas repeticiones fueron promediados. Los porcentajes de configuración de pruebas y entrenamiento son iguales para todos los conjuntos de datos probados.

4.2. Medidas de calidad

El modelo propuesto es evaluado considerando tres aspectos: calidad de las predicciones, de las recomendaciones y calidad de las listas de recomendaciones.

Algunas medidas de calidad existentes en la literatura para este propósito son descritas a continuación:

4.2.1. Calidad de las predicciones

Evaluar la precisión de las predicciones en muy importante en el análisis de los sistemas de recomendación, para este propósito algunas métricas pueden ser utilizadas, en este apartado se describen las más comúnmente usadas en el campo de los sistemas de recomendación.

Error medio absoluto

Se utiliza el error medio absoluto (MAE, por sus siglas en inglés), para medir qué tan cerca está la predicción del sistema con el voto real del usuario dado a cada ítem, considerando la desviación absoluta entre el voto estimado y el voto real del usuario (Herlocker, Konstan, Terveen, y Riedl, 2004).

$$MAE = \frac{\sum_{i=1}^{N} |\hat{r}_i - r_i|}{N}$$
 (4.1)

Donde: N es el número de valores reales del conjunto de test, r es el voto real y \hat{r} el voto estimado.

En esta investigación tomaremos como referencia lo establecido por (Ortega, Rojo, Valdiviezo-Díaz, y Raya, 2018), para el cálculo de esta métrica. De acuerdo a estos autores MAE se define como el promediado MAE_u para todos los usuarios

del RS, para lo cual se utiliza la siguiente ecuación:

$$MAE = \frac{MAE_u}{\#U} \tag{4.2}$$

Donde: MAE_u es la diferencia media absoluta entre los votos de test del usuario u y los votos estimados.

$$MAE_{u} = \frac{\sum_{i \in I_{u}} |r_{u,i} - \hat{r}_{u,i}|}{\#\hat{I}_{u}}$$
(4.3)

 $\hat{I}_u,$ representa el conjunto de ítems de test votados por el usuario u.

Error medio absoluto normalizado

Hay algunas variaciones de MAE, entre ellas, el error medio cuadrático (MSE, por sus siglas en inglés), la raíz del error medio cuadrático (RMSE, por sus siglas en inglés) y MAE normalizado (NMAE, por sus siglas en inglés).

NMAE, hace referencia al error medio absoluto multiplicado por un factor de normalización, en orden a normalizar el rango de los valores del voto. Esta métrica se calcula con la siguiente ecuación (Rawat y Dwivedi, 2019):

$$NMAE = \alpha MAE = \frac{1}{r_{\text{máx}} - r_{\text{mín}}} MAE \tag{4.4}$$

Donde: α es el factor de normalización, $r_{\text{máx}}$ es el voto máximo, y $r_{\text{mín}}$ es el voto más bajo dado por el usuario.

Raíz del Error Medio Cuadrático

RMSE al igual que la métrica anterior, es utilizada frecuentemente para medir las diferencias entre los valores estimados y los valores reales. RMSE está repre-

sentado por la media cuadrática de la diferencia entre el voto real y el estimado.

RMSE =
$$\sqrt{\frac{1}{|N|} \sum_{(u,i) \in N} (r_{ui} - \hat{r}_{ui})^2}$$
 (4.5)

Donde: N es el número de valores reales del conjunto de test, r es el voto real y \hat{r} el voto estimado.

En (Ortega, Rojo, y cols., 2018), RMSE es el promedio de $RMSE_u$ para todos los usuarios del RS:

$$RMSE = \frac{RMSE_u}{\#U} \tag{4.6}$$

Se define a $RMSE_u$, como la diferencia del error cuadrático medio entre los votos de test del usuario u y los votos estimados.

$$RMSE_{u} = \sqrt{\frac{\sum_{i \in \hat{I}_{u}} (r_{u,i} - \hat{r}_{u,i})^{2}}{\# \hat{I}_{u}}}$$
(4.7)

Donde \hat{I}_u , representa el conjunto de ítems de test votados por el usuario u.

Mientras más bajo es el valor de MAE y RMSE, mejor es la predicción del voto.

4.2.2. Calidad de las recomendaciones

Las métricas más populares para evaluar la calidad de las recomendaciones o el desempeño del modelo son: Precisión, Recall, *F-measure* y Característica Operativa del Receptor (ROC, por sus siglas en inglés). Estas métricas son comúnmente usadas cuando el sistema modela las predicciones como un problema de clasificación (Paradarami, Bastian, y Wightman, 2017).

De acuerdo a (Herlocker y cols., 2004), las métricas de clasificación miden la

frecuencia con la que un sistema de recomendación toma decisiones correctas o incorrectas sobre si un ítem es bueno.

Para el cálculo de estas métricas se considera lo siguiente:

- El conjunto de ítems debe estar separado en dos clases: relevante y no relevante, un ítem es relevante si el valor del voto es mayor o igual a un cierto umbral θ , No Relevante si el valor del voto es menor a θ .
- Separar el conjunto de predicciones en dos clases: Recomendados y no Recomendados, un ítem es Recommendable si se encuentra dentro del Top-N de recomendaciones definido en el experimento y si éste ha sido calificado. Los ítems que están fuera del Top-N recomendaciones serían los ítems No Recomendados.

Precisión

Representa la probabilidad de que un ítem recomendado es relevante (Herlocker y cols., 2004). Es decir, la precisión se define como la fracción de ítems recomendados que es realmente relevante para el usuario (Isinkaye, Folajimi, y Ojokoh, 2015).

$$Precisión = \frac{número de ítems relevantes recomendados}{número de ítems recomendados}$$
(4.8)

En (Ortega, Rojo, y cols., 2018) la precisión se define como la $precision_u$ promediada para todos los usuarios de RS:

$$precision = \frac{precision_u}{\#U}$$
 (4.9)

Donde: $precision_u$ es la proporción de los N ítems recomendados para el usuario u que son relevantes para él/ella. Se utiliza la siguiente ecuación:

$$\operatorname{precision}_{u} = \frac{\#\left\{i \in R_{u}^{N} | r_{u,i} \ge \theta\right\}}{N}$$
(4.10)

En este caso, R_u^N es el conjunto de N ítems recomendados para el usuario u y θ es un valor de umbral que indica si una recomendación es relevante o no.

Recall

Representan la probabilidad de que un ítem relevante sea recomendado (Herlocker y cols., 2004). Se define como la fracción de ítems relevantes que también forman parte del conjunto de ítems recomendados.

Recall =
$$\frac{\text{número de ítems relevantes recomendados}}{\text{número de ítems relevantes}}$$
 (4.11)

Para (Ortega, Rojo, y cols., 2018) el recall se define como el $recall_u$ promediado para todos los usuarios del RS:

$$recall = \frac{recall_u}{\#U} \tag{4.12}$$

Donde: $recall_u$ es la proporción de ítems relevantes recomendados para el usuario u con respecto al total de ítems votados relevantes:

$$\operatorname{recall}_{u} = \frac{\#\left\{i \in R_{u}^{N} | r_{u,i} \ge \theta\right\}}{\#\left\{i \in \hat{I}_{u} | r_{u,i} \ge \theta\right\}}$$

$$(4.13)$$

F-measure

Otra métrica que permite evaluar el desempeño del sistema recomendador es F-measure, la cual combina precisión y recall en una sola medida (M. Chen y Liu, 2017). Se define como:

$$F - \text{Measure} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$
(4.14)

El mejor valor de F es 1, que se obtiene cuando: tanto la precisión como el recall son iguales a 1.

De acuerdo a (Rawat y Dwivedi, 2019) usando esta métrica, es posible obtener una visión más realista del rendimiento de un algoritmo de recomendación.

Curva ROC

Las curvas de la Característica Operativa del Receptor (ROC, por sus siglas en inglés), tienen mucho éxito al realizar evaluaciones exhaustivas del rendimiento de algunos algoritmos específicos (Isinkaye y cols., 2015).

La curva ROC es un gráfico de coordenadas bidimensionales, donde el eje X representa la tasa de falsos positivos (FPR, por sus siglas en inglés) y el eje Y es la tasa de verdaderos positivos (TPR, por sus siglas en inglés) (Isinkaye y cols., 2015). Por tanto, la curva ROC muestra la correspondencia entre FPR y TPR.

4.2.3. Calidad de las listas de recomendaciones

Existen algunas medidas de calidad que permiten medir las listas de recomendación, en este apartado se mencionan las siguientes:

Ganancia acumulada descontada normalizada

Esta métrica llamada nDCG (por sus siglas en inglés) (Y. Wang, Wang, Li, He, y Chen, 2013), es una medida de recuperación de información que permite evaluar el desempeño de la clasificación teniendo en cuenta las posiciones de los ítems correctos. nDCG es una versión normalizada de DCG, la cual depende de la posición. De acuerdo a (Weimer, Karatzoglou, Viet Le, y Smola, 2007) las posiciones más altas tienen más influencia en el ranking que las posiciones más bajas.

Para (Ortega, Rojo, y cols., 2018) nDCG se define como el promedio de

 $nDCG_u$ para todos los usuarios del RS.

$$nDCG = \frac{nDCG_n}{\#U} \tag{4.15}$$

Donde: $nDCG_u$ es la relevancia normalizada de N recomendaciones dadas al usuario u basados en su posición en la lista de recomendaciones.

$$nDCG_u = \frac{DCG_u}{IDCG_u} \tag{4.16}$$

 $IDCG_u$ es la ganancia acumulada descontada ideal, es el DCG_u del orden ideal del ranking, es decir, las clasificaciones reales del usuario en el conjunto de prueba.

$$DCG_u = \sum_{p=1}^{N} \frac{2^{r_{k,w,y}} - 1}{\log_2(p+1)}$$
(4.17)

$$IDCG_u = \sum_{p=1}^{\#\hat{I}_u} \frac{2^{r_{u,y_{u,p}}} - 1}{\log_2(p+1)}$$
(4.18)

Donde: $x_{u,p}$ es la ubicación para el ítem recomendado en la p-th posición si los ítems recomendados al usuario u son ordenados desde la mayor a menor predicción $(\hat{r}_{u,i})$ y $y_{u,p}$ es la ubicación para el ítem en la posición p-th si los items de test calificados por el usuario u (\hat{I}_u) son ordenados por su valor de voto $(r_{u,i})$.

Utilidad de vida media half-life

Mide la utilidad esperada de una lista de recomendación para un usuario, basándose en la suposición de que los usuarios tienen más probabilidades de ver los ítems más altos en la lista.

La utilidad half-life esperada R_u de la lista de recomendaciones para un usua-

rio u está definido por:

$$R_u = \sum_{i} \frac{\max(r_{u,i} - d, 0)}{2^{(k_i - 1)/(\alpha - 1)}}$$
(4.19)

Donde: $r_{u,i}$ es el voto del usuario u al ítem i de la lista de votos; α es el half - life, el half - life es el rango del ítem en la lista, de modo que hay un 50% de probabilidad de que el usuario vea ese ítem; d es el voto por defecto, d puede ser el voto promedio del usuario, el voto promedio general del sistema o algún punto fijo neutral en la escala de calificación (Ekstrand y cols., 2011).

Tanto nDCG como half-life son usadas en contextos en los que se producen listas clasificadas de ítems, en este caso se puede medir la capacidad del algoritmo para producir *rankings* que coincidan con las del usuario.

En (Charu, 2016) se mencionan también otras medidas para evaluar el desempeño de los sistemas de recomendación a parte de las mencionadas en este trabajo.

4.2.4. Medidas de calidad seleccionadas

De todo el conjunto de métricas señaladas en el punto anterior, se seleccionan las siguientes:

- El error medio absoluto (MAE), para medir la calidad de las predicciones. Se utiliza esta métrica por ser la más ampliamente usada en el cálculo de la precisión de la predicción de un sistema de recomendación y además porque esta métrica no es tan sensible a los valores atípicos como el error cuadrático medio. De acuerdo (M. Chen y Liu, 2017) el error cuadrado no tiene un significado intuitivo.
- Precisión y Recall, para medir la calidad de las recomendaciones. Estas métricas son comúnmente utilizadas para medir el desempeño de los modelos en sistemas de recomendación. Además fueron seleccionadas debido a que para evaluar completamente la efectividad de un modelo, es necesario examinar la precisión y el recall.

■ Ganancia Acumulada Descontada Normalizada (nDCG) para medir la calidad de las listas de recomendaciones. Se selecciona nDCG ya que está siendo ampliamente utilizada en la evaluación de los sistemas de recomendación, puesto que mide la utilidad o ganancia de un ítem basado en su posición en la lista de resultados. De acuerdo a (Y. Wang y cols., 2013) nDCG tiene dos ventajas en comparación con muchas otras medidas. Primero, nDCG permite que cada ítem recomendado tenga relevancia gradual, mientras que la mayoría de las medidas de ranking tradicionales solo permiten relevancia binaria. En segundo lugar, nDCG implica una función de descuento sobre la posición, mientras que muchas otras medidas equilibran uniformemente todas las posiciones. Esta característica es particularmente importante para los sistemas de recuperación de información ya que los usuarios ponen más atención en los ítems mejor posicionados mucho más que otros.

4.3. Desempeño del clasificador

El método propuesto es un algoritmo de clasificación multiclase. Este clasifica cada par < usuario, item > en un valor de voto. Para analizar la calidad de esta clasificación, se calcula la matriz de confusión del enfoque híbrido.

4.3.1. MovieLens

En la figura 4.1 (a) se puede observar que hay un número mayor de predicciones con votaciones altas (4 y 5), lo que significa que los usuarios usualmente votan los ítems en los cuales tienen más interés.

Desde la figura 4.1 (b), para un bajo porcentaje de las observaciones, el modelo NBCF predijo incorrectamente un voto de 1, 2 o 3 cuando el voto actual es 4 o 5, esto significa que a los usuarios no se les recomienda ítems que son de interés para ellos. Sin embargo, para un alto porcentaje de las observaciones, el modelo NBCF predijo correctamente un voto de 4 o 5 cuando el voto actual es el mismo.

En la figura 4.1 (d) se puede observar que el 59 % de los ítems han sido

MovieLens

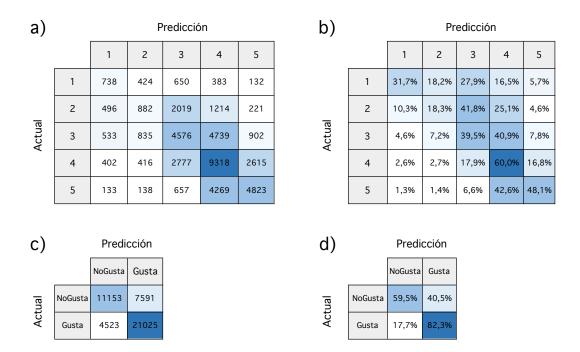


Figura 4.1: (a) matriz de confusión; (b) matriz de confusión normalizada; (c) matriz de confusión discretizando el voto (NoGusta = 1, 2, 3, Gusta = 4, 5); (d) Matriz de confusión normalizada discretizando el voto. Conjunto de datos de MovieLens-1M

correctamente identificados como NoGusta y el 82,3% han sido correctamente identificados como Gusta.

4.3.2. FilmTrust

En la figura 4.2 (a), se puede observar que la mayoría de los usuarios votan los ítems con un valor alto, y las predicciones obtenidas en su mayoría son de votos altos también (3, 3.5, y 4).

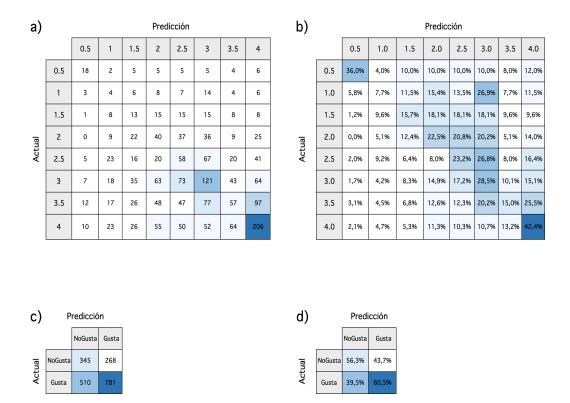


Figura 4.2: (a) matriz de confusión; (b) matriz de confusión normalizada; (c) matriz de confusión discretizando el voto (NoGusta = 1, 2, 3, Gusta = 4, 5); (d) Matriz de confusión normalizada discretizando el voto. Conjunto de datos FilmTrust

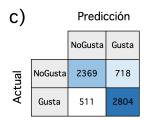
De la figura 4.2 (b), al igual que en el conjunto de datos anterior, se puede observar un gran porcentaje de votos estimados con un valor alto, cuando el voto actual está entre 3 y 4. En este conjunto de datos también se puede observar un porcentaje considerable de votos con valores de 0.5 cuando el voto real es el mismo. Por tanto en la figura 4.2 (d), se tiene que más de la mitad de los ítems (56 %) han sido correctamente estimados como NoGusta y en un 60 % han sido correctamente identificados como Gusta.

4.3.3. Yahoo

En Yahoo, las predicciones de NBCF se centran en su mayoría en votos de 1 y 5, esto significa que así como hay un gran número de usuarios que han votado ítems en los cuales tienen poco interés hay también una gran cantidad de usuarios

b) a) Predicción Predicción 1 2 3 4 5 1 2 3 4 5 1596 247 103 114 90 74,2% 4,8% 5,3% 4,2% 11,5% 2 123 62 73 63 76 2 31,0% 15,6% 18,4% 15,9% 19,1% Actual 112 68 118 110 132 3 20,7% 12,6% 21,9% 20,4% 24,4% 4 74 42 81 179 238 4 12,1% 6,8% 13,2% 29,2% 38,8% 81,2% 2193 6,3% 3,3% 7,2%

que votan por aquellos ítems que verdaderamente les interesa.



| d) | Predicción | | | |
|--------|------------|---------|-------|--|
| | | NoGusta | Gusta | |
| Actual | NoGusta | 76,7% | 23,3% | |
| | Gusta | 15,4% | 84,6% | |

Figura 4.3: (a) matriz de confusión; (b) matriz de confusión normalizada; (c) matriz de confusión discretizando el voto (NoGusta = 1, 2, 3, Gusta = 4, 5); (d) Matriz de confusión normalizada discretizando el voto. Conjunto de datos Yahoo

Desde la figura 4.3 (b), se puede decir que el mayor porcentaje de los votos estimados es con el valor de 1 y 5, cuando el voto actual es el mismo, lo cual significa que NBCF está prediciendo correctamente.

Igualmente hay un bajo porcentaje de votos estimados incorrectamente con valores de 1, 2 y 3 cuando el porcentaje actual es 4 o 5. Esto lo podemos contrastar desde la 4.3 (d) donde a diferencia de los conjuntos de datos anteriores, con Yahoo se tiene un gran porcentaje de ítems identificados correctamente como NoGusta (76, 7%) y Gusta (84, 6%).

4.3.4. BookCrossing

En este conjunto de datos, podemos ver que hay una cantidad reducida de votos estimados cuando los valores actuales del voto son de 1-4. La mayor cantidad de predicciones es con votos altos de 7 a 10, cuando los votos actuales son mayores a 5. Además se puede decir que los usuarios emiten votos por los cuales tienen mayor interés.

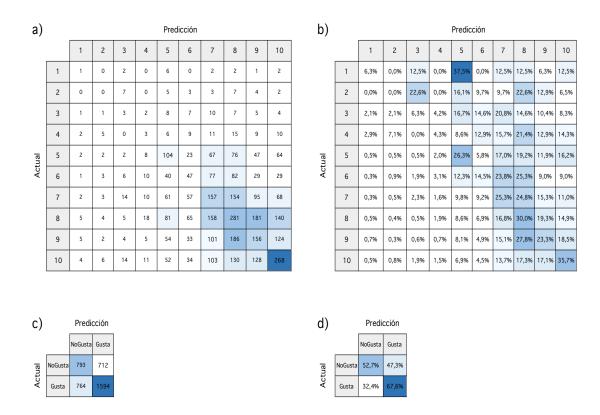


Figura 4.4: (a) matriz de confusión; (b) matriz de confusión normalizada; (c) matriz de confusión discretizando el voto (NoGusta = 1, 2, 3, Gusta = 4, 5); (d) Matriz de confusión normalizada discretizando el voto. Conjunto de datos BookCrossing

En la figura 4.4 (b) a diferencia de los otros conjuntos de datos, en BokkCrossing, el mayor porcentaje de los votos estimados es con un valor de 5 (37%), lo cual no coincide con el voto real del usuario que es de 1. Sin embargo también hay un gran porcentaje de votos estimados con un valor de 10 (35%), lo cual coincide con el voto real del usuario. Aunque se presente esta particularidad con este conjunto de datos, podemos ver que existe un alto porcentaje de las observa-

ciones, donde el modelo NBCF predijo correctamente un voto de 7, 8 y 10 cuando el voto actual es el mismo.

Desde la 4.4 (d) se tiene un gran porcentaje de ítems identificados correctamente como NoGusta (67,6%) y como Gusta el (52,7%), lo cual es aceptable.

4.4. Desempeño del sistema de recomendación

En esta sección, se presentan los resultados empíricos obtenidos de la comparación del modelo propuesto con los métodos de línea base. El hiperparámetro α del enfoque propuesto (NBCF) es configurado en 0.01 para todos los experimentos.

La Tabla 4.4 contiene el MAE para cada conjunto de datos. Se observa que la precisión de la predicción para NBCF (híbrido) es mejor que todos los métodos de línea base de CF en dos de los conjuntos de datos (Yahoo y BookCrossing). En referencia a MovieLens, el resultado en MAE es similar al obtenido con BNMF. Por otro lado, con FilmTrust, NBCF es el segundo modelo con el mejor resultado obtenido en esta métrica.

Tabla 4.4: Error medio absoluto (MAE) del desempeño de las predicciones de los votos de test.

| Method | MovieLens | FilmTrust | Yahoo | BookCrossing |
|---------------|-----------|-----------|---------|--------------|
| NBCF (user) | 0,78369 | 0,77963 | 0,68690 | 1,80944 |
| NBCF (ítem) | 0,79162 | 0,85733 | 1,08200 | 1,61323 |
| NBCF (hybrid) | 0,70915 | 0,74948 | 0,66715 | 1,48323 |
| BNMF | 0,70724 | 0,66523 | 1,04870 | 1,91935 |
| GGM | 1,22667 | 1,06041 | 0,82387 | 2,31250 |
| INBM | 0,89660 | 1,00780 | 1,6406 | 1,97263 |
| Bi-CF | 1,14589 | 1,50488 | 1,85349 | 1,76251 |
| NMF | 0,77006 | 0,78844 | 1,20069 | 1.791998 |

El método propuesto NBCF (híbrido) provee una mejora significativa en MAE con respecto a la mayoría de los métodos de línea base de CF que usamos. Creemos que la razón por la que NBCF no obtiene los mejores resultados en el conjunto de datos de FilmTrust es porque el volumen de datos de FilmTrust es relativamente pequeño, resultando en un pobre desempeño en las estimación de parámetros. A

continuación se muestran los resultados obtenidos con las métricas seleccionadas para medir la calidad de las recomendaciones. Los resultados son analizados por cada conjuntos de datos:

■ MovieLens

La figura siguiente contiene el nDCG para el conjunto de datos MovieLens.

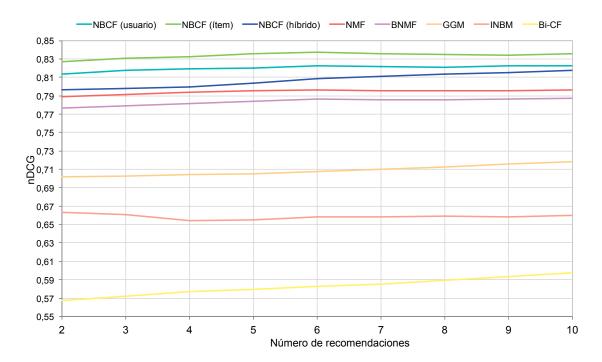


Figura 4.5: Ganancia acumulada descontada normalizada (nDCG) para el conjunto de datos MovieLens

En la Figura 4.5, los resultados de nDCG muestran que los enfoques propuestos NBCF (ítems), NBCF (usuario) y NBCF (Híbrido) superan a los enfoques de línea base en términos de precisión de *ranking*. Se puede observar que los enfoques NMF y BNMF funcionan peor que NBCF pero mejor que el método bayesiano INBM.

En la figura 4.6 se muestra la Precisión y Recall, para estas métricas se utilizó el umbral de relevancia $\theta=4$ para discriminar si una recomendación es relevante o no. En esta figura podemos ver que BNMF provee una mejor Precisión

y Recall que los enfoques de CF probados. NBCF (Híbrido) logra una precisión de recomendación mayor que los métodos de líneas base considerados (excepto para los métodos BNMF y NMF). Además, NBCF (ítems) y NBCF (usuario) presentan una mejor precisión de recomendación que los métodos de línea base (GGM, INBM, Bi-CF).

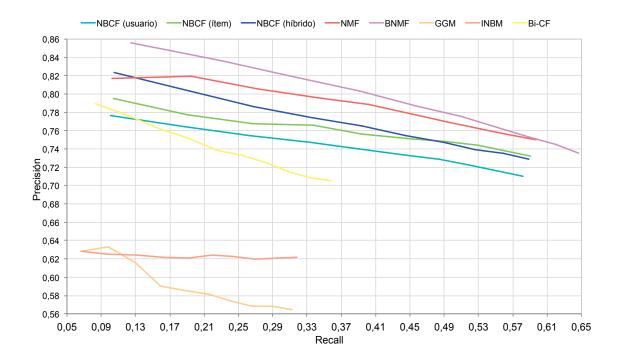


Figura 4.6: Precisión y Recall de cada método de recomendación para el conjunto de datos MovieLens

Analizando el desempeño de los tres enfoques propuestos, podemos concluir de las figuras 4.5 y 4.6 que el enfoque NBCF (híbrido) es mejor en la mayoría de las métricas calculadas, por ejemplo: en MAE, precisión y recall. Sin embargo, los resultados de nDCG muestran que NBCF (ítems) es mejor que los otros dos enfoques propuestos.

■ FilmTrust

La figura 4.7 contiene los resultados obtenidos con nDCG para el conjunto de datos FilmTrust. Se puede observar que los enfoques propuestos proveen valores

de nDCG más altos que los métodos de línea base utilizados.

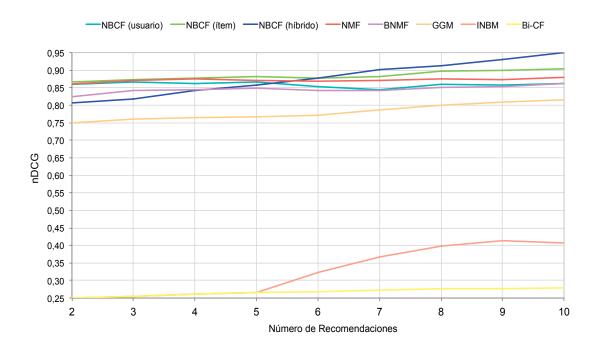


Figura 4.7: Ganancia acumulada descontada normalizada (nDCG) para el conjunto de datos FilmTrust

Al examinar la figura 4.7, NBCF (usuario) presenta un nDCG similar al método BNMF cuando el número de recomendaciones aumenta, y tiene un comportamiento similar al método NMF cuando el número de recomendaciones disminuye. INBM y Bi-CF muestran un nDCG peor que los otros métodos de CF del estado del arte.

La figura 4.8 muestra los valores de Precisión y Recall para este conjunto de datos. Estas medidas han sido probadas usando el umbral de relevancia $\theta = 3$, para discriminar si el voto de test es relevante o no.

En la figura 4.8 podemos observar que NBCF, NMF y BNMF proveen una mejor precisión y recall que otros enfoques de CF probados. Al analizar esta figura, observamos un comportamiento de Precisión y Recall equivalente al obtenido en nDCG, donde el comportamiento del enfoque propuesto NBCF muestra mejores resultados que los obtenidos con los métodos de líneas base de CF.

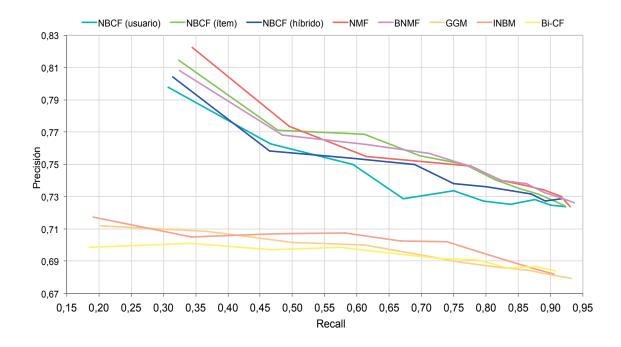


Figura 4.8: Precisión y Recall de cada método de recomendación para el conjunto de datos FilmTrust

Al comparar los tres enfoques propuestos con este conjunto de datos, se puede decir que: el MAE de NBCF (híbrido) logra mejores resultados que los otros dos enfoques propuestos, mientras que la precisión y recall son mejores con NBCF (ítems) y NBCF (usuario). Por otro lado, cuando aumenta el número de recomendaciones, nDCG es mejor con el enfoque NBCF (híbrido).

■ Yahoo

La figura 4.9 contiene los valores de nDCG para el conjunto de datos de Yahoo.

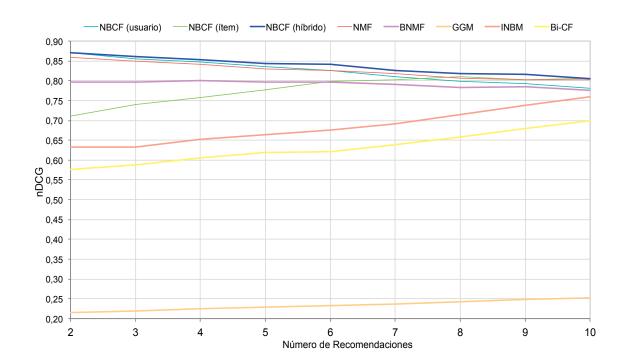


Figura 4.9: Ganancia acumulada descontada normalizada (nDCG) para el conjunto de datos Yahoo

Desde la figura figura 4.9 se puede observar que NBCF (usuario) y NBCF (híbrido) muestran un mejor desempeño en nDCG que los métodos de línea base seleccionados. El método GGM es el que peor desempeño presenta con este conjunto de datos. Esta figura también muestra que cuando el número de recomendaciones aumenta, NBCF (ítem) y NMF presentan un desempeño similar en nDCG en comparación a los otros métodos propuestos.

Los resultados en Precision y Recall se muestran en la figura 4.10. El valor de relevancia considerado es $\theta = 4$.

En la figura 4.10 se puede observar que NBCF, así como NMF, proporcionan una mejor precisión y recall que cualquier otro enfoque de CF probado.

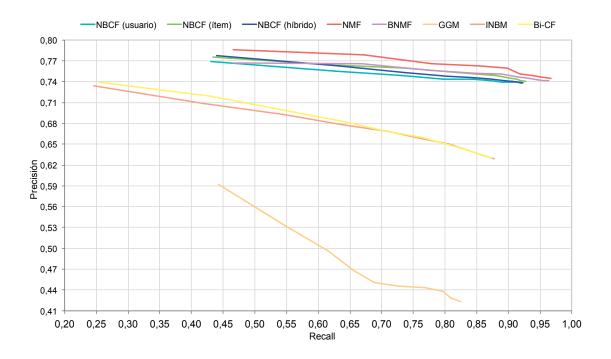


Figura 4.10: Precisión y Recall de cada método de recomendación para el conjunto de datos Yahoo

De manera similar, como se ve en la figura 4.10, nDCG es mejor en NBCF (Híbrido) en comparación con NBCF (ítem) y NBCF (usuario). Además, la precisión y el recall de los tres enfoques propuestos presentan un resultado casi similar entre ellos. Así mismo, hay una superioridad lograda en MAE de NBCF (híbrido) con respecto a los otros enfoques propuestos.

■ BookCrossing

La figura 4.11 contiene el nDCG para el conjunto de datos BookCrossing.

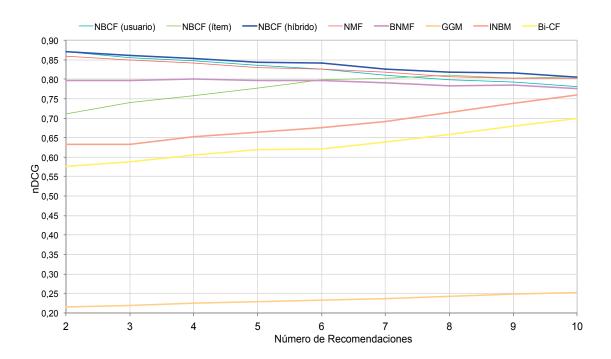


Figura 4.11: Ganancia acumulada descontada normalizada (nDCG) para el conjunto de datos BookCrossing

Desde la figura 4.11, podemos observar que NBCF (híbrido) y NBCF (ítem) proveen mejores resultados para nDCG en comparación con los métodos de línea base de CF. GGM presenta peores resultados que los otros métodos.

La figura 4.12 muestra los valores de Precisión y Recall para este conjunto de datos. La precisión y recall han sido probados utilizando el umbral de relevancia con un valor 8 ($\theta = 8$).

La figura 4.12 muestra que, a diferencia de otros conjuntos de datos en Book-Crossing las métricas de Precision y Recall son mejores para los métodos GGM, INBM y Bi-CF. Esto puede ser por dos razones:

- 1. En este conjunto de datos las predicciones van de 1-10, por tanto, para el clasificador ya es más difícil porque no tiene que clasificar 5 clases sino 10.
- 2. La dispersión (*sparsity*) en BookCrossing es más alta en comparación con los otros conjuntos de datos seleccionados (tabla 4.1). De acuerdo a la defi-

nición del método Gaussian-Gamma (sección 2.3.2), éste presenta un buen desempeño cuando el conjunto de datos es muy disperso, lo cual se corrobora con los resultados obtenidos. Así mismo, se puede concluir que el buen resultado obtenido con Bi-CF es porque este método emplea la técnica de biclustering, la cual actualmente está siendo muy utilizada para mejorar el problema de *sparsity* en CF (Chandralekha y cols., 2016). A pesar de que NBCF esté confundiendo entre las clases más altas lo cual es asumible, estamos acertando en las predicciones, además de acercarnos a una mayor capacidad de selección y a una mayor dispersión.

Por otro lado, los enfoques propuestos muestran una mejora en Precisión y Recall con respecto a los métodos BNMF y NMF, lo cual se cumple con la hipótesis planteada.

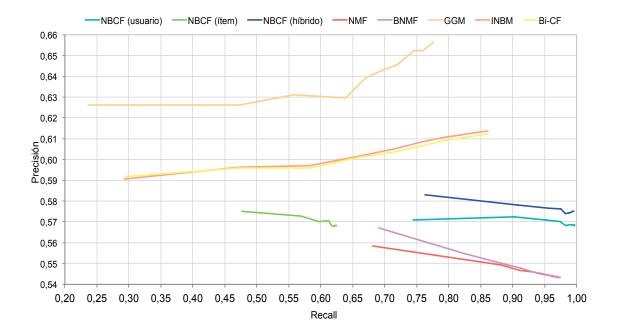


Figura 4.12: Precisión y Recall de cada método de recomendación para el conjunto de datos BookCrossing

Como en la mayoría de los conjuntos de datos, en la figura 4.12 NBCF (híbrido) logra una mejora particular en la precisión y recall en comparación con los enfoques NBCF (ítem) y NBCF (user).

Adicionalmente, comparando los tres enfoques propuestos, en la figura 4.11, podemos observar que cuando el número de recomendaciones es bajo, NBCF (híbrido) es mejor que los otros enfoques propuestos, mientras que cuando el número de recomendaciones es alto, NBCF (ítem) es mejor.

Los resultados experimentales muestran una mejora en nDCG utilizando NBCF para todos los conjuntos de datos presentes en la Tabla VI.

En resumen, al analizar las figuras 4.5 a 4.11, podemos establecer la superioridad de los enfoques propuestos sobre los métodos de línea base que utilizamos: Éstos proporcionan la mejor compensación entre nDCG y las medidas de precisión y recall.

4.5. Medida de confiabilidad

El método propuesto proporciona un valor de confiabilidad que representa la confianza del modelo en las predicciones que realiza. La figura 4.13 contiene el porcentaje de predicciones perfectas consideradas para un valor de confiabilidad fijo en los conjuntos de datos utilizados para NBCF (híbrido).

Podemos ver que, a medida que aumenta la confiabilidad, aumenta el porcentaje de predicciones perfectas (es decir, el porcentaje de predicciones con el error igual a cero). Cuando la fiabilidad es superior a 0,35, el 50 % de las predicciones son perfectas. Cuando la fiabilidad es superior a 0,55, el 70 % de las predicciones son perfectas. Este experimento demuestra que el valor de confiabilidad proporciona información adicional sobre las predicciones. Además, se proporciona a los usuarios información valiosa sobre la confiabilidad de las recomendaciones. Esperamos que si el sistema de recomendación recomienda un ítem a un usuario con una alta predicción, el usuario quede satisfecho con este ítem.

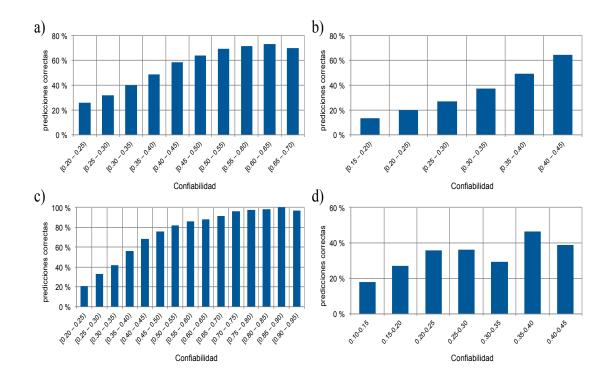


Figura 4.13: Confiabilidad de la recomendación en (a) conjunto de datos MovieLens, (b) conjunto de datos FilmTrust, (c) conjunto de datos Yahoo y (d) conjunto de datos BookCroosing.

4.6. Análisis de complejidad computacional

La complejidad computacional de un sistema de recomendación generalmente aumenta con el tamaño del conjunto de datos, y está dominada por la cantidad de usuarios y la cantidad de ítems (Koren y Bell, 2015).

De acuerdo a (Beel y cols., 2013) la complejidad computacional es importante para estimar la idoneidad a largo plazo de un algoritmo. Un algoritmo puede funcionar bien para unos pocos usuarios, pero puede que éste no se escale bien, por ello es necesario contar con algoritmos que además de ser escalables puedan ser aplicables en la práctica.

De esta manera, la complejidad computacional del algoritmo implementado para NBCF, es $O(U \cdot \overline{I} \cdot (\overline{I} + \overline{U}))$, donde \overline{U} y \overline{I} representan el número promedio de

usuarios que votaron un ítem y el número promedio de ítems que fueron votados por un usuario, respectivamente. Notar que $\overline{I} << I$ y $\overline{U} << U$ en el contexto de los problemas de CF.

NBCF tiene una complejidad computacional similar a los algoritmos de MF. Los métodos NMF (L. Zhang y cols., 2011) y BNMF (Hernando y cols., 2016) tienen una complejidad de $O(N \cdot K \cdot U \cdot \overline{I})$. Ambas complejidades computacionales comparten los términos U y \overline{I} , por lo que la diferencia se encuentra en la comparación de $N \cdot K$ con respecto a \overline{U} y \overline{I} . Por ejemplo, en el conjunto de datos MovieLens, $N=150,~k\approx 10,~\overline{U}\approx 260$ y $\overline{I}\approx 160$. En este caso, NBCF tendría una complejidad ligeramente menor que MF. En otros conjuntos de datos, puede ser que NBCF tenga una complejidad ligeramente mayor que MF. Basado en esto, podemos concluir que la complejidad computacional de NBCF y MF es aproximadamente la misma.

4.7. Discusión

El método propuesto de CF presenta algunas ventajas frente a los métodos del estado del arte, como la facilidad para interpretar sus resultados y explicar las recomendaciones. Sin embargo aún queda algunos puntos por analizar como la paralelización del algoritmo para mejorar su escalabilidad y estudiar la extensibilidad del modelo para trabajar con grupos de usuarios. Estas consideraciones son valiosas para investigaciones adicionales.

Una limitación de nuestro enfoque, así como el problema común de los sistemas de recomendación, es el problema de arranque en frío, donde no es posible recomendar aquellos ítems que nadie a votado aún, por ello extender el modelo incorporando información del contenido de los ítems que pueda ser utilizada para recomendar en base a similitudes entre las características de los ítems, es un punto abierto que puede ser cubierto en futuras investigaciones. De todas formas en esta propuesta se combina las ventajas de los enfoques basados en el usuario e ítems para minimizar los inconvenientes que estos métodos presentan de forma individual.

La mayoría de artículos publicados proponen soluciones basadas en memoria para la explicación de recomendaciones, por la simplicidad y facilidad que éstos ofrecen para interpretar sus resultados. Sin embargo los modelos probabilísticos proporcionan recomendaciones más exactas y brindan mayores ventajas que los enfoques basados en memoria y a los basados en factorización matricial (tabla 2.1). Por ello esta propuesta se centra en el desarrollo de un método que además de combinar enfoques basados en el usuario e ítems, permita la explicación de recomendaciones de una manera simple e intuitiva y que además de esto proporcione recomendaciones aceptables mediante la estimación de los votos que los ítems podrían tener.

Finalmente, según los resultados obtenidos con los conjuntos de datos utilizados en esta investigación (tabla 4.1), de los tres enfoques propuestos, NBCF (híbrido) es mejor que NBCF (ítems) y NBCF (usuario) en términos de MAE, y es mejor en nDCG para FilmTrust cuando aumenta el número de recomendaciones, con el conjunto de datos Yahoo NBCF (híbrido) muestra una mejora mínima que los otros métodos propuestos. Para BookCrossing, NBCF (híbrido) es mejor en nDCG cuando disminuye el número de recomendaciones. En términos de precisión y recall, NBCF (híbrido) logra mejores resultados en dos de los conjuntos de datos que utilizamos para comparar con los otros dos enfoques propuestos. Consecuentemente, como se mencionó con el método híbrido se mejoran los resultados que por cada método individual se podrían lograr.

Capítulo 5

Explicación de recomendaciones

Las explicaciones de recomendaciones proporcionan muchos beneficios, como: mejoran la satisfacción del usuario (Vig, Sen, y Riedl, 2008), generan mayor confianza del usuario (Tintarev, 2007), mejoran la eficacia y la capacidad de persuasión (Y. Zhang y cols., 2014), ayudan a los usuarios a tomar mejores decisiones (Tintarev y Masthoff, 2007), mejoran la experiencia del usuario (Tsai y Brusilovsky, 2019), entre otros. De esta manera, el desarrollo de modelos que no sólo generen recomendaciones de alta calidad sino que también provean recomendaciones intuitivas de sus resultados, pueden ayudar a mejorar la transparencia, confiabilidad y efectividad del sistema.

Las explicaciones son importantes para que el usuario conozca porque el sistema recomienda dichos ítems, es decir éstas revelan por qué al usuario le podrían gustar tales ítems (Vig y cols., 2008). Para algunos autores como (Tintarev y Masthoff, 2007) la explicación de recomendaciones hace que los usuarios encuentren lo que quieren más rápido y más fácil, y podría persuadirlos de que prueben o compren el ítem recomendado. Así mismo en (Svrcek, Kompan, y Bielikova, 2019), mencionan que proporcionar razones para las recomendaciones, ayuda a convencer al usuario para que use los ítems recomendados.

En los últimos años, se han propuesto una gran cantidad de enfoques de recomendación explicables, especialmente algoritmos de recomendación basados en modelos, en esta sección se presentan algunos de ellos.

5.1. Modelos de recomendación explicables

Algunos trabajos relacionados con la explicación de recomendaciones usando factorización matricial son el presentado por (Y. Zhang y cols., 2014), los cuales proponen un modelo de factor explícito (EFM, por sus siglas en inglés) para generar recomendaciones explicables. Los autores extraen las características explícitas del ítem y las opiniones de los usuarios mediante el análisis de sentimientos a nivel de frase en las revisiones de los usuarios, luego generan ambas recomendaciones de acuerdo con las características específicas del ítem de los intereses del usuario y las características ocultas aprendidas. Además, a partir del modelo se generan explicaciones intuitivas a nivel de característica acerca de por qué un ítem es o no recomendado.

Otros autores que basan la explicación de las recomendaciones en factorización matricial son (Rastegarpanah y cols., 2017), ellos generan esta explicación utilizando aproximaciones lineales del comportamiento del sistema de recomendación para cada usuario, y calculan las derivadas parciales de los votos previstos con respecto a los votos proporcionados por cada usuario.

De igual manera en (Abdollahi y Nasraoui, 2016), proponen una nueva técnica de factorización matricial explicativa que calcula una lista precisa de recomendaciones de top-n ítems que se pueden explicar. También introducen nuevas métricas de calidad de explicación, llamadas Precisión de Explicabilidad Media (MEP, por sus siglas en inglés) y Recall de Explicación Media (MER, por sus siglas en inglés).

Otro modelo de este tipo es el propuesto por (Hou, Yang, Wu, y Yu, 2019), ellos proponen un modelo de Factorización Matricial basado en Aspectos (AMF, por sus siglas en inglés), para mejorar la precisión de la predicción del voto al descomponer una matriz de votos con la información auxiliar extraída de los aspectos. Para evaluar cuantitativamente los aspectos, se propone dos métricas: Preferencia de aspecto del usuario (UAP, por sus siglas en inglés) y Calidad de aspecto del ítem (IAQ, por sus siglas en inglés), que cuantifican la preferencia del usuario a un aspecto específico y el sentimiento de revisión del ítem sobre un aspecto, respectivamente. Basados en esas métricas, ellos pueden explicar cuantitativamente por qué un usuario elige un ítem.

Aunque los modelos mencionados intentan explicar de alguna manera sus resultados basándose en representaciones aproximadas del comportamiento de los algoritmos de MF (Rastegarpanah y cols., 2017), proponiendo métricas que les permitan generar explicaciones de sus resultados, etc. éstos siguen presentando problemas en términos de factores latentes que resultan demasiado abstractos para explicar las recomendaciones.

Algunos modelos probabilísticos propuestos para explicar recomendaciones son BNMF (Hernando y cols., 2016), el cual se mencionó en apartados anteriores, en este modelo el espacio de factores latentes tiene un significado probabilístico fácilmente interpretable, debido a que la dispersión de los vectores de usuario permite comprender y justificar las predicciones del modelo.

En (Hanshi, Qiujie, Lizhen, y Wei, 2016) se propone un enfoque probabilístico basado en análisis de sentimientos de revisiones del usuario para dar explicaciones intuitivas de porqué un ítem es recomendado.

Un método híbrido de explicación personalizada de recomendaciones es presentado en (Svrcek y cols., 2019), el cual es independiente de la técnica de recomendación y combina estilos básicos de explicación para proporcionar una presentación adecuada y transparente de las explicaciones y recomendaciones.

Por otro lado, existen algunas formas de explicar las recomendaciones, por ejemplo en (Hernando, Bobadilla, Ortega, y Gutiérrez, 2013) se explica las recomendaciones empleando la visualización de árboles de ítems, brindando a los usuarios una manera rápida y atractiva de entender las recomendaciones.

En (X. Chen y cols., 2018) proponen recomendaciones explicables visualmente basadas en redes neuronales atentas para modelar la atención del usuario en imágenes, bajo la supervisión tanto de la retroalimentación implícita como de las revisiones textuales. Los autores proporcionan los resultados de las recomendaciones a los usuarios, y también les dicen a los usuarios por qué se recomienda un ítem.

Un sistema híbrido que incorpora una variedad de enfoques de recomendación (ejemplo: basados en contenido y CF), a través del cual se generan explicaciones híbridas que consisten en muchos estilos de explicación de recomendacones es

presentado en (Kouki, Schaffer, Pujara, O'Donovan, y Getoor, 2019), en este sistema cada estilo está asociado con un algoritmo de recomendación.

En (S. Chang, Harper, y Terveen, 2016) se generan explicaciones personalizadas en lenguaje natural con un enfoque de computación mixta, que combina crowdsourcing y algoritmos. Los autores modelaron aspectos tópicos clave de las películas, y pidieron a una multitud de trabajadores que escribieran explicaciones basadas en citas de reseñas de películas en línea y personalizaron las explicaciones presentadas a los usuarios en función de su historial del voto.

Así mismo, en (X. Wang y Chen, 2018) se crea un sistema para proporcionar explicaciones personalizadas de las recomendaciones, ellos desarrollaron un modelo de red neuronal recurrente que utiliza datos de evaluación de múltiples criterios para generar revisiones de texto.

En (Abdollahi y Nasraoui, 2018) se revisan algunos modelos que pueden proporcionar explicaciones para sus recomendaciones, además de algunas métricas de evaluación para evaluar el poder de la explicabilidad en los sistemas de recomendación.

Según (Bobadilla y cols., 2013), las recomendaciones generadas por RS deben explicarse de manera simple, convincente y precisa, ya que esto ayuda a mejorar la efectividad, la eficiencia, la capacidad de persuasión y la satisfacción del usuario de los sistemas de recomendación. De ahí que, los modelos probabilísticos proporcionan una mejor calidad de los resultados y también permiten explicar las recomendaciones. En la siguiente sección se muestra esta tarea con el método propuesto.

5.2. Explicación de recomendaciones con el método propuesto

El método propuesto permite explicar las predicciones, considerando que para cualquier predicción, es suficiente ver qué otros votos han influido más en esa predicción. Por ello, en esta sección se presenta primero el algoritmo a seguir para explicar una recomendación, luego se demuestra con un ejemplo real como es el funcionamiento de este proceso.

Para explicar una recomendación al usuario u (nosotros asumimos que esa recomendación le gustará a él), consideramos el caso en el cual el sistema ha recomendado el ítem i, con un voto estimado de $r_{u,i}$.

Teniendo en cuenta esta consideración, primero se presenta el algoritmo utilizado para explicar las recomendaciones con el enfoque basado en el usuario:

```
if el enfoque es "basado en el usuario" then
Ordene todos los ítems votados por el usuario u según su probabilidad dentro del ítem i de más alto a más bajo.
repeat
Extraer el primer ítem j de la lista
if el usuario u ha votado positivamente el ítem j then
Añadir el ítem j a las evidencias
end if
until tener P evidencias:
Justifique su recomendación con la siguiente sentencia:
"le gustará el ítem i porque le gustaron los ítems < complete con las evidencias P > "
end if
```

Algoritmo utilizado para el enfoque basado en ítems:

if el enfoque es "basado en ítems" then

Ordene todos los usuarios que hayan votado el ítem i según su probabilidad dentro del usuario u de mayor a menor

repeat

Extraer el primer usuario v de la lista

if el usuario v ha votado positivamente el ítem i then

Añadir el usuario v a las evidencias

end if

 \mathbf{until} hasta tener Q evidencias:

Justifique su recomendación con la siguiente sentencia:

"le gustará el ítem i porque le gustó a los usuarios < complete con las evidencias Q> que comparten intereses con usted"

end if

Finalmente, se presenta el algoritmo para explicar las recomendaciones con el enfoque híbrido, el cual combina los enfoques anteriores.

if el enfoque es "híbrido" then

Ambos enfoques anteriores se combinan ajustando los valores P y Q de acuerdo con las necesidades

Justifique su recomendación con la siguiente sentencia:

"le gustará el elemento i porque le gustaron los ítems < complete con las evidencias P> y éste le gustó a los usuarios < complete con las evidencias Q> que comparten intereses con usted"

end if

Ahora se presenta un ejemplo de la explicación de recomendaciones, considerando datos de películas del conjunto de datos MovieLens que serían recomendadas con el algoritmo NBCF. Para esto se considera una matriz de votos (tabla 5.1) de 9 usuarios y 14 películas y el caso en el que el sistema de recomendación ha recomendado el ítem ToyStory al usuario U_1 con un voto estimado.

| | Comedy | Comedy | Comedy | Sci-Fi | Horror | Animation | Animation | Animation | Horror | Sci-Fi | Sci-Fi | Sci-Fi | Horror |
|----|-----------|------------------|-----------------|--------|---------|-----------|------------|-------------------------------------------------------------|--------------------------------------------------|--------|---------|------------|-----------------------------|
| | Toy Story | Mounstruos SA | Finding Nemo | Powder | Species | Pinocchio | Aristocats | Wallace & Gromit: The Best of Aardman Animation | Robert A. Heinlein's The Puppet Masters | Brazil | Stalker | Metropolis | Hellbound: Hellraiser II |
| U1 | | 5 | 4 | 1 | 2 | 1 | | 2 | | | | | |
| U2 | 4 | 3 | 4 | 2 | 1 | | 1 | | | | | | |
| U3 | 2 | 4 | 5 | 2 | 3 | | | 1 | | | | | 3 |
| U4 | | | | | | 3 | 4 | 5 | 3 | | | | |
| U5 | | | | | | 4 | 4 | 4 | 3 | | 2 | | |
| U6 | | | 1 | 2 | 1 | 4 | 3 | 4 | 1 | | | | |
| U7 | | | 2 | | | | | | | 2 | 5 | 3 | 2 |
| U8 | | | 3 | | | | | | | 5 | 5 | 5 | 1 |
| U9 | 2 | | 2 | _ | | | | | | 5 | 5 | 5 | 2 |

Tabla 5.1: Matriz de votos

Enfoque basado en el usuario

Recordemos que en este enfoque el likelihood se calcula de acuerdo con los ítems votados por el usuario, por tanto es necesario identificar las películas que han sido votadas por el usuario U_1 , éstas se resaltan en color verde en la tabla que se muestra a continuación.

Tabla 5.2: Naïve Bayes based Collaborative Filtering - NBCF (usuario)

| | Comedy | Comedy | Comedy | Sci-Fi | Horror | Animation | Animation | Animation | Horror | Sci-Fi | Sci-Fi | Sci-Fi | Horror |
|----|----------------------|------------------|-----------------|--------|---------|-----------|------------|-------------------------------------------------------------|--------------------------------------------------|--------|---------|------------|-----------------------------|
| 1 | Toy Story | Mounstruos SA | Finding Nemo | Powder | Species | Pinocchio | Aristocats | Wallace & Gromit: The Best of Aardman Animation | Robert A. Heinlein's The Puppet Masters | Brazil | Stalker | Metropolis | Hellbound: Hellraiser II |
| U1 | | 5 | 4 | 1 | 2 | 1 | | 2 | | | | | |
| U2 | 4 | 3 | 4 | 2 | 1 | | 1 | | | | | | |
| U3 | 2 | 4 | 5 | 2 | 3 | | | 1 | | | | | 3 |
| U4 | | | | | | 3 | 4 | 5 | 3 | | | | |
| U5 | | | | | | 4 | 4 | 4 | 3 | | 2 | | |
| U6 | | | 1 | 2 | 1 | 4 | 3 | 4 | 1 | | | | |
| U7 | | | 2 | | | | | | | 2 | 5 | 3 | 2 |
| U8 | | | 3 | | | | | | | 5 | 5 | 5 | 1 |
| U9 | 2 | | 2 | | | | | | | 5 | 5 | 5 | 2 |
| F | P(r _i =y) | | | | | | | | | | | | |

De acuerdo al cálculo del *likelihood*, el orden de las películas es el siguiente: Mounstruos SA (0.2), Powder (0.2), Pinocchio (0.2), Finding Nemo (0.009619), Species (0.0095), Wallace Gromit: The Best of Aardman Animation (0.0095).

Luego, las evidencias estarían formadas por las películas que han sido votados positivamente por el usuario U1, en base a la matriz de votos éstas serían: Mounstruos SA, $Finding\ Nemo$. Por tanto se tiene la siguiente justificación:

Justificación de la recomendación

Usuario 1, le gustará la película *Toy Story*, porque le gustaron las películas *Mounstruos SA*, y *Finding Nemo*.

Enfoque basado en ítems

En este enfoque se considera los usuarios que han votado la película $Toy\ Story$ (ítem objetivo), éstos son: $U2,\ U3$ y U9.

Comedy Sci-Fi Animation Comedy Comedy Horror Animation Animation Horror Horror Wallace & Robert A. Heinlein's The Puppet Masters Hellbound: Hellraiser I Animation P(r_u=y) $P(r_v=k \mid r_u=y) \bigcup_{U3}^{U2}$ U Ш

Tabla 5.3: Naïve Bayes based Collaborative Filtering - NBCF (ítems)

De acuerdo al cálculo del *likelihood*, el orden de los usuarios que han votado la película *Toy Story*, según su probabilidad dentro del usuario U1, es el siguiente: $U9(0.2),\ U2(0.0095),\ U3\ (0.0048).$

Luego, las evidencias estarían formadas por los usuarios que han votado positivamente el ítem $Toy\ Story$, en base a la matriz de votos se tiene que el usuario U2 formaría parte de las evidencias.

Justificación de la recomendación

Usuario 1, le gustará la película $Toy\ Story$ porque le gustó al usuario U2 que comparte intereses con usted.

Enfoque híbrido

En este caso se combinan ambos enfoques (tabla 5.4), es decir que la justificación de la recomendación se forma considerando las evidencias del enfoque basado en el usuario y basado en ítem.

Comedy Sci-Fi Sci-Fi Sci-Fi Horror Wallace & Gromit: The Best of Aardman Animation Pinocchio Stalker U5 Enfoque híbrido $P(r_i=y)$ $P(r_j=k \mid r_i=y)$ Comedy Comedy Sci-Fi Horror Animation Animation Animation Horror Sci-Fi Wallace & Gromit: The Best of Aardman Animation Heinlein's The Puppe Masters $P(r_u=y)$ $P(r_v=k \mid r_u=y) = U_3$ TIS

Tabla 5.4: Naïve Bayes based Collaborative Filtering - NBCF (híbrido)

Justificación de la recomendación

Usuario
1, le gustará la película $Toy\ Story$ porque le gustaron las películas $Mounstruos\ SA,\ y\ Finding\ Nemo$ y esa película le gusto al usuario U2 que comparte intereses con usted.

Capítulo 6

Conclusiones y trabajo futuro

Este trabajo de investigación se ha centrado en analizar los diferentes enfoques basados en modelos para sistemas de recomendación de filtrado colaborativo y cómo facilitar la explicación de las recomendaciones mediante el desarrollo de un modelo bayesiano que provea recomendaciones tan buenas como los modelos basados en factorización matricial pero que a diferencia de éstos permita justificarlas.

Los resultados de la revisión de la literatura proporcionan una orientación útil para profesionales e investigadores en el área de los sistemas de recomendación. Basados en esta revisión se presentan algunos problemas relacionados con los enfoques de recomendación mayormente utilizados para el proceso de recomendación. Temas que se consideran relevantes por los desafíos que plantean a la hora de desarrollar sistemas recomendadores y por las innovaciones que suponen tendrían en los contextos que se utilicen.

De acuerdo al estudio realizado de los enfoques basados en modelos, los modelos probabilísticos presentan grandes ventajas frente a los basados en factorización matricial o basado en reglas, como la de ser flexibles en el modelado de diversos problemas y la facilidad que presentan para interpretar los resultados. En sistemas de recomendación éstos juegan un rol importante para la construcción de sistemas que además de ser escalables, las recomendaciones sean fáciles de explicar. El enfoque propuesto en esta investigación combina enfoques basados en el espacio de usuarios e ítems dentro de un solo modelo probabilístico que permite la explicación de las recomendaciones. Este modelo además hizo posible obtener valores de confiabilidad asociados con las predicciones.

El enfoque propuesto fue probado utilizando cuatro conjuntos de datos públicos y un gran conjunto de métodos de línea base de CF basados en modelos. Los resultados de los experimentos indican que NBCF obtiene mejores resultados de precisión, especialmente cuando el número de recomendaciones es bajo. El enfoque propuesto ofrece mejores características que los métodos de línea de base probados. Debido a que NBCF proporciona mejoras en sus resultados, éstos pueden ser adecuados para hacer comparaciones entre diferentes métodos y varios conjuntos de datos.

Los resultados también muestran la superioridad del enfoque propuesto con respecto a los métodos de línea base en nDCG. Del mismo modo, presenta mejoras significativas en la precisión de la predicción en dos de los conjuntos de datos probados. Consecuentemente, los resultados obtenidos con NBCF se consideran aceptables, ya que el modelo permite estimar el voto que podría tener un ítem.

El método propuesto se considera apropiado por las siguientes razones: a) sistemas de recomendación basado en técnicas bayesianas, b) sistema que proporciona resultados aceptables en cuanto a calidad de predicciones y recomendaciones, c) explicación de recomendaciones a los usuarios, debido a la superioridad de los modelos probabilísticos para explicar las recomendaciones frente a los modelos basados en factorización matricial. Los resultados confirman la hipótesis planteada tanto para los resultados de predicción como para los resultados de recomendación.

A partir de esto, algunas líneas de investigación resultan interesantes para mejorar los resultados experimentales presentados en este documento. De esta manera se proponen los siguientes trabajos futuros:

 Extender el método propuesto mediante la integración de información de atributos de los ítems o usuarios, de redes sociales, información contextual, etc. Esto se lograría modificando los cálculos de la probabilidad condicionada.

- Aplicar otras medidas de calidad como: novedad, diversidad, serendipity, etc.) para probar el enfoque propuesto.
- Extender el método propuesto para recomendaciones a grupos de usuarios.
 de tal forma que el modelo sea capaz de hacer recomendaciones tanto a grupos y a usuarios individuales.
- Estudiar la paralelización del algoritmo de NBCF para mejorar su escalabilidad.
- Comparar el enfoque propuesto con otros modelos probabilísticos de CF, que no hayan sido mencionados en este estudio y que sean de reciente publicación, considerando que éstos permitan la explicación de sus resultados.
- Estudiar el impacto del problema de cold-start en sistemas de recomendación de filtrado colaborativo, proponiendo mejoras al enfoque propuesto que puedan ayudar a aliviar este problema.
- Analizar otros tipos de modelos que aún no han sido bien explotados dentro de los sistemas de recomendación para CF, como los basados en reglas, para combinarlos con métodos probabilísticos bayesianos como el desarrollado en esta investigación.

- Abdollahi, B., y Nasraoui, O. (2016). Explainable Matrix Factorization for Collaborative Filtering. En *Proceedings of the 25th International Conference Companion on World Wide Web. WWW'16 Companion* (pp. 5–6). Montréal, Québec, Canada: ACM. doi: 10.1145/2872518.2889405
- Abdollahi, B., y Nasraoui, O. (2018). Transparency in fair machine learning: the case of explainable recommender systems. En J. Zhou y F. Chen (Eds.), Human and Machine Learning: Visible, Explainable, Trustworthy and Transparent (pp. 21–35). Cham: Springer International Publishing. doi: 10.1007/978-3-319-90403-0_2
- Adomavicius, G., y Tuzhilin, A. (2005). Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6), 734–749. doi: 10.1109/TKDE.2005.99
- Adomavicius, G., y Tuzhilin, A. (2011). Context-Aware Recommender Systems. En F. Ricci, L. Rokach, B. Shapira, y P. Kantor (Eds.), *Recommender Systems Handbook* (pp. 217 250). Boston, MA: Springer.
- Aghdam, M. H., Analoui, M., y Kabiri, P. (2015). A Novel Non-Negative Matrix Factorization Method for Recommender Systems. *Applied Mathematics & Information Sciences*, 2732(5), 2721–2732.
- Aguilar, J., Valdiviezo-Díaz, P., y Riofrio, G. (2016). A General Framework for Intelligent Recommender Systems. *Applied Computing and Informatics*, 13(2), 147–160. doi: 10.1016/j.aci.2016.08.002
- Ali, M., Ali, R., Khan, W. A., Han, S. C., Bang, J., Hur, T., ... Kang, B. H. (2018). A Data-Driven Knowledge Acquisition System: An End-to-End Knowledge Engineering Process for Generating Production Rules. *IEEE Access*, 6(May), 15587–15607. doi: 10.1109/ACCESS.2018.2817022

Alqadah, F., Reddy, C. K., Hu, J., y Alqadah, H. F. (2015). Biclustering neighborhood-based collaborative filtering method for top-n recommender systems. *Knowledge and Information Systems*, 44(2), 475–491. doi: 10.1007/s10115-014-0771-x

- Anderson, M., Ball, M., Boley, H., Greene, S., Howse, N., Lemire, D., y McGrath, S. (2003). RACOFI: A Rule-Applying Collaborative Filtering System. En Proceedings of the IEEE/WIC COLA 2003 (pp. 13–24). Halifax, Canada.
- Barber, D. (2012). Bayesian Reasoning and Machine Learning. Cambridge University Press. doi: 10.1055/s-0043-124183
- Barnard, T., y Prügel-Bennett, A. (2011). Experiments in Bayesian recommendation. En S. M. Mugellini E., Szczepaniak P.S., Pettenati M.C. (Ed.), Advances in Intelligent Web Mastering 3. Advances in Intelligent and Soft Computing (Vol. 86, pp. 39–48). Berlin, Heidelberg: Springer. doi: 10.1007/978-3-642-18029-3_5
- Beel, J., Langer, S., Genzmehr, M., Gipp, B., Breitinger, C., y Nürnberger, A. (2013). Research paper recommender system evaluation. Proceedings of the International Workshop on Reproducibility and Replication in Recommender Systems Evaluation RepSys '13 (April), 15–22. doi: 10.1145/2532508.2532512
- Blei, D. M., Ng, A. Y., y Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993–1022. doi: 10.1162/jmlr.2003.3.4-5.993
- Bobadilla, J., Bojorque, R., Hernando, A., y Hurtado, R. (2018). Recommender Systems Clustering using Bayesian non Negative Matrix Factorization. *IEEE Access*, 3536(c), 1–1. doi: 10.1109/ACCESS.2017.2788138
- Bobadilla, J., Gutiérrez, A., Ortega, F., y Zhu, B. (2018). Reliability quality measures for recommender systems. *Information Sciences*, 442-443, 145–157. doi: 10.1016/j.ins.2018.02.030
- Bobadilla, J., Ortega, F., Hernando, A., y Gutiérrez, A. (2013). Recommender systems survey. *Knowledge-Based Systems*, 46, 109–132. doi: 10.1016/j.knosys.2013.03.012
- Chandralekha, M., Saranya, K., y Sudha, G. (2016). Biclustering based Collaborative Filtering Algorithm for Personalized Web Service Recommendation. *International Journal of Computer Applications*, 142(7), 18–24. doi: 10.5120/ijca2016909871

Chang, S., Harper, F. M., y Terveen, L. G. (2016). Crowd-based personalized natural language explanations for recommendations. En *Proceedings of the 10th ACM Conference on Recommender Systems* (pp. 175–182). New York, NY, USA: ACM. doi: 10.1145/2959100.2959153

- Chang, T.-m., y Hsiao, W.-f. (2013). LDA-based Personalized Document. En *Proceedings of the pacis*.
- Charu, A. (2016). Recommender Systems: The Textbook (first edit ed.). Springer International Publishing. doi: 10.1007/978-3-319-29659-34
- Chen, G., Zhu, F., y Heng, P. A. (2018). Large-scale bayesian probabilistic matrix factorization with memo-free distributed variational inference. *ACM Transactions on Knowledge Discovery from Data (TKDD)*, 12(3), 31:1–31:24. doi: 10.1145/3161886
- Chen, L., Chen, G., y Wang, F. (2015). Recommender systems based on user reviews: the state of the art. *User Modeling and User Adapted Interaction*, 25(2), 99–154. doi: http://dx.doi.org/10.1007/s11257-015-9155-5
- Chen, M., y Liu, P. (2017). Performance Evaluation of Recommender Systems. International Journal of Performability Engineering, 13(8), 1246–1256. doi: 10.23940/ijpe.17.08.p7.12461256
- Chen, R., Hua, Q., Chang, Y. S., Wang, B., Zhang, L., y Kong, X. (2018). A survey of collaborative filtering-based recommender systems: from traditional methods to hybrid methods based on social networks. *IEEE Access*, 6(October), 64301–64320. doi: 10.1109/ACCESS.2018.2877208
- Chen, S.-M., Cheng, S.-H., y Lin, T.-E. (2015). Group decision making systems using group recommendations based on interval fuzzy preference relations and consistency matrices. *Information Sciences*, 298, 555–567. doi: 10.1016/J.INS.2014.11.027
- Chen, X., Zhang, Y., Xu, H., Cao, Y., Qin, Z., y Zha, H. (2018). Visually Explainable Recommendation. arXiv(February).
- Chlis, N. (2015). Machine Learning Methods for Genomic Signature Extraction (Tesis Doctoral, Technical University of Crete school of Electronic & Computer Engineering Digital signal & Image Processing Lab). doi: 10.13140/RG.2.1.1515.6324
- Cho, Y., Kim, J., y Kim, S. (2002). A personalized recommender system based on web usage mining and decision tree induction. *Expert Systems with Applications*, 44(23), 329–342. doi: https://doi.org/10.1016/

- S0957-4174(02)00052-0
- Devi, M. K. K., Samy, R. T., Kumar, S. V., y Venkatesh, P. (2010). Probabilistic neural network approach to alleviate sparsity and cold start problems in collaborative recommender systems. En 2010 IEEE International Conference on Computational Intelligence and Computing Research (p. 1-4). doi: 10.1109/ICCIC.2010.5705777
- Du, W., y Chen, J. (2013). The Bayesian network and trust model based movie recommendation system. Advances in Intelligent Systems and Computing, 180 AISC, 797–803. doi: 10.1007/978-3-642-31656-2_107
- Ekstrand, M., Riedl, J., y Konstan, J. (2011). Collaborative Filtering Recommender Systems. Foundations and Trends® in Human-Computer Interaction, 4(2), 81–173. doi: 10.1561/1100000009
- Fouss, F., Pirotte, A., Renders, J., y Saerens, M. (2007). Random-walk computation of similarities between nodes of a graph with application to collaborative recommendation. *IEEE Transactions on Knowledge and Data Engineering*, 19(3), 355-369. doi: 10.1109/TKDE.2007.46
- Gaikwad, R. S., Udmale, S. S., y Sambhe, V. K. (2018). E-commerce Recommendation System Using Improved Probabilistic Model. En Information and Communication Technology for Sustainable Development. Lecture Notes in Networks and Systems (pp. 277–284). Springer, Singapore. doi: 10.1007/978-981-10-3920-1_28
- Gandhi, M., y Gandhi, S. (2019). An enhanced approach for tourism recommendation system using hybrid filtering and association rule mining. *Asian Journal For Convergence in Technology (AJCT)*, 5(1).
- Golbandi, N., Koren, Y., y Lempel, R. (2011). Adaptive bootstrapping of recommender systems using decision trees. En Proceedings of the fourth ACM International Conference on Web Search and Data Mining WSDM '11 (p. 595-604). New York, New York, USA: ACM Press. doi: 10.1145/1935826.1935910
- Gupta, M., Kochhar, S., Jain, P., y Nagrath, P. (2019). Hybrid Recommender System Using A-priori Algorithm. En *Proceedings of International Conference on Sustainable Computing in Science, Technology and Management (SUSCOM)*. Jaipur India. doi: 10.2139/SSRN.3349290
- Hanshi, W., Qiujie, F., Lizhen, L., y Wei, S. (2016). A probabilistic rating prediction and explanation inference model for recommender systems. *China*

- Communications, 13(2), 79-94.
- Hassan, M., y Hamada, M. (2018). Genetic Algorithm Approaches for Improving Prediction Accuracy of Multi-criteria Recommender Systems. *International Journal of Computational Intelligence Systems*, 11(1), 146. doi: 10.2991/ijcis.11.1.12
- He, X., Liao, L., Zhang, H., Nie, L., Hu, X., y Chua, T.-S. (2017). Neural Collaborative Filtering. En *International World Wide Web Conference Committee*. Perth, Australia: ACM. doi: 10.1145/3038912.3052569
- Herlocker, J. L., Konstan, J. A., y Riedl, J. (2000). Explaining collaborative filtering recommendations. En Proceedings of the 2000 ACM Conference on Computer Supported Cooperative Work (pp. 241–250). New York, NY, USA: ACM. doi: 10.1145/358916.358995
- Herlocker, J. L., Konstan, J. a., Terveen, L. G., y Riedl, J. T. (2004). Evaluating collaborative filtering recommender systems. *ACM Transactions on Information Systems*, 22(1), 5–53. doi: 10.1145/963770.963772
- Hernández, J., Ramirez, M. J., y Ferri, C. (2004). *Introducción a la Minería de Datos* (1.ª ed.). Madrid, España: Pearson Prentice Hall.
- Hernando, A., Bobadilla, J., y Ortega, F. (2016). A non negative matrix factorization for collaborative filtering recommender systems based on a Bayesian probabilistic model. *Knowledge-Based Systems*, 97, 188–202. doi: 10.1016/j.knosys.2015.12.018
- Hernando, A., Bobadilla, J., Ortega, F., y Gutiérrez, A. (2013). Trees for explaining recommendations made through collaborative filtering. *Information Sciences*, 239, 1–17. doi: 10.1016/j.ins.2013.03.018
- Hernando, A., Bobadilla, J., Ortega, F., y Gutiérrez, A. (2017). A probabilistic model for recommending to new cold-start non-registered users. *Information Sciences*, 376, 216–232. doi: 10.1016/j.ins.2016.10.009
- Hernando, A., Bobadilla, J., Ortega, F., y Tejedor, J. (2013). Incorporating reliability measurements into the predictions of a recommender system. *Information Sciences*, 218, 1–16. doi: 10.1016/j.ins.2012.06.027
- Hou, Y., Yang, N., Wu, Y., y Yu, P. S. (2019). Explainable recommendation with fusion of aspect information. World Wide Web, 22, 221–240. doi: 10.1007/s11280-018-0558-1
- Hu, Y., Volinsky, C., y Koren, Y. (2008). Collaborative filtering for implicit feedback datasets. *Proceedings IEEE International Conference on Data*

- Mining, ICDM, 263–272. doi: 10.1109/ICDM.2008.22
- Huang, L., Tan, W., y Sun, Y. (2019). Collaborative recommendation algorithm based on probabilistic matrix factorization in probabilistic latent semantic analysis. *Multimed Tools Appl*, 78, 8711–8722. doi: 10.1007/s11042-018-6232-x
- Isinkaye, F., Folajimi, Y., y Ojokoh, B. (2015). Recommendation systems: Principles, methods and evaluation. *Egyptian Informatics Journal*, 16(3), 261–273. doi: 10.1016/J.EIJ.2015.06.005
- Iwata, T., y Takeuchi, K. (2015). Cross-domain recommendation without shared users or items. En Proceedings of the 18th International Conference on Artificial Intelligence and Statistics (AISTATS) (Vol. 38). San Diego, CA, USA.
- Jung, H. J., y Lease, M. (2012). Improving Quality of Crowdsourced Labels via Probabilistic Matrix Factorization. En *Proceedings of the 4th Human Computation Workshop (HCOMP) at AAAI* (pp. 101–106).
- Kant, S., y Mahara, T. (2018). Merging user and item based collaborative filtering to alleviate data sparsity. *International Journal of Systems Assurance Engi*neering and Management, 9(1), 173–179. doi: 10.1007/s13198-016-0500-9
- Koren, Y., y Bell, R. (2011). Advances in Collaborative Filtering. En F. Ricci, L. Rokach, B. Shapira, y P. Kantor (Eds.), *Recommender Systems Handbook* (pp. 145–186). Boston, MA: Springer. doi: 10.1007/978-0-387-85820-3
- Koren, Y., y Bell, R. (2015). Advances in collaborative filtering. En F. Ricci, L. Rokach, y B. Shapira (Eds.), Recommender Systems Handbook (pp. 77– 118). Boston, MA: Springer US. doi: 10.1007/978-1-4899-7637-6_3
- Koren, Y., Bell, R., y Volinsky, C. (2009). Matrix Factorization Techniques for Recommender Systems. *IEEE Computer Society*, 42(8), 42–49.
- Kouki, P., Schaffer, J., Pujara, J., O'Donovan, J., y Getoor, L. (2019). Personalized explanations for hybrid recommender systems. En *Proceedings of the 24th International Conference on Intelligent User Interfaces* (pp. 379–390). Marina del Ray, California: ACM. doi: 10.1145/3301275.3302306
- Kumar, N. P., y Fan, Z. (2015). Hybrid user-item based collaborative filtering. Procedia Computer Science, 60(1), 1453-1461. doi: 10.1016/j.procs.2015.08 .222
- Lenskiy, A. A., y Makita, E. (2017). Bayesian Approach to Users' Perspective on Movie Genres. *Journal of Information and Communication Convergence*

- Engineering, 15(1), 43-48.
- Li, K., Zhou, X., Lin, F., Zeng, W., y Alterovitz, G. (2019). Deep probabilistic matrix factorization framework for online collaborative filtering. *IEEE Access*, 7, 56117–56128. doi: 10.1109/ACCESS.2019.2900698
- Li, X., y Li, J. (2018). Health Risk Prediction Using Big Medical Data a Collaborative Filtering-Enhanced Deep Learning Approach. En 2018 IEEE 20th International Conference on e-Health Networking, Applications and Services (Healthcom). IEEE. doi: 10.1109/HealthCom.2018.8531143
- Liu, J., y Wang, D. (2017). PHD: A Probabilistic Model of Hybrid Deep Collaborative Filtering for Recommender Systems (Vol. 77; Inf. Téc.).
- Lops, P., Gemmis, M. D., y Semeraro, G. (2011). Recommender Systems Handbook (F. Ricci, L. Rokach, B. Shapira, y P. B. Kantor, Eds.). Boston, MA: Springer US. doi: 10.1007/978-0-387-85820-3
- Lu, J., Wu, D., Mao, M., Wang, W., y Zhang, G. (2015). Recommender System Application Developments: A Survey. *Decision Support Systems*, 74, 12–32. doi: http://dx.doi.org/10.1016/j.dss.2015.03.008
- Luo, C., Zhang, B., Xiang, Y., y Qi, M. (2017). Gaussian-Gamma collaborative filtering: A hierarchical Bayesian model for recommender systems. *Journal* of Computer and System Sciences, 102, 42–56. doi: 10.1016/j.jcss.2017.03 .007
- Ma, W., Wu, Y., Gong, M., Qin, C., y Wang, S. (2017). Local Probabilistic Matrix Factorization for Personal Recommendation. Proceedings - 13th International Conference on Computational Intelligence and Security, CIS 2017, 1, 97–101. doi: 10.1109/CIS.2017.00029
- Mohamed, M. H., Khafagy, M. H., y Ibrahim, M. H. (2019). Recommender Systems Challenges and Solutions Survey. *Proceedings of 2019 International Conference on Innovative Trends in Computer Engineering, ITCE 2019* (February), 149–155. doi: 10.1109/ITCE.2019.8646645
- Moradi, P., y Ahmadian, S. (2015). A reliability-based recommendation method to improve trust-aware recommender systems. *Expert Systems with Applications*, 42(21), 7386–7398. doi: 10.1016/j.eswa.2015.05.027
- Najafabadi, M. K., Mahrin, M. N., Chuprat, S., y Sarkan, H. M. (2017). Improving the accuracy of collaborative filtering recommendations using clustering and association rules mining on implicit data. *Computers in Human Behavior*, 67, 113–128. doi: 10.1016/j.chb.2016.11.010

Nguyen, T. B., y Takasu, A. (2017). A probabilistic model for the cold-start problem in rating prediction using click data. En E. Liu D., Xie S., Li Y., Zhao D., El-Alfy (Ed.), Lecture notes in computer science (including subseries lecture notes in artificial intelligence and lecture notes in bioinformatics) (Vol. 10638 LNCS, pp. 196–205). doi: 10.1007/978-3-319-70139-4-20

- Nilashi, M., bin Ibrahim, O., Ithnin, N., y Sarmin, N. H. (2015). A multi-criteria collaborative filtering recommender system for the tourism domain using Expectation Maximization (EM) and PCA-ANFIS. *Electronic Commerce Research and Applications*, 14(6), 542–562. doi: 10.1016/j.elerap.2015.08.004
- Ortega, F., Rojo, D., Valdiviezo-Díaz, P., y Raya, L. (2018). Hybrid Collaborative Filtering based on Users Rating Behavior. *IEEE Access*, 6, 69582 69591. doi: 10.1109/ACCESS.2017
- Ortega, F., Zhu, B., Bobadilla, J., y Hernando, A. (2018). CF4J: Collaborative Filtering for Java. *Knowledge-Based Systems*, 152, 94–99. doi: 10.1016/j.knosys.2018.04.008
- Paradarami, T. K., Bastian, N. D., y Wightman, J. L. (2017). A hybrid recommender system using artificial neural networks. *Expert Systems with Applications*, 83, 300–313. doi: 10.1016/j.eswa.2017.04.046
- Parambath, S. A. P. (2013). *Matrix Factorization Methods for Recommender Systems* (Master). Umeå University.
- Park, D. H., Kim, H. K., Choi, I. Y., y Kim, J. K. (2012). A literature review and classification of recommender systems research. *Expert Systems with Applications*, 39(11), 10059–10072. doi: 10.1016/j.eswa.2012.02.038
- Parvin, H., Moradi, P., Esmaeili, S., y Qader, N. N. (2019). A scalable and robust trust-based nonnegative matrix factorization recommender using the alternating direction method. *Knowledge-Based Systems*. doi: 10.1016/j.knosys.2018.12.016
- Pazzani, M. J. (2000). oku-A Framework for Collaborative, Content-Based and Demographic Filtering. *Artificial Intelligence Review*, 13, 393–408. doi: 10.1023/A:1006544522159
- Rastegarpanah, B., Crovella, M., y Gummadi, K. P. (2017). Exploring Explanations for Matrix Factorization Recommender Systems. En *Proceedings* of the FATREC 2017 Workshop on Responsible Recommendation. doi: 10.18122/B2R717

Rawat, B., y Dwivedi, S. K. (2019). Selecting Appropriate Metrics for Evaluation of Recommender Systems. *International Journal of Information Technology and Computer Science*, 11(1), 14–23. doi: 10.5815/ijitcs.2019.01.02

- Ricci, F., Rokach, L., y Shapira, B. (2015). Recommender Systems Handbook (Vol. 32) (n.º 2). doi: 10.1016/0002-9343(62)90176-6
- Ricci, F., Rokach, L., Shapira, B., y Kantor, P. B. (2011). Recommender Systems Handbook (F. Ricci, L. Rokach, B. Shapira, y P. B. Kantor, Eds.). Boston, MA: Springer US. doi: 10.1007/978-0-387-85820-3
- Salakhutdinov, R., y Mnih, A. (2007). Probabilistic matrix factorization. En Proceedings of the 20th International Conference on Neural Information Processing Systems (pp. 1257–1264). USA: Curran Associates Inc.
- Shengbo, G. (2011). Bayesian Recommender Systems: Models and Algorithms (Tesis Doctoral no publicada). Australian National University.
- Su, X., y Khoshgoftaar, T. M. (2009). A Survey of Collaborative Filtering Techniques. Advances in Artificial Intelligence, 2009, 19. doi: 10.1155/ 2009/421425
- Sun, W., Zhang, X., Liang, W., y He, Z. (2015). High Dimensional Explicit Feature Biased Matrix Factorization Recommendation. En *Trends and Applications in Knowledge Discovery and Data Mining* (pp. 66–77). Springer, Cham. doi: 10.1007/978-3-319-25660-3_6
- Svrcek, M., Kompan, M., y Bielikova, M. (2019). Towards understandable personalized recommendations: Hybrid explanations. *Computer Science and Information Systems*, 16(1), 179–203. doi: 10.2298/CSIS171217012S
- Tang, K., Chen, S., Liu, Z., y Khattak, A. J. (2018). A tensor-based Bayesian probabilistic model for citywide personalized travel time estimation. Transportation Research Part C: Emerging Technologies, 90, 260–280. doi: 10.1016/J.TRC.2018.03.004
- Tao, Y., Jia, Y., Wang, N., y Wang, H. (2019). The fact: Taming latent factor models for explainability with factorization trees. En Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval, SIGIR 2019, Paris, France, july 21-25, 2019. (pp. 295–304). doi: 10.1145/3331184.3331244
- Tintarev, N. (2007). Explanations of Recommendations. En Recsys 2007 Proceedings of the 2007 ACM Conference on Recommender Systems (pp. 203–206). New York, NY, USA: ACM.

Tintarev, N., y Masthoff, J. (2007). Effective Explanations of Recommendations: User-Centered Design. En *Proceedings of the 2007 ACM Conference on Recommender Systems*, RecSys '07 (pp. 153–156).

- Tiwari, S. K., y Potter, H. (2015). An Approach for Recommender System by Combining Collaborative Filtering with User Demographics and Items Genres. *International Journal of Computer Applications*, 128(13), 16–24.
- Tsai, C.-H., y Brusilovsky, P. (2019). Explaining recommendations in an interactive hybrid social recommender. En *Proceedings of the 24th international conference on intelligent user interfaces* (pp. 391–396). New York, NY, USA: ACM. doi: 10.1145/3301275.3302318
- Valdiviezo, P., y Hernando, A. (2016). A Comprehensive View of Recommendation Methods based on Probabilistic Techniques. En A. Rocha, L. Reis, M. Cota, R. Goncalves, y O. Suarez (Eds.), *Iberian Conference on Information Systems and Technologies, CISTI* (pp. 604–609). Gran Canaria, Spain: IEEE Computer Society. doi: 10.1109/CISTI.2016.7521413
- Valdiviezo-Díaz, P., y Bobadilla, J. (2018). A hybrid approach of recommendation via extended matrix based on collaborative filtering with demographics information. En *International Conference on Technology Trends, CITT 2018* (pp. 384–398).
- Valdiviezo-Diaz, P., Ortega, F., Cobos, E., y Lara-Cabrera, R. (2019). A Collaborative Filtering Approach Based on Naïve Bayes Classifier. *IEEE Access*, 7, 108581–108592. doi: 10.1109/access.2019.2933048
- Vig, J., Sen, S., y Riedl, J. (2008). Tagsplanations: Explaining Recommendations
 Using Tags. Proceedings of the 13th International Conference on Intelligent
 User Interfaces IUI '09. doi: 10.1145/1502650.1502661
- Wang, C., y Blei, D. M. (2011). Collaborative Topic Modeling for Recommending Scientific Articles. En 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 448–456). ACM.
- Wang, K., y Tan, Y. (2011). A New Collaborative Filtering Recommendation Approach Based on Naive Bayesian Method. En W. G. Tan Y., Shi Y., Chai Y. (Ed.), Advances in Swarm Intelligence. ICSI 2011. Lecture Notes in Computer Science (Vol. 6729, pp. 160–167). Springer, Berlin, Heidelberg. doi: 10.1007/978-3-642-38703-6
- Wang, K., Zhao, W. X., Peng, H., y Wang, X. (2016). Bayesian probabilistic multi-topic matrix factorization for rating prediction. *IJCAI International*

- Joint Conference on Artificial Intelligence, 2016-January, 3910–3916.
- Wang, T., Rudin, C., Doshi-Velez, F., Liu, Y., Jones, E., Klampfl, E., ... Gupta, M. (2017). A Bayesian Framework for Learning Rule Sets for Interpretable Classification. *Journal of Machine Learning Research*, 18, 1–37. doi: 10.1109/ICRA.2013.6630888
- Wang, X., y Chen, Y. (2018). A Reinforcement Learning Framework for Explainable Recommendation. En *IEEE International Conference on Data Mining* (pp. 587–596). EEE. doi: 10.1109/ICDM.2018.00074
- Wang, X., He, X., Feng, F., Nie, L., y Chua, T.-S. (2018). TEM: Tree-enhanced Embedding Model for Explainable Recommendation. En *Proceedings of the 2018 World Wide Web Conference on World Wide Web WWW '18* (pp. 1543–1552). doi: 10.1145/3178876.3186066
- Wang, Y., Wang, L., Li, Y., He, D., y Chen, W. (2013). A Theoretical Analysis of NDCG Type Ranking Measures. En 26th Annual Conference on Learning Theory (pp. 25–54). NJ, USA: Princeton University.
- Weimer, M., Karatzoglou, A., Viet Le, Q., y Smola, A. (2007). COFI RANK Maximum Margin Matrix Factorization for Collaborative Ranking. Advances in neural information processing systems 20. En 21th Annual Conference on Neural Information Processing Systems (pp. 1593–1600). Vancouver, British Columbia, Canada.
- Wen, S., Wang, C., Li, H., y Wen, S. (2018). Naïve Bayes regression model and its application in collaborative filtering recommendation algorithm. *International Journal Internet Manufacturing and Services*, 5(1), 85–99.
- Wen, Z. (2008). Recommendation System Based on Collaborative Filtering. En Cs229 Lecture Notes. Stanford University.
- Weng, Y., Wu, L., y Hong, W. (2018). Bayesian Inference via Variational Approximation for Collaborative Filtering. *Neural Processing Letters*. doi: 10.1007/s11063-018-9841-5
- Wu, Y., Huang, M., y Lu, Y. (2017). Association rules and collaborative filtering on sparse data of a leading online retailer. En 2017 IEEE International Conference on Industrial Engineering and Engineering Management (IEEM) (pp. 794–798). IEEE. doi: 10.1109/IEEM.2017.8290000
- Yang, Z., Wu, B., Zheng, K., Wang, X., y Lei, L. (2016). A survey of collaborative filtering-based recommender systems for mobile internet applications. *IEEE Access*, 4, 3273–3287. doi: 10.1109/ACCESS.2016.2573314

Zafari, F., y Moser, I. (2017). Modelling socially-influenced conditional preferences over feature values in recommender systems based on factorised collaborative filtering. *Expert Systems with Applications*, 87, 98–117. doi: 10.1016/j.eswa.2017.05.058

- Zhang, H., Nikolov, N. S., y Ganchev, I. (2017). Exploiting User Feedbacks in Matrix Factorization for Recommender Systems. En *Proceedings of the 7th International Conference on Model and Data Engineering, MEDI 2017* (Vol. 10563, pp. 235–247). doi: 10.1007/978-3-319-66854-3
- Zhang, L., Chen, Z., Zheng, M., y He, X. (2011). Robust non-negative matrix factorization. Frontiers of Electrical and Electronic Engineering in China, 6(2), 192–200. doi: 10.1007/s11460-011-0128-0
- Zhang, S., Wang, W., Ford, J., y Makedon, F. (2013). Learning from Incomplete Ratings Using Non-negative Matrix Factorization. En Sixth SIAM International Conference on Data Mining (pp. 549–553). doi: 10.1137/1.9781611972764.58
- Zhang, Y., Lai, G., Zhang, M., Zhang, Y., Liu, Y., y Ma, S. (2014). Explicit factor models for explainable recommendation based on phrase-level sentiment analysis. En *Proceedings of the 37th International ACM SI-GIR Conference on Research & Development in Information Retrieval.* SIGIR'14 (pp. 83–92). Gold Coast, Queensland, Australia: ACM. doi: 10.1145/2600428.2609579
- Zhao, C., Sun, S., Han, L., y Peng, Q. (2016). Hybrid matrix factorization for recommender systems in social networks. *Neural Network World*, 26(6), 559–569. doi: 10.14311/NNW.2016.26.032
- Zhu, B. (2018). Towards reliability in collaborative filtering recommender systems (Tesis Doctoral, Universidad Politécnica de Madrid). doi: https://doi.org/10.20868/UPM.thesis.54719
- Zhu, B., Hurtado, R., Bobadilla, J., y Ortega, F. (2018). An efficient recommender system method based on the numerical relevances and the non-numerical structures of the ratings. *IEEE Access*, 6, 49935–49954. doi: 10.1109/ ACCESS.2018.2868464
- Zhu, B., Ortega, F., Bobadilla, J., y Gutiérrez, A. (2018). Assigning reliability values to recommendations using matrix factorization. *Journal of Computational Science*, 26, 165–177. doi: 10.1016/j.jocs.2018.04.009