

Hibridación de técnicas de Sistemas de Recomendación. Ventajas del enfoque probabilístico en comparación con la factorización matricial. Implementación del algoritmo Naive Bayes Collaborative Filtering y su expansión para realizar recomendaciones a grupos de usuarios.

Daniel Machado Pérez
Osvaldo R. Moreno Prieto
Daniel Toledo Martínez

Facultad de Matemática y Computación, Universidad de La Habana, Cuba.
<https://github.com/DanielMPMatCom/SRI-Project.git>

Resumen El presente trabajo explora la hibridación de técnicas en sistemas de recomendación, centrándose en las ventajas del enfoque probabilístico frente a la factorización matricial en cuanto a filtrado colaborativo. Se destaca cómo el enfoque probabilístico, al proporcionar una representación explícita de las incertidumbres, mejora la interpretabilidad y explicación de las recomendaciones generadas. En particular, se implementa el algoritmo *Naive Bayes Collaborative Filtering* (NBCF), que combina la simplicidad del modelo *Naive Bayes* con el poder del filtrado colaborativo, permitiendo recomendaciones precisas y explicativas. Además, se expande este algoritmo para adaptarse a la recomendación a grupos de usuarios, abordando un área clave en la personalización colectiva de contenidos. Los resultados demuestran que el enfoque probabilístico no solo ofrece una alternativa robusta a la factorización matricial, sino que también potencia la capacidad del sistema para ofrecer recomendaciones personalizadas y comprensibles, tanto a individuos como a grupos.

Palabras clave: Sistemas de Recomendación (RS), Filtrado Colaborativo (CF), Enfoque Probabilístico, Factorización Matricial, *Naive Bayes Collaborative Filtering* (NBCF), *Naive Pooling* (NBP).

Abstract This work explores the hybridization of techniques in recommendation systems, focusing on the advantages of the probabilistic approach over matrix factorization in collaborative filtering. It highlights how the probabilistic approach, by providing an explicit representation of uncertainties, improves the interpretability and explanation of the generated recommendations. In particular, the Naive Bayes Collaborative Filtering (NBCF) algorithm is implemented, combining the simplicity of

the Naive Bayes model with the power of collaborative filtering, allowing for precise and explanatory recommendations. Additionally, this algorithm is expanded to adapt to group recommendations, addressing a key area in the collective personalization of content. The results demonstrate that the probabilistic approach not only offers a robust alternative to matrix factorization but also enhances the system's ability to deliver personalized and understandable recommendations to both individuals and groups.

1. Introducción

En la era de la información, el acceso a grandes volúmenes de datos ha transformado la manera en que los usuarios interactúan con los contenidos en línea. Plataformas como servicios de *streaming*, comercio electrónico, redes sociales y sitios de reseñas, enfrentan el desafío de presentar información relevante de manera eficiente y personalizada. Ante este reto, los sistemas de recomendación han emergido como una herramienta clave para filtrar y personalizar las interacciones de los usuarios, facilitando la identificación de productos, servicios o contenidos acordes a sus preferencias.

A lo largo de los años, diversas técnicas de recomendación han sido desarrolladas y perfeccionadas para abordar este problema, desde enfoques clásicos como el filtrado colaborativo, hasta métodos más sofisticados que combinan varios enfoques en un esquema híbrido. En este contexto, el presente trabajo explora un área crítica dentro de los sistemas de recomendación: la hibridación de técnicas, con un enfoque especial en la comparación entre la factorización matricial y los modelos probabilísticos aplicados al filtrado colaborativo.

Este informe también extiende la aplicación del algoritmo *Naive Bayes Collaborative Filtering* (NBCF) para abordar un aspecto poco explorado en la literatura: la recomendación grupal, un desafío clave en la personalización colectiva de contenidos. A continuación, se describe en detalle el contexto de la investigación, así como las principales técnicas y métodos utilizados.

1.1. Descripción del tema y Técnicas de Recomendación

Los sistemas de recomendación tienen como objetivo filtrar grandes volúmenes de información y presentar a los usuarios elementos relevantes según sus preferencias. Entre las técnicas de recomendación más utilizadas, se destacan el filtrado colaborativo, el filtrado basado en contenido, el filtrado demográfico y los enfoques híbridos que combinan estos métodos.

El filtrado colaborativo, en particular, ha sido ampliamente adoptado debido a su capacidad para identificar patrones de comportamiento entre usuarios y ofrecer recomendaciones basadas en similitudes en sus interacciones previas. Este enfoque se puede implementar mediante técnicas basadas en memoria, que

utilizan directamente las interacciones pasadas de los usuarios, o mediante técnicas basadas en modelos, que crean representaciones abstractas de las relaciones entre usuarios e ítems.

1.2. Enfoques de Filtrado Colaborativo Basado en Modelos

Dentro del filtrado colaborativo basado en modelos, dos enfoques destacan por su eficacia y popularidad: la factorización matricial y los modelos probabilísticos. La factorización matricial, como lo demuestra el algoritmo de descomposición en valores singulares (SVD), es una técnica poderosa para descomponer la matriz de interacciones usuario-ítem en factores latentes, permitiendo predicciones precisas de las preferencias de los usuarios. No obstante, su principal limitación radica en la falta de interpretabilidad de los factores latentes, lo que dificulta la explicación de las recomendaciones generadas.

En contraste, los modelos probabilísticos, como el *Naive Bayes Collaborative Filtering* (NBCF), ofrecen una alternativa que, si bien puede alcanzar niveles de precisión similares a los de la factorización matricial, presenta la ventaja adicional de proporcionar interpretaciones más claras de las recomendaciones. El enfoque probabilístico permite modelar explícitamente la incertidumbre en las preferencias de los usuarios, lo que facilita la explicación del porqué de cada recomendación.

1.3. Antecedentes y Justificación

La elección del enfoque probabilístico como base de esta investigación se sustenta en los hallazgos presentados en la tesis doctoral titulada “Sistema recomendador híbrido basado en modelos probabilísticos”. Esta tesis profundiza en las ventajas de utilizar modelos probabilísticos en sistemas de recomendación, destacando su capacidad para superar las limitaciones de los enfoques tradicionales de factorización matricial. Además, se presenta una implementación del algoritmo NBCF, que ha mostrado resultados prometedores en términos de precisión y explicabilidad.

Sin embargo, un área poco explorada en esta tesis es la capacidad de estos modelos para realizar recomendaciones a grupos de usuarios, una característica esencial en contextos como la recomendación de contenido para familias, grupos de amigos o equipos de trabajo. Esta investigación se propone expandir el algoritmo NBCF, siguiendo las recomendaciones de la tesis doctoral, para adaptarlo a la recomendación grupal, un desafío significativo en la personalización colectiva.

Para extender el algoritmo NBCF a la recomendación de grupos, se adoptará la idea del *Naive Pooling* (NBP) propuesta en el artículo “*Extended Naïve Bayes for Group Based Classification*” [5]. El método NBP utiliza las probabilidades calculadas (en nuestro caso las ya con NBCF) y las combina de manera que se

maximice la probabilidad conjunta para un grupo de usuarios, permitiendo así una clasificación efectiva de grupos con una alta coherencia en las recomendaciones. Este enfoque se considera particularmente adecuado para garantizar que todos los miembros del grupo reciban recomendaciones que reflejen tanto las preferencias individuales como las del colectivo.

1.4. Dataset Seleccionado

Para la evaluación de la implementación y expansión del algoritmo NBCF, se ha seleccionado el dataset FilmTrust[6], un conjunto de datos ampliamente utilizado en la investigación de sistemas de recomendación. FilmTrust contiene miles de calificaciones de películas proporcionadas por usuarios, lo que lo convierte en un recurso valioso para el análisis y desarrollo de modelos de recomendación. La riqueza y diversidad del dataset permiten probar la eficacia de los algoritmos en un entorno cercano a escenarios del mundo real. Este dataset fue uno de los utilizados en la tesis antes mencionada.

1.5. Estructura del Trabajo

El presente informe se estructura en varias secciones que desarrollan en detalle los diferentes aspectos de la investigación:

- **Estado del Arte:** Se revisa la literatura existente sobre técnicas de recomendación, con un enfoque en el filtrado colaborativo basado en modelos.
- **Algoritmo NBCF:** Se describe la implementación del algoritmo NBCF y su funcionamiento.
- **Expansión del Algoritmo NBCF:** Se presenta la adaptación del NBCF para realizar recomendaciones a grupos de usuarios, detallando las modificaciones realizadas.
- **Evaluación de los Resultados:** Se analizan los resultados obtenidos tras la implementación y se comparan con enfoques tradicionales.
- **Conclusiones:** Se resumen los hallazgos más relevantes de la investigación y se sugieren posibles direcciones futuras.

2. Estado del Arte

Los sistemas de recomendación se han vuelto indispensables en la era de la información, donde los usuarios requieren herramientas que les permitan descubrir contenidos relevantes de manera eficiente. Existen diversas técnicas para abordar este problema, cada una con sus propias ventajas y limitaciones. Entre las más destacadas están el filtrado colaborativo, el filtrado basado en contenido, el filtrado demográfico y los enfoques híbridos. En esta sección, se revisarán las principales técnicas de recomendación, con un enfoque particular en el filtrado colaborativo y sus variantes basadas en modelos probabilísticos.

2.1. Técnicas de Recomendación

- **Filtrado Colaborativo:** Este enfoque se basa en la idea de que los usuarios que han compartido preferencias similares en el pasado probablemente coincidan en sus elecciones futuras. El filtrado colaborativo puede implementarse a través de dos métodos: basado en memoria y basado en modelos. Los enfoques basados en memoria, como el algoritmo de k vecinos más cercanos (k -NN), utilizan directamente la matriz de interacciones usuario-ítem para realizar recomendaciones. Por otro lado, los enfoques basados en modelos, que incluyen técnicas como la factorización matricial y los modelos probabilísticos, construyen un modelo predictivo a partir de los datos disponibles, ofreciendo recomendaciones más precisas y escalables. [2]
- **Filtrado Basado en Contenido:** Este método recomienda ítems a un usuario en función de la similitud entre los ítems que ha consumido previamente y otros ítems disponibles. A diferencia del filtrado colaborativo, se basa en las características de los ítems, como el género, el director o los actores en el caso de películas. [2]
- **Filtrado Demográfico:** Aunque menos utilizado en comparación con los métodos anteriores, el filtrado demográfico se basa en las características personales de los usuarios, tales como su edad, género o ubicación. Este enfoque supone que usuarios con características demográficas similares tienden a compartir preferencias similares. Si bien puede ser útil para ciertos contextos, su efectividad suele ser menor, ya que no tiene en cuenta las interacciones individuales entre usuarios e ítems. [2]
- **Enfoques Híbridos:** Estos combinan dos o más de las técnicas mencionadas para mejorar la precisión y superar las limitaciones inherentes a cada uno de los métodos. Por ejemplo, un sistema híbrido puede combinar el filtrado colaborativo con el filtrado basado en contenido para ofrecer recomendaciones más completas, tanto en precisión como en diversidad. [2]

2.2. Filtrado Colaborativo Basado en Modelos

El filtrado colaborativo basado en modelos ha demostrado ser especialmente eficaz en sistemas de recomendación a gran escala. Entre los enfoques más destacados se encuentran la factorización matricial y los modelos probabilísticos.

- **Factorización Matricial:** Esta técnica ha demostrado ser una de las más efectivas para el filtrado colaborativo. En la factorización matricial, la matriz de interacciones usuario-ítem se descompone en dos matrices de menor dimensión que representan factores latentes tanto para los usuarios como para los ítems. Estos factores latentes permiten realizar predicciones sobre las preferencias de los usuarios al capturar características no observadas explícitamente. Aunque la factorización matricial, especialmente con algoritmos como la descomposición en valores singulares (SVD), ha demostrado ser muy precisa, su principal limitación radica en la falta de interpretabilidad. Los factores latentes no siempre son comprensibles o intuitivos para los usuarios, lo que dificulta la explicación de las recomendaciones. [4]

- **Modelos Probabilísticos:** En contraste con la factorización matricial, los modelos probabilísticos proporcionan una representación más clara de las incertidumbres en las preferencias de los usuarios. Uno de los enfoques más representativos es el *Naive Bayes Collaborative Filtering* (NBCF), que combina la simplicidad del modelo de *Naive Bayes* con la estructura del filtrado colaborativo. Este enfoque permite una mayor interpretabilidad, ya que ofrece una explicación probabilística de las recomendaciones. Además, el NBCF ha mostrado ser altamente adaptable a diferentes escenarios, permitiendo la incorporación de nuevas variables sin comprometer su eficiencia. [4]

2.3. Desarrollo en las Tesis y Papers

El enfoque probabilístico ha sido objeto de un estudio detallado en la tesis doctoral titulada “Sistema recomendador híbrido basado en modelos probabilísticos” [4]. En esta tesis, se aborda la integración de modelos probabilísticos dentro de sistemas de recomendación híbridos, destacando cómo estos modelos no solo permiten una mayor precisión, sino que también aportan una capa de interpretabilidad que los métodos de factorización matricial no ofrecen. El autor propone un enfoque híbrido que combina los beneficios del filtrado colaborativo basado en modelos probabilísticos con técnicas de filtrado basado en contenido.

En el paper titulado “*Extended Naïve Bayes for Group Based Classification*” [5], los autores presentan una extensión del clásico modelo *Naive Bayes*, adaptándolo para su aplicación en la clasificación basada en grupos. Uno de los enfoques tratados, denominado *Naive Pooling* (NBP), se centra en la agregación de probabilidades individuales para generar una probabilidad conjunta que permita la clasificación efectiva de grupos de usuarios. La metodología propuesta combina las probabilidades individuales de cada miembro del grupo para maximizar la coherencia y relevancia de la clasificación final. Este método resulta particularmente útil en contextos donde se deben generar recomendaciones o decisiones que reflejen tanto las preferencias individuales como la dinámica grupal. La capacidad de NBP para mantener la simplicidad del modelo *Naive Bayes*, al tiempo que amplía su aplicabilidad a escenarios grupales, lo convierte en una herramienta poderosa para la personalización colectiva en sistemas de recomendación.

Además, en el paper “*A Collaborative Filtering Approach Based on Naive Bayes Classifier*” [1], se profundiza en la implementación del NBCF y se demuestra su viabilidad como alternativa a los métodos tradicionales de filtrado colaborativo. Los resultados obtenidos en este estudio muestran que el NBCF puede igualar o superar el rendimiento de la factorización matricial, especialmente en datasets donde la interpretabilidad es tan importante como la precisión.

Finalmente, el trabajo “*Hybrid Collaborative Filtering Based on Users’ Rating Behavior*” [3] presenta un enfoque híbrido que integra el comportamiento de valoración de los usuarios con el filtrado colaborativo. Este enfoque tiene una relevancia particular para nuestro proyecto, ya que permite ajustar las recomendaciones no solo en función de las interacciones pasadas, sino también

considerando la manera en que los usuarios valoran los ítems, lo que aporta una capa adicional de personalización.

3. Algoritmo NBCF

3.1. Introducción al Algoritmo NBCF

El algoritmo *Naive Bayes Collaborative Filtering* (NBCF) es una técnica innovadora dentro del campo de los sistemas de recomendación colaborativos. A diferencia de otros enfoques, como la factorización matricial, el NBCF aprovecha la simplicidad y efectividad del clasificador *Naive Bayes* para predecir las preferencias de los usuarios en función de sus interacciones anteriores con ítems. Este método considera la probabilidad de que un usuario asigne una cierta calificación a un ítem, basándose en las calificaciones previas tanto del usuario como de otros usuarios con comportamientos similares.

3.2. Formulación Matemática del Algoritmo NBCF

El algoritmo NBCF se basa en la combinación de dos enfoques principales: basado en usuarios y basado en ítems. En cada uno de estos enfoques, se calcula la probabilidad a priori de que un usuario califique un ítem con un valor específico, y posteriormente se calcula el *likelihood* para ajustar esta probabilidad en función de las calificaciones observadas.

- **Enfoque basado en el usuario:** la probabilidad a priori y el *likelihood* se calculan de acuerdo con los ítems que cada usuario ha votado. [4]
- **Enfoque basado en ítems:** la probabilidad a priori y el *likelihood* se calculan de acuerdo con los votos que cada ítem ha recibido. [4]
- **Enfoque híbrido:** integra los enfoques basados en el usuario e ítems, a fin de complementarse uno con otro y mejorar la precisión del modelo. [4]

Para el desarrollo de cada uno de estos enfoques se utiliza los siguientes conceptos de probabilidades:

- **Probabilidad A Priori:** En el enfoque basado en ítems, se calcula la probabilidad a priori de que un usuario u asigne una calificación y a un ítem i , denotado como $P(r_u = y)$. De manera análoga, en el enfoque basado en usuarios, se calcula la probabilidad de que un ítem i reciba una calificación y de cualquier usuario u , denotado como $P(r_i = y)$.

$$P(r_i = y) = \frac{|\{u \in U | r_{u,i} = y\}| + \alpha}{|\{u \in U | r_{u,i} \neq \bullet\}| + |R| * \alpha} \quad (1)$$

[4]

Donde:

- U es el conjunto de usuarios.

- $r_{u,i}$ es la calificación otorgada por el usuario u al ítem i .
 - α es un parámetro para evitar 0 probabilidades.
 - $|R|$ representa el número de votos plausibles.
 - \bullet representa la ausencia de voto.
- **Likelihood:** El *likelihood* ajusta la probabilidad a priori mediante la consideración de la información adicional disponible en las calificaciones observadas. Para el enfoque basado en ítems, esto se expresa como $P(r_v = k | r_u = y)$, que representa la probabilidad de que otro usuario v califique con k un ítem que ha sido calificado con y por el usuario u . Similarmente, para el enfoque basado en usuarios, se calcula el *likelihood* correspondiente $P(r_j = k | r_i = y)$.

$$P(r_j = k | r_i = y) = \frac{|\{u \in U | r_{u,j} = k \wedge r_{u,i} = y\}| + \alpha}{|\{u \in U | r_{u,j} \neq \bullet \wedge r_{u,i} = y\}| + |R| * \alpha} \quad (2)$$

[4]

- **Combinación de Enfoques:** En el enfoque híbrido, se integran las probabilidades obtenidas de los enfoques basados en usuarios y en ítems, proporcionando un modelo más robusto y preciso para la predicción de calificaciones. $P(r_{u,i} = y)$ representa el valor de probabilidad de que el usuario u vote el ítem i con el voto y :

$$P(r_{u,i} = y) \propto \left(P(r_u = y) \cdot \prod_{v \in U_i} P(r_v = r_{v,i} | r_u = y) \right)^{\frac{1}{1+|U_i|}} \cdot \left(P(r_i = y) \cdot \prod_{j \in I_u} P(r_j = r_{u,j} | r_i = y) \right)^{\frac{1}{1+|I_u|}} \quad (3)$$

[4]

Donde:

- $I_u = \{i \in I \mid r_{u,i} \neq \bullet\}$ es el conjunto de ítems votados por el usuario u ,
- y $U_i = \{u \in U \mid r_{u,i} \neq \bullet\}$ es el conjunto de usuarios que han votado el ítem i .

3.3. Algoritmo NBCF: Implementación Paso a Paso

El algoritmo NBCF se implementa de manera iterativa, asegurando la eficiencia computacional mediante técnicas de memorización que permiten evitar el recálculo innecesario de probabilidades. A continuación se describen los pasos del algoritmo:

- **Inicialización:** Se inicializan las probabilidades a priori y los contadores utilizados en el cálculo de *likelihoods*.
- **Iteración sobre Usuarios e Ítems:** Para cada usuario, se calcula la probabilidad de cada calificación posible basada en las calificaciones observadas para los ítems que ha evaluado. De manera similar, se calcula para cada ítem la probabilidad de recibir una calificación específica basada en las calificaciones anteriores recibidas.
- **Almacenamiento de Resultados:** Los valores calculados se almacenan para ser utilizados posteriormente en la predicción de nuevas calificaciones, evitando la necesidad de recalcular durante la fase de predicción.

Este enfoque garantiza que el NBCF no solo sea eficiente, sino que también se adapte bien a problemas de gran escala, manteniendo una complejidad computacional similar a la de otros métodos avanzados, como la factorización matricial [4].

3.4. Resultados Experimentales y Comparativa

El algoritmo NBCF ha demostrado su eficacia en múltiples conjuntos de datos públicos (MovieLens, FilmTrust, Yahoo, BookCrossing)[4], superando en varias métricas clave a los métodos de referencia más utilizados en el campo:

- Error Medio Absoluto (MAE) [4]
- Precisión y *Recall* [4]
- Ganancia acumulada descontada normalizada (nDCG) [4]

Se compararon los siguientes enfoques:

- NBCF (usuario)
- NBCF (ítem)
- NBCF (híbrido)
- BNMF
- GGM
- INBM
- Bi-CF
- NMF

Los resultados fueron los siguientes:

- **MovieLens:** El enfoque híbrido de NBCF ha mostrado mejoras significativas en medidas de MAE, precisión y *recall*, así como el enfoque basado en ítems fue mejor en la nDCG en comparación con enfoques tradicionales.[4]
- **FilTrust:** el MAE de NBCF (híbrido) logra mejores resultados que los otros dos enfoques propuestos, mientras que la precisión y *recall* son mejores con NBCF (ítems) y NBCF (usuario). Por otro lado, cuando aumenta el número de recomendaciones, nDCG es mejor con el enfoque NBCF (híbrido).[4]
- **Yahoo:** nDCG es mejor en NBCF (híbrido) en comparación con NBCF (ítem) y NBCF (usuario). Además, la precisión y el *recall* de los tres enfoques propuestos presentan un resultado casi similar entre ellos. Así mismo, hay una superioridad lograda en MAE de NBCF (híbrido) con respecto a los otros enfoques propuestos.[4]
- **BookCrossing:** NBCF (híbrido) y NBCF (ítem) proveen mejores resultados para nDCG en comparación con los métodos de línea base de CF. A diferencia de otros conjuntos de datos en BookCrossing las métricas de precisión y *recall* son mejores para los métodos GGM, INBM y Bi-CF. Sin embargo muestran una mejora con respecto a los métodos BNMF y NMF. NBCF (híbrido) se muestra superior al resto de los enfoques en cuanto al MAE.[4]

3.5. Conclusión

El algoritmo NBCF representa una mejora significativa en el ámbito de los sistemas de recomendación colaborativos, combinando la simplicidad del clasificador *Naive Bayes* con técnicas de filtrado colaborativo para ofrecer recomendaciones precisas y eficaces. Su capacidad para integrar múltiples enfoques y adaptarse a diferentes escenarios lo convierte en una herramienta valiosa para la mejora de la experiencia del usuario en plataformas de recomendación.

4. Expansión del Algoritmo NBCF

4.1. Algoritmo NBP. Formulación Matemática

En los sistemas de recomendación modernos, la capacidad de realizar recomendaciones efectivas no solo a usuarios individuales, sino también a grupos, se ha vuelto un aspecto crucial. Contextos como la recomendación de contenido para familias, equipos de trabajo o grupos de amigos demandan un enfoque que pueda considerar y equilibrar las preferencias individuales dentro de un colectivo, maximizando la satisfacción general del grupo. En respuesta a esta necesidad, surge el algoritmo NBP, una extensión del modelo clásico de *Naive Bayes* adaptado específicamente para la clasificación y recomendación a grupos de usuarios.

El algoritmo se fundamenta en la misma premisa básica que el *Naive Bayes*, es decir, la independencia condicional de las características dadas las clases. Sin embargo, lo que distingue a NBP es su capacidad para combinar las probabilidades individuales de los miembros de un grupo, produciendo una probabilidad conjunta que guía la recomendación o clasificación final para todo el grupo.

Matemáticamente, la probabilidad conjunta para un grupo G de n usuarios con respecto a una clase C_l se puede expresar como:

$$P(C_l) = \frac{\prod_{k=1}^n P(C_l|x_k)}{\prod_{k=1}^n P(c_l|x_k) + \prod_{k=1}^n (1 - P(c_l|x_k))} \quad (4)$$

[5]

Donde:

- x_k es un usuario del grupo G ,
- $P(C_l|x_k)$ es la probabilidad de la clase C_l dada para el usuario individual x_k .

El algoritmo NBP maximiza esta probabilidad conjunta, seleccionando la clase C_l que mayor valor obtenga, lo que se traduce en una recomendación para el grupo que refleje un consenso entre las preferencias individuales.

4.2. Ventajas y Desventajas de NBP

El algoritmo Naive Pooling presenta varias ventajas notables:

- **Simplicidad y Eficiencia:** Al estar basado en el modelo *Naive Bayes*, NBP hereda la simplicidad computacional y la eficiencia del mismo, lo que permite su implementación en sistemas a gran escala sin requerir un costo computacional elevado.
- **Interpretabilidad:** Una de las fortalezas del enfoque probabilístico es su capacidad para proporcionar una explicación clara de las recomendaciones basadas en probabilidades. Esto facilita la interpretación de por qué un grupo recibió una recomendación específica.
- **Adaptabilidad:** NBP es altamente adaptable y puede integrarse con facilidad en sistemas de recomendación existentes que ya utilicen el enfoque *Naive Bayes* para recomendaciones individuales. Esto permite a los desarrolladores extender sus sistemas a la recomendación grupal sin necesidad de una reingeniería significativa.

A pesar de sus ventajas, el algoritmo NBP también presenta algunas limitaciones que deben ser consideradas:

- **Suposición de Independencia:** Al igual que *Naive Bayes*, NBP asume que las preferencias de los usuarios dentro del grupo son condicionalmente independientes, lo cual puede no reflejar adecuadamente la realidad, donde las preferencias de los usuarios pueden estar correlacionadas.
- **Equidad en la Recomendación:** NBP no tiene en cuenta explícitamente la equidad entre las preferencias individuales dentro del grupo. Es decir, podría favorecer las preferencias de algunos usuarios sobre otros, especialmente si las probabilidades individuales de ciertos miembros del grupo son mucho más altas que las de los demás.
- **Escalabilidad con Grupos Grandes:** Aunque eficiente, a medida que el tamaño del grupo aumenta, la combinación de probabilidades puede llevar a situaciones donde las recomendaciones sean dominadas por usuarios con preferencias extremas, lo que podría reducir la diversidad y la satisfacción global del grupo.

4.3. Aplicación del Algoritmo NBP en la Expansión de NBCF

En el contexto de esta investigación, el algoritmo *Naive Pooling* se integrará con el modelo *Naive Bayes Collaborative Filtering* (NBCF). Teniendo previamente calculados los valores de las probabilidades para cada usuario con NBCF, ya sea con su enfoque basado en usuario, basado en ítems o híbrido, se puede efectuar la fórmula de NBP y obtener el resultado que se quiere. De esta forma, se extiende la funcionalidad del NBCF para proporcionar recomendaciones no solo a individuos, sino también a grupos de usuarios, conservando la precisión y explicabilidad del enfoque probabilístico. Esta expansión permitirá que el sistema no solo mantenga la calidad en las recomendaciones individuales, sino que también pueda satisfacer las necesidades de colectivos en situaciones donde la personalización grupal es esencial.

5. Evaluación de los resultados

En esta sección se presentará la evaluación del rendimiento de la expansión del algoritmo NBCF para la recomendación a grupos utilizando el algoritmo NBP. Para ello, se ha seleccionado el dataset *FilmTrust* por sus características particulares y su amplio uso en investigaciones de sistemas de recomendación.

5.1. Descripción del dataset *FilmTrust*

El dataset *FilmTrust* contiene información sobre la interacción de usuarios con películas, lo cual lo convierte en un recurso valioso para el análisis de sistemas de recomendación. Sus características principales son las siguientes:

- **1508 usuarios:** Cada usuario ha evaluado uno o varios ítems (películas) del conjunto.
- **2071 ítems:** El conjunto de ítems representa las películas que los usuarios han visto y valorado.
- **35494 votos:** Los usuarios han emitido un total de 35,494 calificaciones sobre las películas del conjunto.
- **Escala de votación:** Las calificaciones originales varían entre 0.5 y 4, con incrementos de 0.5. Para simplificar la indexación y el procesamiento en la implementación del sistema, se ha multiplicado la escala por 2, de modo que las calificaciones oscilan entre 1 y 8, con incrementos de 1. Esto permite una mayor precisión y facilidad a la hora de manejar los datos.
- **Dispersión del dataset:** El valor de dispersión (*sparsity*) de este conjunto es del 98.86 %. Esto significa que la mayoría de las posibles combinaciones entre usuarios e ítems no tienen una calificación registrada, lo que introduce un desafío significativo para el modelo de recomendación. La *sparsity* es una medida que refleja el nivel de dispersión de los datos en una matriz de interacciones usuario-ítem, donde un valor elevado indica que muchas de las posiciones en la matriz están vacías, es decir, no contienen interacciones registradas. Este fenómeno es común en sistemas de recomendación, y requiere el uso de modelos capaces de manejar eficazmente la falta de datos.

5.2. Diseño del test

Dado que no se encontró un dataset disponible que incluyera información sobre recomendaciones realizadas a grupos de usuarios, surgió la necesidad de diseñar un test propio que permitiera evaluar la efectividad del método propuesto para recomendaciones grupales. El enfoque adoptado utiliza el conjunto de datos de *FilmTrust*, donde se ha adaptado la estructura del dataset para generar grupos de usuarios con características comunes.

Confección de los grupos de usuarios A partir de cada película en el dataset, se forma un grupo compuesto por todos los usuarios que le han asignado la misma calificación. Este proceso garantiza que los grupos compartan una opinión similar sobre el ítem en cuestión, lo que es relevante para medir la coherencia del sistema de recomendación en entornos colaborativos. Una vez conformados los grupos iniciales, de cada uno se selecciona aleatoriamente un subconjunto de usuarios, que constituirá uno de los grupos finales sobre los que se realizarán las evaluaciones.

En particular, se pone énfasis en la evaluación de la eficacia del método para grupos que hayan otorgado altas calificaciones a las películas (valores de 6, 7 u 8 en la escala de votos) y bajas calificaciones (1, 2, 3). Esto permite analizar el rendimiento del algoritmo en escenarios donde existe un fuerte consenso positivo entre los usuarios, lo que representa un caso de uso frecuente en las recomendaciones de contenido audiovisual para grupos de amigos o familiares. Es válido señalar que de esta forma de armar los grupos, pueden existir intersecciones entre ellos, lo cual se ajusta a los escenarios reales y no provoca dificultades para el desempeño del método propuesto. La semilla para replicar los experimentos fue 42.

Procedimiento Una vez conformados los grupos de usuarios que han calificado de manera idéntica una película en particular, se procede a eliminar la información de los votos emitidos por esos usuarios hacia dicha película. Este paso es fundamental para simular un escenario en el que los miembros del grupo no han visto la película, lo cual nos permite evaluar la capacidad del sistema de realizar recomendaciones grupales efectivas.

Es importante destacar que la razón de la selección de subconjuntos de usuarios de los grupos iniciales es evitar la pérdida completa de la información relacionada con los votos de la película. De esta manera, se conserva parte de la información del ítem en cuestión, lo que nos permite continuar utilizando el resto de las interacciones de los usuarios con otras películas en el proceso de recomendación.

El objetivo de este procedimiento es evaluar si, bajo la suposición de que los usuarios del grupo no han visto la película, el sistema es capaz de predecir una calificación grupal similar a la calificación inicial. Dado que los miembros del grupo han otorgado una calificación uniforme a la película antes de eliminar esta información, se espera que el sistema de recomendación prediga un voto grupal consistente con las valoraciones originales. Además, al aplicar este procedimiento a películas que recibieron calificaciones altas (6, 7 u 8), se puede evaluar la capacidad del modelo para recomendar este tipo de películas en escenarios donde los usuarios no las hayan visto. De la misma forma al comprobar el rendimiento con las bajas calificaciones (1, 2, 3) se analiza su efectividad para no recomendar películas que no serían bien calificadas por los integrantes del grupo.

Resultados con votaciones altas (6, 7, 8)

Diferencias

En la Figura 1, se muestran las diferencias entre las recomendaciones sugeridas por el sistema y las expectativas del usuario. Este gráfico permite identificar las desviaciones del sistema con respecto a las preferencias reales, lo que ofrece una visión clara de las áreas donde se puede mejorar la precisión de las recomendaciones.




Figura 1. Gráfico de diferencias entre las recomendaciones del sistema y las preferencias reales del usuario. Calificaciones 6, 7, 8.

El análisis de estas diferencias sugiere que, si bien el sistema tiende a alinearse con las preferencias de los usuarios en un número considerable de casos, persisten desviaciones en ciertos grupos.

Diferencias absolutas

La Figura 2 muestra las diferencias absolutas, es decir, el valor absoluto de la desviación entre las recomendaciones sugeridas y las expectativas del usuario. Esta representación visual permite observar cuán grandes son las desviaciones sin tener en cuenta la dirección (positiva o negativa) de la diferencia.

Lo observado permite concluir que el sistema, en general, ofrece recomendaciones razonablemente precisas en la mayoría de los casos.

Tabla de Resultados

En la Tabla 3 se presenta un resumen cuantitativo de los resultados. Se muestran las predicciones, valores reales, diferencias y diferencias absolutas para 25 grupos confeccionados y las películas seleccionadas. Los resultados completos pueden verse en el archivo **Grupos678.xlsx** en la ruta **report/assets/** a partir del directorio raíz del repositorio de GitHub.

Otras métricas:

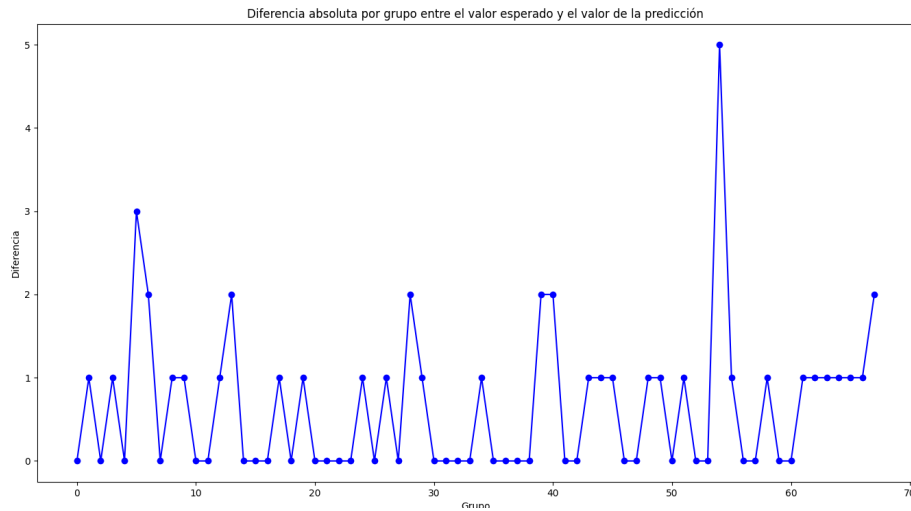


Figura 2. Gráfico de diferencias absolutas entre las recomendaciones del sistema y las preferencias del usuario. Calificaciones 6, 7, 8.

- **MSE (Error Cuadrático Medio): 0.657:** Este valor indica el promedio de los errores al cuadrado entre las predicciones del sistema y los valores reales. El MSE es sensible a errores grandes, ya que estos se amplifican al ser elevados al cuadrado. Un valor de 0.657 implica que, en promedio, las diferencias entre las recomendaciones del sistema y las preferencias reales de los usuarios son moderadamente bajas. Sin embargo, aún existen algunos errores significativos que deben ser corregidos para mejorar la precisión del sistema de recomendación. [4]
- **MAE (Error Medio Absoluto): 0.486:** Esta métrica refleja el error medio absoluto entre las predicciones y los valores reales, lo cual ofrece una interpretación más intuitiva de la precisión del modelo. En este caso, el valor de 0.486 indica que, en promedio, la desviación entre la predicción y las preferencias reales de los usuarios es de aproximadamente 0.49 unidades. Este valor es más fácil de interpretar que el MSE, y nos muestra que las predicciones del sistema son razonablemente precisas, aunque pueden ser perfeccionadas. [4]

Resultados con votaciones altas (1, 2, 3)

Diferencias

En la Figura 4, se muestran las diferencias entre las recomendaciones sugeridas por el sistema y las expectativas del usuario al analizar las películas con calificaciones bajas (1, 2, 3).

El análisis indica que el método manifiesta un rendimiento no tan bueno a la hora de predecir las calificaciones de estas películas, pues en los experimentos

Grupo	Película	Esperado	Recibido	Diferencia	Diferencia absoluta
0	1	8	8	0	0
1	2	7	5	2	2
2	4	8	8	0	0
3	6	7	7	0	0
4	9	8	6	2	2
5	10	8	8	0	0
6	11	8	7	1	1
7	16	6	6	0	0
8	0	6	6	0	0
9	204	6	8	-2	2
10	16	7	8	-1	1
11	214	7	8	-1	1
12	215	8	8	0	0
13	214	8	8	0	0
14	218	7	7	0	0
15	1	7	8	-1	1
16	3	8	8	0	0
17	205	8	8	0	0
18	12	8	8	0	0
19	210	8	8	0	0
20	235	8	8	0	0
21	10	6	8	-2	2
22	11	6	6	0	0
23	206	8	8	0	0
24	218	6	7	-1	1

Figura 3. Resumen cuantitativo de los resultados del sistema de recomendación. Calificaciones 6, 7, 8.

siempre predijo valores superiores a los reales. Sin embargo se observa que en algunos casos las diferencias son pequeñas.

Diferencias absolutas

La Figura 5 muestra las diferencias absolutas, que como en este caso todas las diferencias son negativas, se comporta como mismo la gráfica 4

Tabla de Resultados

La Tabla 6 muestra el resumen cuantitativo de los resultados para este conjunto de calificaciones. Los resultados completos pueden verse en el archivo **Grupos123.xlsx** en la ruta **report/assets/** a partir del directorio raíz del repositorio de GitHub.

Otras métricas:

- **MSE (Error Cuadrático Medio): 9.222:** Este valor elevado del MSE indica que el sistema de recomendación está generando errores significativos al comparar las predicciones con los valores reales. Dado que el MSE eleva al cuadrado las diferencias entre los valores predichos y los valores reales, un valor de 9.222 refleja la presencia de desviaciones grandes en las predicciones. Este resultado es preocupante, ya que significa que, en algunos casos, el

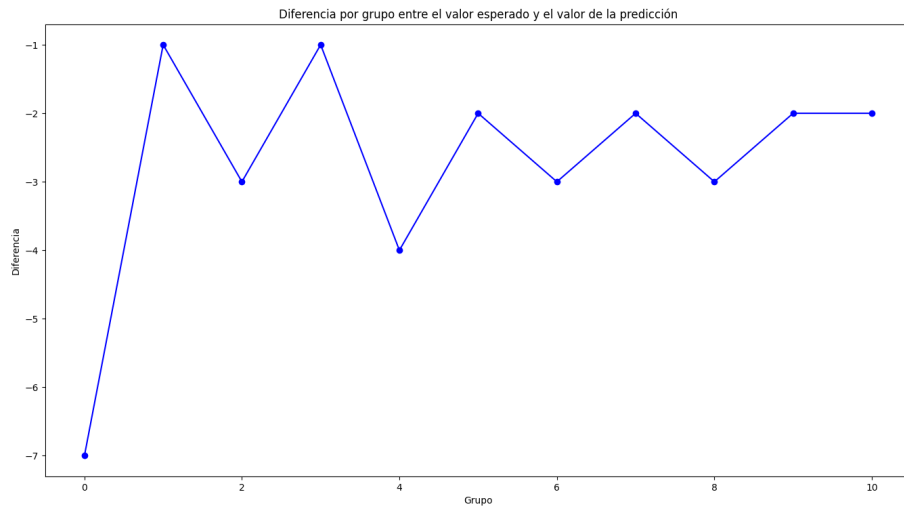


Figura 4. Gráfico de diferencias entre las recomendaciones del sistema y las preferencias reales del usuario. Calificaciones 1, 2, 3.

sistema está haciendo predicciones muy alejadas de lo que realmente deberían ser.

- **MAE (Error Medio Absoluto): 2.778:** El MAE de 2.778 también es considerablemente alto, lo que sugiere que, en promedio, el sistema se está desviando casi 3 unidades en sus predicciones. Esto implica que las recomendaciones del sistema no están siendo lo suficientemente precisas para ajustarse a las expectativas de los usuarios, lo que puede resultar en una experiencia insatisfactoria para ellos.

Limitaciones A pesar de los resultados obtenidos, el sistema de recomendación presenta algunas limitaciones que es importante destacar. Una de las principales dificultades observadas es la capacidad del modelo para realizar predicciones precisas en películas que se espera tengan calificaciones bajas. Este tipo de películas tienden a recibir menos atención de los usuarios, lo que genera un sesgo en los datos disponibles para su análisis y, en consecuencia, afecta la precisión de las predicciones. Esto es especialmente notable cuando se trabaja con conjuntos de datos que no cuentan con suficientes ejemplos de estas películas, dificultando la generalización de las recomendaciones.

Otra limitación importante se refiere a la velocidad de la implementación. Durante la primera ejecución del algoritmo, el procesamiento de los datos y el cálculo de las probabilidades resulta lento debido a la necesidad de precomputar una gran cantidad de información. Sin embargo, una vez que estos cálculos iniciales se han realizado, el sistema es capaz de ejecutar las recomendaciones de manera mucho más eficiente. Esta característica hace que el sistema sea más adecuado para implementarse en computadoras con buenos recursos computacio-




Figura 5. Gráfico de diferencias absolutas entre las recomendaciones del sistema y las preferencias del usuario. Calificaciones 1, 2, 3.

nales, donde la fase de precomputación puede realizarse sin afectar la experiencia del usuario final.

6. Conclusiones

El presente trabajo se centró en la hibridación de técnicas en sistemas de recomendación, específicamente comparando el enfoque probabilístico con la factorización matricial en el contexto del filtrado colaborativo. Los resultados permiten extraer las siguientes conclusiones relevantes:

- El enfoque probabilístico, materializado a través del algoritmo *Naive Bayes Collaborative Filtering* (NBCF), no solo demuestra una capacidad comparable en términos de precisión frente a la factorización matricial, sino que también ofrece ventajas adicionales en cuanto a la interpretabilidad de las recomendaciones. Este aspecto resulta fundamental en aplicaciones donde la transparencia es clave para mejorar la experiencia del usuario.
- La implementación del algoritmo NBCF y su expansión a la recomendación grupal mediante la técnica de *Naive Pooling* (NBP) resuelve de manera eficiente el problema de personalización colectiva. Los resultados experimentales mostraron que este enfoque proporciona recomendaciones coherentes tanto a nivel individual como grupal, lo que es particularmente útil en escenarios de recomendación para familias o grupos de amigos.
- En la evaluación sobre el dataset *FilmTrust*, se observó que el enfoque NBCF híbrido mejoró las métricas de rendimiento clave como el error cuadrático medio (MSE) y el error medio absoluto (MAE), especialmente en grupos

Grupo	Película	Esperado	Recibido	Diferencia	Diferencia absoluta
0	206	1	8	-7	7
1	234	3	4	-1	1
2	0	3	6	-3	3
3	9	3	4	-1	1
4	16	3	7	-4	4
5	256	2	4	-2	2
6	206	3	6	-3	3
7	6	3	5	-2	2
8	11	3	6	-3	3
9	215	3	5	-2	2
10	9	2	4	-2	2

Figura 6. Resumen cuantitativo de los resultados del sistema de recomendación. Calificaciones 1, 2, 3.

con votaciones positivas. No obstante, en contextos de votaciones negativas, el rendimiento fue menor, lo que apunta a posibles áreas de mejora en el tratamiento de conjuntos de datos escasos.

- A pesar de los buenos resultados en general, el sistema de recomendación presenta limitaciones en la velocidad inicial de procesamiento y en su capacidad para predecir con precisión películas con bajas calificaciones, lo que sugiere la necesidad de optimizaciones adicionales tanto en la fase de precomputación como en la gestión de la dispersión de datos (*sparsity*) del conjunto.
- Finalmente, se destaca la flexibilidad del enfoque probabilístico para integrar nuevas variables y su potencial para aplicaciones futuras en diferentes dominios, extendiendo así las capacidades actuales de los sistemas de recomendación colaborativos.

La investigación confirma que la hibridación de técnicas de recomendación, en particular el enfoque probabilístico, ofrece una alternativa robusta y explicativa frente a la factorización matricial, mejorando la capacidad de personalización tanto a nivel individual como grupal, con oportunidades claras de optimización en áreas específicas. Se propuso la extensión del método NBCF para realizar recomendaciones a grupos mediando su hibridación con el método NBP.

Referencias

1. Valdiviezo-Díaz, P., Ortega, F., Cobos, E., & Lara-Cabrera, R. (2019). A collaborative filtering approach based on Naïve Bayes classifier. *IEEE Access*, 7, 108581-108592.
2. González, O. E., & Jacques, S. M. (2017). Estado del arte en los sistemas de recomendación. *Res. Comput. Sci.*, 135, 25-40.
3. Ortega, F., Rojo, D., Valdiviezo-Díaz, P., & Raya, L. (2018). Hybrid collaborative filtering based on users rating behavior. *IEEE Access*, 6, 69582-69591.
4. Valdiviezo, P. M. (2019). Sistema recomendador híbrido basado en modelos probabilísticos (Doctoral dissertation, Universidad Politécnica de Madrid).

5. Samsudin, N. A., & Bradley, A. P. (2014). Extended naïve bayes for group based classification. In Recent Advances on Soft Computing and Data Mining: Proceedings of The First International Conference on Soft Computing and Data Mining (SCDM-2014) Universiti Tun Hussein Onn Malaysia, Johor, Malaysia June 16th-18th, 2014 (pp. 497-505). Springer International Publishing.
6. J. Golbeck, J. Hendler, “FilmTrust: movie recommendations using trust in web-based social networks”, CCNC 2006, 3rd IEEE Consumer Communications and Networking Conference, 2006, DOI: 10.1109/CCNC.2006.1593032